




Машинное обучение

Лонгрид

Методы оптимизации

04

Выпуклость множеств и функций. Условие Поляка–Лоясиевича



Выпуклость множеств и функций

Контекст

Хотим решать $f(\mathbf{x}) \rightarrow \min_{\mathbf{x} \in S \subseteq \mathbb{R}^n}$. Без структуры это задача поиска иголки в стоге сена: локальных минимумов может быть экспоненциально много, а градиентный спуск не обязан сходиться к глобальному минимуму. Выпуклость — та структура, при которой локальный минимум автоматически глобален, условия оптимальности из необходимых становятся достаточными, а для градиентных методов появляются *глобальные* оценки скорости сходимости.

Применение

Многие задачи ML изначально выпуклы: линейные наименьшие квадраты, логистическая регрессия, SVM, оценка ковариации через $\log \det$. Даже когда лосс не является выпуклой функцией от параметров модели (например в случае многослойных нейросетей), полезно понимать, какие *элементы* теории выпуклой оптимизации ещё работают. Два таких элемента — сильная выпуклость (единственная точка минимума и линейная сходимость градиентного спуска) и условие Поляка — Лоясиевича (линейная сходимость градиентного спуска без выпуклости целевой функции).

Задача лонгрида

Пройти путь слайдов подробно: от геометрии множеств к критериям выпуклости функций, затем к сильной выпуклости, ℓ_2 -регуляризации и PL. Все основные теоремы доказываются, а не только формулируются.

Краткий план

- Зачем выпуклость
- Выпуклые множества: определение, операции, проекция
- Выпуклые функции: эпиграф, критерии 1-го и 2-го порядка
- Сильная выпуклость и задача наименьших квадратов
- Условие PL и линейный GD без выпуклости

1. КАРТА ПОНЯТИЙ

Четыре свойства, которые понадобятся дальше, удобно держать рядом: каждое отвечает на свой вопрос — про допустимую область, про ландшафт лосса, про единственность минимума и про скорость GD.

Свойство	Геометрия	Практика
S выпукло	отрезок внутри S	допустимая область содержит все отрезки с концами в S
f выпукла	хорда над графиком	локальный min = глобальный
f μ -сильно выпукла	квадратичная оценка снизу	единственный min, линейная сходимость GD
Условие Поляка — Лоясиевича (PL)	$\ f'(\mathbf{x})\ ^2 \gtrsim f(\mathbf{x}) - f^*$	линейная сходимость GD без выпуклости

Базовая литература:



- S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge Univ. Press, 2004. [ссылка](#). (геометрия, эпиграф, DCP)
- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018; (гладкость, сильная выпуклость, скорости GD).
- H. Karimi, J. Nutini, M. Schmidt. *Linear Convergence of Gradient and Proximal-Gradient Methods under the Polyak-Łojasiewicz Condition*. ECML PKDD, 2016. [arXiv:1608.04636](#).

2. ВЫПУКЛЫЕ МНОЖЕСТВА

Прежде чем говорить о выпуклых функциях, нужно уметь быстро распознавать выпуклые множества, так как выпуклые функции определены *на* выпуклых множествах. Рабочий навык тот же, что в слайдах: либо узнать простое множество (шар, полупространство, полиэдр), либо представить его как результат операций, сохраняющих выпуклость (пересечение, аффинное отображение, сумма Минковского).

Определение и примеры

ОПРЕДЕЛЕНИЕ 1

Множество $S \subseteq \mathbb{R}^n$ **выпукло**, если вместе с любыми двумя точками оно содержит весь отрезок:

$$\mathbf{x}, \mathbf{y} \in S, \quad \lambda \in [0, 1] \implies \lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in S.$$

ЗАМЕЧАНИЕ

Невыпуклость проверяется контрпримером: необходимо найти две точки множества такие что, соединив их отрезком, найдётся точка внутри отрезка, но не из множества.

Примеры:

- Сфера $\{\mathbf{x} : \|\mathbf{x}\|_2 = 1\}$ невыпукла: любая хорда содержит точки вне сферы
- График функции $f(x) = x^2$ образует невыпуклое множество: любой отрезок, соединяющий точки графика, содержит точки ниже графика
- Объединение двух непересекающихся шаров, которые сами по себе являются выпуклыми множествами, невыпукло.

ПРИМЕР 1

Выпуклы:

- $\mathbb{R}^n$;
- полупространство $\{\mathbf{x} : \mathbf{a}^\top \mathbf{x} \leq b\}$;
- политоп $\{\mathbf{x} : \mathbf{A}\mathbf{x} \leq \mathbf{b}\}$;
- вероятностный симплекс $\{\mathbf{p} \geq 0 : \sum_i p_i = 1\}$;
- множество PSD-матриц $\mathbb{S}_+^n = \{\mathbf{X} = \mathbf{X}^\top : \mathbf{X} \succeq 0\}$;
- аффинное множество (вместе с двумя точками содержит *всю* прямую).

ДОКАЗАТЕЛЬСТВО

Во всех пунктах берём $\mathbf{x}, \mathbf{y}$ из множества и $\lambda \in [0, 1]$. Нужно проверить, что $\mathbf{z} = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ тоже лежит в множестве.

$\mathbb{R}^n$. Сложение и умножение на скаляр не выводят из $\mathbb{R}^n$, поэтому $\mathbf{z} \in \mathbb{R}^n$.

Полупространство. Пусть $\mathbf{a}^\top \mathbf{x} \leq b$ и $\mathbf{a}^\top \mathbf{y} \leq b$. Линейность скалярного произведения даёт

$$\mathbf{a}^\top \mathbf{z} = \lambda \mathbf{a}^\top \mathbf{x} + (1 - \lambda) \mathbf{a}^\top \mathbf{y} \leq \lambda b + (1 - \lambda)b = b,$$

то есть $\mathbf{z}$ лежит в полупространстве.

Открытое полупространство $\{\mathbf{a}^\top \mathbf{x} < b\}$ выпукло по тем же рассуждениям (неравенство остаётся строгим).

Гиперплоскость $\{\mathbf{a}^\top \mathbf{x} = b\}$ выпукла: в цепочке выше оба неравенства становятся равенствами.

Политоп. Условие $\mathbf{Ax} \leq \mathbf{b}$ — это конечный набор полупространств: если $\mathbf{a}_i^\top$ — i -я строка $\mathbf{A}$, то

$$\{\mathbf{x} : \mathbf{Ax} \leq \mathbf{b}\} = \bigcap_i \{\mathbf{x} : \mathbf{a}_i^\top \mathbf{x} \leq b_i\}.$$

Каждое полупространство выпукло. Если $\mathbf{x}$ и $\mathbf{y}$ удовлетворяют всем неравенствам, то по уже доказанному пункту им удовлетворяет и $\mathbf{z}$. Значит политоп является пересечением выпуклых множеств и, следовательно, выпуклое множество. (Ниже мы оформим это как общее утверждение: пересечение любого семейства выпуклых множеств выпукло.)

Вероятностный симплекс. Запишем его как пересечение ортанта и гиперплоскости

$$\{\mathbf{p} : p_i \geq 0, i = 1, \dots, n\} \cap \{\mathbf{p} : \mathbf{1}^\top \mathbf{p} = 1\}.$$

Ортант — пересечение полупространств $\{-e_i^\top \mathbf{p} \leq 0\}$, гиперплоскость выпукла по пункту про полупространство. Если $\mathbf{p}, \mathbf{q}$ — вероятностные векторы, то $z_i = \lambda p_i + (1 - \lambda)q_i \geq 0$ и

$$\sum_i z_i = \lambda \sum_i p_i + (1 - \lambda) \sum_i q_i = 1,$$

поэтому $\mathbf{z}$ лежит в симплексе.

Множество PSD-матриц. Пусть $\mathbf{X}, \mathbf{Y} \in \mathbb{S}_+^n$ и $\mathbf{Z} = \lambda \mathbf{X} + (1 - \lambda) \mathbf{Y}$. Симметричность сохраняется: $\mathbf{Z}^\top = \lambda \mathbf{X}^\top + (1 - \lambda) \mathbf{Y}^\top = \lambda \mathbf{X} + (1 - \lambda) \mathbf{Y} = \mathbf{Z}$. По определению $\mathbf{X} \succeq 0$ тогда и только тогда, когда $\mathbf{v}^\top \mathbf{X} \mathbf{v} \geq 0$ для всех $\mathbf{v} \in \mathbb{R}^n$. Поэтому

$$\mathbf{v}^\top \mathbf{Z} \mathbf{v} = \lambda \mathbf{v}^\top \mathbf{X} \mathbf{v} + (1 - \lambda) \mathbf{v}^\top \mathbf{Y} \mathbf{v} \geq 0$$

для любого $\mathbf{v}$, то есть $\mathbf{Z} \succeq 0$.

Аффинное множество. По определению вместе с $\mathbf{x}, \mathbf{y}$ оно содержит всю прямую $\{\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} : \lambda \in \mathbb{R}\}$, а отрезок — это сужение той же прямой на $\lambda \in [0, 1]$. Значит всякое аффинное множество выпукло.

Обратное неверно: шар выпуклое множество, но не аффинное.

ПРИМЕР 2

Шар в любой норме $\{\mathbf{x} : \|\mathbf{x} - \mathbf{x}_0\| \leq R\}$ является выпуклым множеством.

ДОКАЗАТЕЛЬСТВО

Пусть $\|\mathbf{x} - \mathbf{x}_0\| \leq R$, $\|\mathbf{y} - \mathbf{x}_0\| \leq R$, $\lambda \in [0,1]$. Однородность и неравенство треугольника дают

$$\begin{aligned} \|\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} - \mathbf{x}_0\| &= \|\lambda(\mathbf{x} - \mathbf{x}_0) + (1 - \lambda)(\mathbf{y} - \mathbf{x}_0)\| \leq \\ &\leq \lambda \|\mathbf{x} - \mathbf{x}_0\| + (1 - \lambda) \|\mathbf{y} - \mathbf{x}_0\| \leq R. \end{aligned}$$

Выпуклая комбинация и оболочка

ОПРЕДЕЛЕНИЕ 2

Точка $\sum_{i=1}^k \lambda_i \mathbf{x}_i$ с $\lambda_i \geq 0$, $\sum_i \lambda_i = 1$ называется **выпуклой комбинацией** точек $\mathbf{x}_i$. **Выпуклая оболочка** $\text{conv}(S)$ — наименьшее выпуклое множество, содержащее S ; она совпадает с множеством всех конечных выпуклых комбинаций точек из S .

ЗАМЕЧАНИЕ

На политопе линейная функция достигает минимума в вершине. Это геометрическая основа симплекс-метода для задачи линейного программирования.

$$\begin{aligned} \min \mathbf{c}^\top \mathbf{x} \\ \text{s.t. } \mathbf{x} \geq 0 \\ \mathbf{Ax} = \mathbf{b} \end{aligned}$$

Операции, сохраняющие выпуклость

Проверять выпуклость каждого множества «в лоб» неэффективно. Рабочий путь — собрать его из простых выпуклых элементов операциями, которые выпуклость сохраняют.

ТЕОРЕМА 1

Пересечение любого (в том числе бесконечного) семейства выпуклых множеств выпукло.

ДОКАЗАТЕЛЬСТВО

Пусть $S = \bigcap_{\alpha} S_{\alpha}$, все S_{α} выпуклы, $\mathbf{x}, \mathbf{y} \in S$. Тогда $\mathbf{x}, \mathbf{y} \in S_{\alpha}$ для каждого α , значит отрезок лежит в каждом S_{α} , а потому и в пересечении.

ТЕОРЕМА 2

Пусть $S \subseteq \mathbb{R}^n$ выпукло и $\varphi(\mathbf{x}) = \mathbf{Ax} + \mathbf{b}$ — аффинное отображение. Тогда выпуклы образ $\varphi(S)$ и, если $D \subseteq \mathbb{R}^m$ выпукло, прообраз $\varphi^{-1}(D) = \{\mathbf{x} : \mathbf{Ax} + \mathbf{b} \in D\}$.

ДОКАЗАТЕЛЬСТВО

Образ: $\lambda(\mathbf{Ax} + \mathbf{b}) + (1 - \lambda)(\mathbf{Ay} + \mathbf{b}) = \mathbf{A}(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) + \mathbf{b} \in \varphi(S)$. Прообраз: если $\mathbf{Ax} + \mathbf{b}, \mathbf{Ay} + \mathbf{b} \in D$, то $\mathbf{A}(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) + \mathbf{b}$ — выпуклая комбинация в D .

ТЕОРЕМА 3

Если S_1, S_2 выпуклы, выпукла сумма Минковского $S_1 + S_2 = \{\mathbf{x} + \mathbf{y} : \mathbf{x} \in S_1, \mathbf{y} \in S_2\}$.

ДОКАЗАТЕЛЬСТВО

Это аффинный образ $S_1 \times S_2$ при $(\mathbf{x}, \mathbf{y}) \mapsto \mathbf{x} + \mathbf{y}$. Декартово произведение выпуклых множеств выпукло (отрезок берётся по координатам).

Проекция

Многие методы для задач с ограничениями делают шаг как будто ограничений нет и затем *проецируют* точку на допустимое множество S :

$$\Pi_S(\mathbf{z}) = \arg \min_{\mathbf{x} \in S} \|\mathbf{x} - \mathbf{z}\|_2.$$

ТЕОРЕМА 4

Если $S \subseteq \mathbb{R}^n$ выпукло и замкнуто, проекция $\Pi_S(\mathbf{z})$ существует и единственна для любого $\mathbf{z}$.

ДОКАЗАТЕЛЬСТВО

Существование: функция $\mathbf{x} \mapsto \|\mathbf{x} - \mathbf{z}\|_2^2$ непрерывна и ограничена снизу, на непустом замкнутом S минимум достигается.

Единственность: если $\mathbf{x} \neq \mathbf{y}$ — два минимума, то середина $\mathbf{m} = \frac{1}{2}(\mathbf{x} + \mathbf{y}) \in S$ (выпуклость S), и

$$\|\mathbf{m} - \mathbf{z}\|_2^2 = \frac{1}{2}\|\mathbf{x} - \mathbf{z}\|_2^2 + \frac{1}{2}\|\mathbf{y} - \mathbf{z}\|_2^2 - \frac{1}{4}\|\mathbf{x} - \mathbf{y}\|_2^2$$

строго меньше общего значения минимума, получаем противоречие.

ЗАМЕЧАНИЕ

Без выпуклости проекция может быть неоднозначной (несколько ближайших точек) и NP-трудной. Для ℓ_2 -шара, ортанта, симплекса и аффинного подпространства проекция считается в замкнутой форме. Вариационная характеристика: $\mathbf{x} = \Pi_S(\mathbf{z}) \Leftrightarrow \langle \mathbf{z} - \mathbf{x}, \mathbf{y} - \mathbf{x} \rangle \leq 0$ для всех $\mathbf{y} \in S$ (все допустимые направления смотрят «от $\mathbf{z}$ »).

3. ВЫПУКЛЫЕ ФУНКЦИИ

Выпуклая функция — это функция, надграфик которой выпукл: вся геометрия предыдущего подраздела немедленно превращается в утверждения о функциях. Именно выпуклость отделяет задачи, которые мы умеем решать с гарантиями, от задач, где гарантий нет.

Определение

ОПРЕДЕЛЕНИЕ 3

Функция f , заданная на выпуклом $S \subseteq \mathbb{R}^n$, **выпукла**, если для всех $\mathbf{x}, \mathbf{y} \in S$ и $\lambda \in [0, 1]$

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Строгая выпуклость: неравенство строгое при $\mathbf{x} \neq \mathbf{y}$ и $\lambda \in (0, 1)$. Функция **вогнута**, если $-f$ выпукла.

Геометрия: график лежит *не выше* любой хорды.

ПРИМЕР 3

Выпуклые функции:

- аффинная $\mathbf{a}^\top \mathbf{x} + b$ (и вогнута, так как равенство в определении);
- любая норма $\|\mathbf{x}\|_p$, $p \geq 1$;
- поточечный максимум выпуклых функций.

ДОКАЗАТЕЛЬСТВО

Во всех пунктах берём $\mathbf{x}, \mathbf{y}$ из области определения и $\lambda \in [0, 1]$; нужно проверить $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y})$.

Аффинная функция. Пусть $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + b$. Тогда

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) = \lambda(\mathbf{a}^\top \mathbf{x} + b) + (1 - \lambda)(\mathbf{a}^\top \mathbf{y} + b) = \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}).$$

В определении выпуклости — равенство, поэтому f одновременно выпукла и вогнута.

Норма. Для любой нормы (в том числе $\|\cdot\|_p$ при $p \geq 1$) однородность и неравенство треугольника дают

$$\|\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}\| \leq \lambda \|\mathbf{x}\| + (1 - \lambda)\|\mathbf{y}\|.$$

Это в точности определение выпуклости. При $0 < p < 1$ функция $\|\cdot\|_p$ нормой не является и, как правило, невыпукла.

Поточечный максимум. Пусть $f = \max_i f_i$ и каждое f_i выпукло. Тогда

$$\begin{aligned} f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) &= \max_i f_i(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \\ &\leq \max_i (\lambda f_i(\mathbf{x}) + (1 - \lambda)f_i(\mathbf{y})) \\ &\leq \lambda \max_i f_i(\mathbf{x}) + (1 - \lambda) \max_i f_i(\mathbf{y}) = \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}). \end{aligned}$$

Тот же аргумент работает для $\sup$ любого (даже бесконечного) семейства выпуклых функций.

ПРИМЕР 4

Невыпуклые функции:

- x^3 на $\mathbb{R}$;
- нуль-норма $\|\mathbf{x}\|_0$ равная числу ненулевых координат вектора $\mathbf{x}$;
- NMF $f(\mathbf{W}, \mathbf{H}) = \|\mathbf{X} - \mathbf{WH}\|_F^2$ при $\mathbf{W}, \mathbf{H} \geq 0$ невыпуклая, так как невыпуклость произведения матриц.

Надграфик

ОПРЕДЕЛЕНИЕ 4

Надграфик f — множество

$$\text{epi } f = \{(\mathbf{x}, t) : f(\mathbf{x}) \leq t\} \subseteq S \times \mathbb{R}.$$

ТЕОРЕМА 5

f выпукла на выпуклом S тогда и только тогда, когда $\text{epi } f$ выпукло.

ДОКАЗАТЕЛЬСТВО

($\Rightarrow$) Пусть $(\mathbf{x}, t), (\mathbf{y}, s) \in \text{epi } f$, $\lambda \in [0, 1]$. Тогда $f(\mathbf{x}) \leq t$, $f(\mathbf{y}) \leq s$, и по выпуклости f

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \leq \lambda t + (1 - \lambda)s,$$

то есть $\lambda(\mathbf{x}, t) + (1 - \lambda)(\mathbf{y}, s) \in \text{epi } f$.

($\Leftarrow$) Возьмём $\mathbf{x}, \mathbf{y} \in S$. Точки $(\mathbf{x}, f(\mathbf{x}))$ и $(\mathbf{y}, f(\mathbf{y}))$ лежат в $\text{epi } f$. Их выпуклая комбинация тоже в $\text{epi } f$, откуда $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y})$.

Следствие: свойства функций сводятся к геометрии множеств. В частности, минимизация f — это поиск «самой нижней» точки эпиграфа.

ТЕОРЕМА 6

$$\min_{\mathbf{x}} f(\mathbf{x}) \iff \min_{\mathbf{x}, t} t \quad \text{s.t.} \quad f(\mathbf{x}) \leq t.$$

Правая задача — линейная целевая функция на ер f . В оптимуме $t^* = f(\mathbf{x}^*)$.

ДОКАЗАТЕЛЬСТВО

Если $(\mathbf{x}, t)$ допустима, то $t \geq f(\mathbf{x}) \geq \inf f$, поэтому $\inf t \geq \inf f$. Для любого $\mathbf{x}$ пара $(\mathbf{x}, f(\mathbf{x}))$ допустима, значит $\inf t \leq \inf f$. Итого значения совпадают. Если $t > f(\mathbf{x})$, можно уменьшить t при том же $\mathbf{x}$; значит в минимуме $t^* = f(\mathbf{x}^*)$, и $\mathbf{x}^*$ минимизирует f .

Критерий первого порядка

ТЕОРЕМА 7

Пусть f дифференцируема на S . Тогда f выпукла $\Leftrightarrow$

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle \quad \forall \mathbf{x}, \mathbf{y} \in S.$$

Геометрия: график лежит *не ниже* любой касательной.

ДОКАЗАТЕЛЬСТВО

($\Rightarrow$) По определению

$$f(\mathbf{x} + \lambda(\mathbf{y} - \mathbf{x})) \leq (1 - \lambda)f(\mathbf{x}) + \lambda f(\mathbf{y}), \quad \lambda \in (0, 1].$$

Перенос и деление на λ :

$$\frac{f(\mathbf{x} + \lambda(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{\lambda} \leq f(\mathbf{y}) - f(\mathbf{x}).$$

Предел $\lambda \rightarrow 0+$ есть $f'(\mathbf{x})^\top (\mathbf{y} - \mathbf{x})$.

($\Leftarrow$) Запишем неравенство в $\mathbf{x}$ и в $\mathbf{y}$ для точки $\mathbf{z} = \lambda\mathbf{x} + (1 - \lambda)\mathbf{y}$:

$$\begin{aligned} f(\mathbf{x}) &\geq f(\mathbf{z}) + \langle f'(\mathbf{z}), \mathbf{x} - \mathbf{z} \rangle, \\ f(\mathbf{y}) &\geq f(\mathbf{z}) + \langle f'(\mathbf{z}), \mathbf{y} - \mathbf{z} \rangle. \end{aligned}$$

Умножим на λ и $1 - \lambda$ и сложим. Слагаемые с $f'(\mathbf{z})$ сокращаются, потому что $\lambda(\mathbf{x} - \mathbf{z}) + (1 - \lambda)(\mathbf{y} - \mathbf{z}) = \mathbf{0}$. Получаем определение выпуклости.

ТЕОРЕМА 8

Если f выпукла и дифференцируема, то $f'(\mathbf{x}) = \mathbf{0}$ влечёт, что $\mathbf{x}$ — глобальный минимум. Локальных «ложных» минимумов нет.

ДОКАЗАТЕЛЬСТВО

Критерий первого порядка: $f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \mathbf{0}, \mathbf{y} - \mathbf{x} \rangle = f(\mathbf{x})$ для всех $\mathbf{y}$.



Интерпретация для GD: шаг в направлении антиградиента всегда уменьшает *линейную модель* лосса.

Критерий второго порядка

ТЕОРЕМА 9

Пусть f дважды непрерывно дифференцируема на открытом выпуклом S . Тогда f выпукла $\Leftrightarrow f''(\mathbf{x}) \succeq 0$ во всех $\mathbf{x} \in S$.

ДОКАЗАТЕЛЬСТВО

($\Rightarrow$) Критерий первого порядка в $\mathbf{x}$ и в $\mathbf{x} + t\mathbf{h}$:

$$f(\mathbf{x} + t\mathbf{h}) \geq f(\mathbf{x}) + t\langle f'(\mathbf{x}), \mathbf{h} \rangle.$$

Разложение Тейлора слева: $f(\mathbf{x}) + t\langle f'(\mathbf{x}), \mathbf{h} \rangle + \frac{t^2}{2} \mathbf{h}^\top f''(\mathbf{x}) \mathbf{h} + o(t^2)$. Значит $\mathbf{h}^\top f''(\mathbf{x}) \mathbf{h} \geq 0$ для всех $\mathbf{h}$.

($\Leftarrow$) Формула Тейлора с остаточным членом в форме Лагранжа:

$$f(\mathbf{y}) = f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{1}{2}(\mathbf{y} - \mathbf{x})^\top f''(\xi)(\mathbf{y} - \mathbf{x})$$

для некоторого ξ на отрезке, соединяющем $\mathbf{x}$ и $\mathbf{y}$. Последнее слагаемое неотрицательно в силу положительной определённости гессиана, и срабатывает критерий первого порядка.

ПРИМЕР 5

Квадратичная $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x}$ выпукла $\Leftrightarrow \mathbf{A} \succeq 0$ по критерию второго порядка. Для LLS $f(\boldsymbol{\theta}) = \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|_2^2$ гессиан равен $2\mathbf{X}^\top \mathbf{X} \succeq 0$ всегда.

Операции, сохраняющие выпуклость

ТЕОРЕМА 10

Если f_i выпуклы, то выпуклы:

- неотрицательная сумма $\sum_i \alpha_i f_i, \alpha_i \geq 0$;
- аффинная подстановка $f(\mathbf{A}\mathbf{x} + \mathbf{b})$;
- поточечный максимум $\max_i f_i$ (и $\sup$ любого семейства);
- композиция $g(f(\mathbf{x}))$, если g выпукла и неубывает (на образе f).

ДОКАЗАТЕЛЬСТВО

Сумма и аффинная подстановка — прямая подстановка в определение. Максимум: $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \max_i (\lambda f_i(\mathbf{x}) + (1 - \lambda)f_i(\mathbf{y})) \leq \lambda \max f_i(\mathbf{x}) + (1 - \lambda) \max f_i(\mathbf{y})$. Композиция: $g(f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y})) \leq g(\lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}))$ (неубывание g и выпуклость f), и далее $\leq \lambda g(f(\mathbf{x})) + (1 - \lambda)g(f(\mathbf{y}))$ (выпуклость g). Примеры неубывающих выпуклых g : $e^t, \max\{t, 0\}$.

ПРИМЕР 6

Логистический лосс $\ell(z) = \log(1 + e^{-z})$ выпукл по z (вторая производная $\ell''(z) = \sigma(z)(1 - \sigma(z)) \in (0, 1/4]$, где σ — сигмоида). Аффинная подстановка $z = \mathbf{y}_i \mathbf{x}_i^\top \mathbf{w}$ и неотрицательная сумма дают выпуклость $\sum_i \ell(\mathbf{y}_i \mathbf{x}_i^\top \mathbf{w})$ по $\mathbf{w}$.



DCP (Disciplined Convex Programming): вместо проверки выпуклости «с нуля» функцию собирают из атомов по правилам, автоматически сохраняющим выпуклость. Так устроены CVX, CVXPY, Convex.jl. См. Grant, Boyd, Ye, *CVX: Matlab software for disciplined convex programming*.

4. СИЛЬНАЯ ВЫПУКЛОСТЬ

Выпуклости достаточно, чтобы локальный минимум был глобальным, но недостаточно для линейной скорости GD и единственности точки минимума. Нужна более жёсткая оценка снизу — квадратичная. Существование такой оценки приводит к определению сильной выпуклости.

Определение и эквивалентности

ОПРЕДЕЛЕНИЕ 5

Функция f μ -сильно выпукла ($\mu > 0$), если для всех $\mathbf{x}, \mathbf{y}$ и $\lambda \in [0, 1]$

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) - \frac{\mu}{2}\lambda(1 - \lambda)\|\mathbf{x} - \mathbf{y}\|^2.$$

Эквивалентно: $f - \frac{\mu}{2}\|\cdot\|^2$ выпукла.

ТЕОРЕМА 11

Для дифференцируемой f μ -сильная выпуклость эквивалентна

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

Для дважды непрерывно дифференцируемой f это же свойство эквивалентно $f''(\mathbf{x}) \succeq \mu \mathbf{I}$ всюду.

ДОКАЗАТЕЛЬСТВО

Первая эквивалентность — критерий первого порядка, применённый к выпуклой $g = f - \frac{\mu}{2}\|\cdot\|^2$: $g(\mathbf{y}) \geq g(\mathbf{x}) + \langle g'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle$, и $g'(\mathbf{x}) = f'(\mathbf{x}) - \mu\mathbf{x}$. Вторая — критерий второго порядка для g : $g'' = f'' - \mu\mathbf{I} \succeq 0$.

Геометрия: график лежит не ниже параболы с кривизной μ , касающейся графика в $\mathbf{x}$. Не путать *сильную* выпуклость со *строгой*: строгая запрещает линейные куски, но не даёт квадратичного роста и линейной скорости GD.

Единственность точки минимума

ТЕОРЕМА 12

Пусть f μ -сильно выпукла и дифференцируема, $\mathbf{x}^*$ — стационарная точка ($f'(\mathbf{x}^*) = 0$). Тогда $\mathbf{x}^*$ — единственный глобальный минимум и

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \frac{\mu}{2}\|\mathbf{x} - \mathbf{x}^*\|^2.$$

«Плоского дна» нет: уход на расстояние δ поднимает значение хотя бы на $\frac{\mu}{2}\delta^2$.

ДОКАЗАТЕЛЬСТВО

Подставить $\mathbf{y} = \mathbf{x}$, $\mathbf{x} = \mathbf{x}^*$ в критерий первого порядка. Если есть два минимума, квадратичный рост запрещает $f(\mathbf{x}) = f(\mathbf{x}^*)$ при $\mathbf{x} \neq \mathbf{x}^*$.

5. УСЛОВИЕ ПОЛЯКА — ЛОЯСИЕВИЧА (PL)

Определение

ОПРЕДЕЛЕНИЕ 6

Говорят, что f удовлетворяет **условию Поляка — Лоясиевича (PL)** с константой $\mu > 0$, если

$$\|f'(\mathbf{x})\|^2 \geq 2\mu(f(\mathbf{x}) - f^*) \quad \forall \mathbf{x},$$

где $f^* = \inf f$.

Выпуклость не требуется. Смысл: если градиент мал, значение уже близко к оптимуму. В частности, всякая стационарная точка — глобальный минимум: из $f'(\mathbf{x}) = \mathbf{0}$ следует $f(\mathbf{x}) = f^*$. Множество $\{f' = 0\}$ при этом может быть несвязным, и минимум не обязан быть единственным.

ЗАМЕЧАНИЕ Исторически неравенство появилось у Polyak (1963) именно как достаточное условие линейной скорости GD и у Łojasiewicz (1963) в аналитической теории особенностей.

Сильная выпуклость влечёт PL

ТЕОРЕМА 13

Если f L -гладкая и μ -сильно выпукла, то она удовлетворяет PL с той же константой μ . Обратное неверно: бывают невыпуклые PL-функции.

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость:

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|^2.$$

Правая часть по $\mathbf{y}$ — квадратичная; минимум в $\mathbf{y} = \mathbf{x} - \frac{1}{\mu} f'(\mathbf{x})$ равен $f(\mathbf{x}) - \frac{1}{2\mu} \|f'(\mathbf{x})\|^2$. Значит $f^* \geq f(\mathbf{x}) - \frac{1}{2\mu} \|f'(\mathbf{x})\|^2$, что и есть PL.

6. ЕСЛИ КРАТКО

- Выпуклое множество содержит все свои отрезки; пересечение и аффинные образы/прообразы сохраняют выпуклость.
- f выпукла $\Leftrightarrow \text{epi } f$ выпукло $\Leftrightarrow$ график не ниже касательной $\Leftrightarrow f'' \succeq 0$.
- У выпуклой дифференцируемой задачи любая стационарная точка — глобальный минимум.
- Сильная выпуклость: квадратичный рост, уникальный min
- ℓ_2 -регуляризация превращает выпуклый лосс в сильно выпуклый (ridge / Tikhonov для LLS).
- PL: $\|f'\|^2 \geq 2\mu(f - f^*)$ без выпуклости самой f ; SC $\Rightarrow$ PL, но не наоборот.

Что почитать

- S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge Univ. Press, 2004. web.stanford.edu/~boyd/cvxbook. Геометрия множеств, эпиграф, критерии, DCP.
- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018. Гладкость, сильная выпуклость, линейная скорость GD, §2.1–2.2.
- S. Bubeck. *Convex Optimization: Algorithms and Complexity*. Foundations and Trends in Machine Learning, 2015 ([arXiv:1405.4980](https://arxiv.org/abs/1405.4980)).
- B. T. Polyak. *Gradient methods for minimizing functionals*. Zh. Vychisl. Mat. Mat. Fiz., 3(4):643–653, 1963. Исходное PL-неравенство и линейная скорость GD.
- S. Łojasiewicz. *Une propriété topologique des sous-ensembles analytiques réels*. In: Les équations aux dérivées partielles, CNRS, 1963.
- H. Karimi, J. Nutini, M. Schmidt. *Linear Convergence of Gradient and Proximal-Gradient Methods under the Polyak-Łojasiewicz Condition*. ECML PKDD, 2016 ([arXiv:1608.04636](https://arxiv.org/abs/1608.04636)).
- M. C. Grant, S. Boyd, Y. Ye. CVX: Matlab software for disciplined convex programming. cvxr.com/cvx.

- S. Diamond, S. Boyd. CVXPY: A Python-embedded modeling language for convex optimization. JMLR, 2016 (cvxpy.org).
- C. Liu, L. Zhu, M. Belkin. *Loss landscapes and optimization in over-parameterized non-linear systems and neural networks*. NeurIPS, 2020 ([arXiv:2003.00307](https://arxiv.org/abs/2003.00307)). Локальное PL^* у широких сетей.
- K. Kawaguchi. *Deep Learning without Poor Local Minima*. NeurIPS, 2016 ([arXiv:1605.07110](https://arxiv.org/abs/1605.07110)).
- M. Hardt, T. Ma. *Identity Matters in Deep Learning*. ICLR, 2017 ([arXiv:1611.04231](https://arxiv.org/abs/1611.04231)); см. также [arXiv:1707.02444](https://arxiv.org/abs/1707.02444) про глубокие линейные сети.