Линейное программирование: постановка и солвер

Контекст

Линейное программирование — первый класс задач в курсе, для которого есть не просто метод, а готовый промышленный солвер: любую задачу в стандартной форме можно отдать в HiGHS или CBC и получить гарантированно оптимальный ответ. Поэтому центр тяжести смещается с того, *как решать*, на то, *как поставить*: вся работа инженера — перевести словесное описание в матрицы и правильно прочитать то, что вернул солвер.

Применение

Планирование производства, составление смесей, раскрой материала, маршрутизация, распределение бюджета, расписания — всё это записывается как LP или как его целочисленный вариант. Полезнее всего оказывается не само оптимальное значение, а двойственная информация: какой ресурс расшивать первым и сколько за это разумно заплатить.

Задача лонгрида

Разберём сквозной пример: поставим задачу, прочитаем ответ целиком и сравним два метода решения. В следующих разделах эта же задача станет целочисленной.

Краткий план

- От словесной задачи к матричной форме
- Что стоит за решением

ЗАМЕЧАНИЕ

Вся вычислительная часть семинара вынесена в ноутбук `lp_ilp_seminar.ipynb`: там решаются те же задачи в `scipy.optimize`, сравниваются методы и реализуется ветвление. Здесь — только то, что решается на доске.

1. ОТ СЛОВЕСНОЙ ЗАДАЧИ К МАТРИЧНОЙ ФОРМЕ



Сквозной пример. Мастерская выпускает два изделия. На единицу первого уходит 6 кг материала и 1 час работы, на единицу второго — 4 кг и 2 часа. В наличии 24 кг материала и 6 часов. Второго изделия нельзя выпустить больше первого более чем на единицу, и больше двух единиц второго склад не примет. Прибыль — 5 и 4 условные единицы за штуку.

$$\max_{x \in \mathbb{R}^2} \; 5x_1 + 4x_2 \quad \text{при} \quad \begin{cases} 6x_1 + 4x_2 \leqslant 24 & \text{(материал)} \\ x_1 + 2x_2 \leqslant 6 & \text{(время)} \\ -x_1 + x_2 \leqslant 1 & \text{(баланс)} \\ x_2 \leqslant 2 & \text{(склад)} \\ x_1, x_2 \geqslant 0 \end{cases}$$

Оптимум достигается в точке $x^\star = (3;\, 1{,}5)$ и равен 21.

Солвер принимает задачу строго в виде $\min c^\top x$ при $A_{ub} x \preceq b_{ub}$, $A_{eq} x = b_{eq}$, $l \preceq x \preceq u$; всё остальное приводится к этому виду руками.

ЗАДАЧА 1

Приведи к стандартной форме $\min c^\top x$ при $Ax \preceq b$, $x \succeq 0$:

1) ограничение $a^\top x \geqslant \beta$;
2) переменную x_i, свободную по знаку;

3) задачу $\min \|x\|_1$ при $Cx = d$;
4) задачу $\min \max_i \left(a_i^\top x + \beta_i\right)$.

Сколько переменных и ограничений добавляется в каждом случае?

ЗАДАЧА 2

Для сквозного примера:

1) какие ограничения активны в точке $(3;\, 1{,}5)$ и почему их ровно столько, сколько переменных;
2) перечисли все вершины допустимого множества и убедись, что максимум достигается в одной из них;
3) при каком изменении вектора прибыли c оптимальной станет вершина $(2;\, 2)$?

2. ЧТО СТОИТ ЗА РЕШЕНИЕМ

Оптимальное значение — наименее содержательная часть ответа. Вместе с ним солвер возвращает остатки $b - Ax^\star$ по каждому ограничению и двойственные переменные, они же **теневые цены**: теневая цена ресурса показывает, на сколько вырастет оптимум, если этого ресурса станет на единицу больше. Для сквозного примера получается такая картина:

ресурс	израсходовано	остаток	теневая цена
материал	24 из 24	0	$0{,}75$
время	6 из 6	0	$0{,}50$
баланс	$-1{,}5$ из 1	$2{,}5$	0
склад	$1{,}5$ из 2	$0{,}5$	0

ЗАМЕЧАНИЕ

Нулевая теневая цена у неактивного ограничения — не совпадение: расширять то, что и так не израсходовано, бессмысленно. Обратное тоже полезно помнить: положительная теневая цена бывает только у активного ограничения.

ЗАДАЧА 3

По таблице выше:

1) какой ресурс стоит расширять первым и сколько разумно заплатить за дополнительный килограмм материала;
2) проверь ответ, решив задачу с лимитом материала 25 вместо 24;
3) останется ли теневая цена прежней, если добавить сразу 10 кг? Что при этом происходит с составом активных ограничений?

3. ЕСЛИ КРАТКО

- Постановка LP механична: переменные, целевая функция, по строке на каждое ограничение. Вся работа — в переводе словесной задачи в c, A, b.
- Максимизация, ограничения вида $\geqslant$, свободные переменные, модули и минимаксы приводятся к стандартной форме стандартными приёмами; часть из них добавляет переменные.
- Остатки показывают, какие ресурсы израсходованы, теневые цены — сколько стоит расширить каждый из них. Ненулевая теневая цена бывает только у активного ограничения.

Целочисленные задачи

Контекст

Как только переменные означают что-то неделимое — штуки изделий, выбранные маршруты, включённые станки, решения «да/нет», — к задаче добавляется требование $x \in \mathbb{Z}^n$, и она перестаёт быть линейным программированием. Множество допустимых точек из многогранника превращается в решётку внутри него, вершины больше ни при чём, и полиномиального метода не существует.

Применение

Практически все производственные задачи планирования целочисленны хотя бы частично. Правильная реакция на это — не пугаться, а понять две вещи: во-первых, округлить решение непрерывной задачи нельзя; во-вторых, для целого класса задач целочисленность даётся бесплатно, и тогда достаточно обычного LP.

Задача лонгрида

Сделаем сквозной пример целочисленным, убедимся, что округление не спасает, и разберём, когда релаксация оказывается целой сама по себе.

Краткий план

- Округление не работает
- Когда релаксация уже целая

1. ОКРУГЛЕНИЕ НЕ РАБОТАЕТ

Выпустить полтора изделия нельзя, поэтому добавим к сквозному примеру условие $x \in \mathbb{Z}^2$. Такая задача называется **целочисленным линейным программированием** (ILP), а исходная задача без этого условия — её **LP-релаксацией**. Оптимум релаксации всегда не хуже целого: она решается на более широком множестве.

Здесь оптимум релаксации равен 21 в точке $(3;\,1{,}5)$, а целочисленный оптимум равен 20 и достигается в точке $(4;\,0)$. Посмотрим на все округления дробного решения:

точка	допустима	прибыль
$(3;\,1)$	да	19
$(3;\,2)$	нет	—
$(4;\,1)$	нет	—
$(4;\,2)$	нет	—



Единственное допустимое округление даёт прибыль 19, тогда как настоящий оптимум равен 20 и достигается в точке $(4;\,0)$ — её нельзя получить из $(3;\,1{,}5)$ никаким округлением. Целочисленный оптимум, вообще говоря, лежит не рядом с дробным.

ЗАДАЧА 1

1. Нарисуй допустимое множество сквозного примера, отметьте все целые точки, оптимум LP и оптимум ILP. Объясни по рисунку, почему округление промахивается.
2. Построй задачу с двумя переменными, в которой все четыре округления LP-решения недопустимы.
3. Приведи пример, в котором разрыв между оптимумами LP и ILP можно сделать сколь угодно большим.

2. КОГДА РЕЛАКСАЦИЯ УЖЕ ЦЕЛАЯ

Так бывает не всегда. В задаче о назначениях требуется раздать n работ n исполнителям, по одной каждому, минимизируя суммарную стоимость:

$$\min_{X} \sum_{i,j} c_{ij} x_{ij} \quad \text{при} \quad \sum_{j} x_{ij} = 1, \qquad \sum_{i} x_{ij} = 1, \qquad x_{ij} \geqslant 0.$$

Условия $x_{ij} \in \{0,1\}$ здесь можно не писать: матрица ограничений вполне унимодулярна, все вершины многогранника целые, и обычный LP возвращает целое решение.

ОПРЕДЕЛЕНИЕ 1

Целочисленная матрица A называется **вполне унимодулярной**, если определитель любой её квадратной подматрицы равен 0, $+1$ или -1. В частности, все элементы самой A равны 0 или ± 1.

ТЕОРЕМА 1

Хоффман — Крускал

Пусть матрица A целочисленна. Многогранник $\{x : Ax \preceq b,\ x \succeq 0\}$ имеет только целые вершины при *любом* целом векторе b тогда и только тогда, когда A вполне унимодулярна.

Слова «при любом b» здесь существенны: свойство относится к матрице ограничений, а не к конкретной задаче. Поэтому его проверяют один раз для целого класса задач — и дальше решают их обычным LP, не вспоминая про целочисленность.

Во что обходится проверка. В лоб — безнадёжно: квадратных подматриц $\sum_k \binom{m}{k}\binom{n}{k}$ штук, то есть экспоненциально много. Критерий Гуила — Ури («всякое подмножество строк можно разбить на две части так, чтобы в каждом столбце разность сумм лежала в $\{-1,0,1\}$») не спасает: подмножеств строк тоже экспоненциально много.

Тем не менее вполне унимодулярность распознаётся за *полиномиальное* время: это следствие теоремы Сеймура о декомпозиции регулярных матроидов (1980). Алгоритм сложный и в обычных библиотеках не встречается, так что на практике матрицу не проверяют, а *опознают* в известном списке. Самый частый пункт списка — матрица инцидентности двудольного графа; именно она стоит в задаче о назначениях и в транспортной задаче. Для недвудольного графа свойство теряется: цикл нечётной длины даёт квадратную подматрицу с определителем ± 2.

Противоположный случай — задача о рюкзаке $\max v^\top x$ при $w^\top x \leqslant W$, $x \in \{0,1\}^n$. Её релаксация дробная почти всегда, причём ровно в одной переменной — той, что «не помещается целиком».

ЗАДАЧА 2

1. Докажи, что вершина многогранника назначений целочисленна, если матрица ограничений вполне унимодулярна.
2. Добавь к задаче побочное ограничение вида «не более одного назначения из заданного набора пар». Почему вполне унимодулярность при этом разрушается и релаксация может стать дробной?
3. Какие ещё знакомые задачи обладают тем же свойством? Проверь рассуждением транспортную задачу.

4. Выпиши матрицу инцидентности треугольника (цикла длины три) и предъяви подматрицу с определителем ± 2. Почему для двудольного графа такой подматрицы не найдётся?

ЗАДАЧА 3

Задача о рюкзаке.

1. Реши её LP-релаксацию вручную и докажите, что дробной может быть не более одной переменной.
2. Как по решению релаксации получить допустимое целое решение и оценку снизу на оптимум?
3. Оцени сверху разрыв между релаксацией и целым оптимумом.

3. ЕСЛИ КРАТКО

- LP-релаксация даёт оценку сверху (для задачи на максимум), но её решение может быть дробным, и округление даёт либо недопустимую точку, либо не оптимальную.
- Целочисленный оптимум не обязан лежать рядом с дробным: в сквозном примере они находятся в разных вершинах.
- Если матрица ограничений вполне унимодулярна (назначения, транспортная задача, потоки в сети), все вершины целые при любом целом b и достаточно обычного LP — это теорема Хоффмана — Крускала.
- Проверять определение перебором подматриц экспоненциально дорого; полиномиальный алгоритм существует, но сложен, поэтому на практике матрицу опознают по известным классам — прежде всего по матрице инцидентности двудольного графа.
- Любое побочное ограничение это свойство, как правило, разрушает.

Branch-and-bound и branch-and-cut

Контекст

Перебор всех целых точек невозможен: их экспоненциально много. Работающая идея — умный перебор, при котором большинство вариантов отбрасывается не глядя, потому что доказано, что ничего лучше уже найденного там нет. Доказательство даёт та самая LP-релаксация: её оптимум ограничивает сверху всё, что достижимо в поддереве.

Применение

Это ровно та схема, по которой работают все промышленные MILP-солверы. Понимать её нужно не чтобы написать свой солвер, а чтобы читать его лог: строчки про gap, nodes и cuts — это про разрыв между релаксацией и рекордом, про размер дерева и про добавленные отсечения. Заодно тем, кто знаком с классическими алгоритмами, здесь встретится знакомый перебор с отсечением.

Задача лонгрида

Разберём дерево ветвления на сквозном примере в пяти узлах, а затем построим отсечение, которое заменяет это дерево целиком.

Краткий план

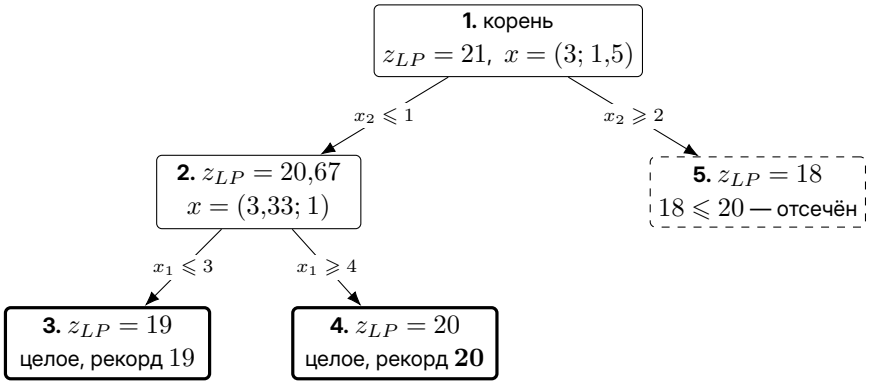
- Дерево ветвления
- Отсечения

1. ДЕРЕВО ВЕТВЛЕНИЯ

Метод **ветвей и границ** укладывается в три правила.

1. **Релаксация.** В каждом узле решаем LP без условия целочисленности. Его оптимум — верхняя оценка всего, что достижимо в этой ветке.
2. **Ветвление.** Если решение дробное, например $x_j = 1{,}5$, задача разбивается на две: $x_j \leqslant 1$ и $x_j \geqslant 2$. Ни одна целая точка не теряется, а дробная исключается из обеих веток.
3. **Отсечение по границе.** Если оценка в узле не лучше уже найденного целого решения (рекорда), ветку можно не смотреть.

Для сквозного примера всё дерево умещается в пять узлов; номер в углу — порядок обхода.



Пятый узел не исследован вообще: его оценка 18 хуже уже найденного рекорда 20, поэтому вся ветка отмирает целиком. В этом и состоит вся экономия метода — чем точнее оценки и чем раньше найден хороший рекорд, тем больше веток не придётся смотреть.

ЗАДАЧА 1

1. Построй дерево заново, ветвясь в корне по x_1, а не по x_2. Сколько узлов получится?
2. Что изменится, если обходить узлы в порядке убывания оценки вместо обхода в глубину? В каком случае это выгодно, а в каком нет?
3. Почему оценка в узле — именно верхняя граница? Где в рассуждении используется то, что мы добавляем ограничения, а не убираем?
4. Что произойдёт с методом, если ни одного целого решения долго не находится? Как в этом случае получить рекорд заранее?

ЗАДАЧА 2

Пусть в задаче n булевых переменных.

1. Сколько узлов содержит полный перебор? Сколько узлов в дереве ветвей и границ в худшем случае?
2. Оцени, при каком качестве оценок дерево перестаёт расти экспоненциально.
3. На рюкзаке из предыдущего раздела ($n = 16$) метод проходит 51 узел. Во сколько раз это меньше полного перебора?

2. ОТСЕЧЕНИЯ: ОТКУДА ОНИ БЕРУТСЯ

От дробного решения можно избавиться и без ветвления: достаточно добавить к задаче неравенство, которое отрезает дробную точку, но не отрезает ни одной целой. Такое неравенство называется **отсечением**. Строится оно из двух наблюдений.

Первое: комбинировать можно. Если $u \succeq 0$, то из $Ax \preceq b$ следует $u^\top A\,x \leqslant u^\top b$ — неотрицательная комбинация верных неравенств снова верна. Ничего нового мы пока не получили: это неравенство выполнено и для дробных точек тоже.

Второе: округлять вниз можно. Пусть $x \in \mathbb{Z}^n$, $x \succeq 0$. Заменим коэффициенты слева на их целые части: раз $\lfloor u^\top A \rfloor \preceq u^\top A$ и $x \succeq 0$, левая часть только уменьшится, поэтому

$$\lfloor u^\top A \rfloor\, x \;\leqslant\; u^\top A x \;\leqslant\; u^\top b.$$

Но теперь слева стоит *целое* число: коэффициенты целые и переменные целые. Целое число, не превосходящее $u^\top b$, не превосходит и $\lfloor u^\top b \rfloor$. Значит,

$$\boxed{\lfloor u^\top A \rfloor\, x \;\leqslant\; \lfloor u^\top b \rfloor}$$

для всех целых допустимых точек. Это **отсечение Гомори — Хватала**. Целые точки оно не трогает по построению — а дробные может отрезать, потому что для них последний шаг незаконен: дробному x никто не мешает дать слева дробное значение между $\lfloor u^\top b \rfloor$ и $u^\top b$.

Откуда берутся веса u. Их не угадывают — их подсказывает сам оптимум релаксации. Добавим переменные-остатки и запишем задачу как $Ax + s = b$. В оптимальной вершине часть переменных базисные, остальные небазисные и равны нулю; солвер как раз и хранит выражение базисных переменных через небазисные. Строка для базисной переменной x_i выглядит так:

$$x_i + \sum_{j \in N} \bar{a}_{ij}\, x_j = \bar{b}_i,$$

где N — номера небазисных переменных. Если $\bar{b}_i$ дробно, берём эту строку в качестве комбинации и округляем коэффициенты вниз:

$$x_i + \sum_{j \in N} \lfloor \bar{a}_{ij} \rfloor\, x_j \;\leqslant\; \lfloor \bar{b}_i \rfloor.$$

Вычитая это из исходного равенства, получаем отсечение в терминах дробных частей $f_{ij} = \bar{a}_{ij} - \lfloor \bar{a}_{ij} \rfloor$ и $f_i = \bar{b}_i - \lfloor \bar{b}_i \rfloor$:

$$\sum_{j \in N} f_{ij}\, x_j \;\geqslant\; f_i.$$

Вот почему оно *гарантированно* отрезает текущую вершину: в ней все небазисные x_j равны нулю, слева выходит 0, а справа $f_i > 0$. Никакой магии — строка дробной базисной переменной сама и есть нужная комбинация.

Проделаем это для сквозного примера. В оптимуме $(3;\,1{,}5)$ активны первые два ограничения, то есть их остатки s_1, s_2 и есть небазисные переменные. Выразив базисные x_1, x_2 через них из системы $6x_1 + 4x_2 = 24 - s_1$, $x_1 + 2x_2 = 6 - s_2$, получаем

$$x_1 = 3 - \tfrac{1}{4}s_1 + \tfrac{1}{2}s_2, \qquad x_2 = \tfrac{3}{2} + \tfrac{1}{8}s_1 - \tfrac{3}{4}s_2.$$

Дробна вторая строка; в канонической записи она имеет вид $x_2 - \frac{1}{8}s_1 + \frac{3}{4}s_2 = \frac{3}{2}$. Дробные части коэффициентов равны $\frac{7}{8}$ и $\frac{3}{4}$, дробная часть правой части — $\frac{1}{2}$, так что отсечение есть

$$\tfrac{7}{8}s_1 + \tfrac{3}{4}s_2 \geqslant \tfrac{1}{2}.$$

Осталось вернуться к исходным переменным, подставив $s_1 = 24 - 6x_1 - 4x_2$ и $s_2 = 6 - x_1 - 2x_2$:

$$6x_1 + 5x_2 \leqslant 25.$$

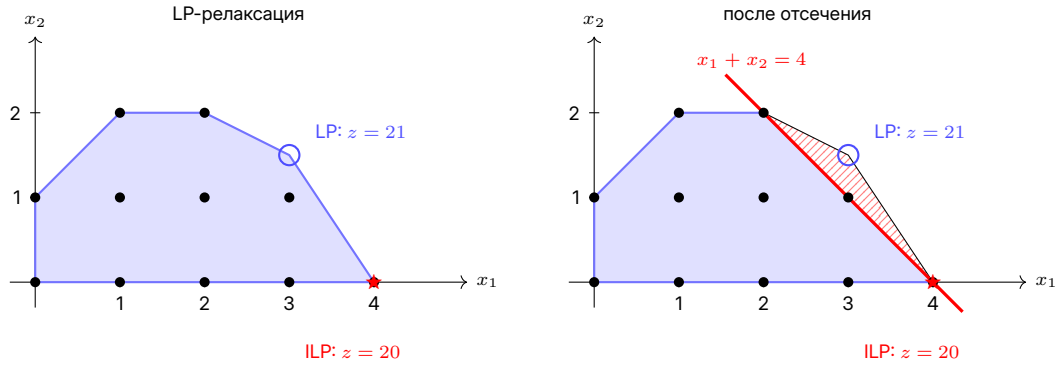
В дробной точке слева стоит $25{,}5$ — отсечение работает. Добавив его, получаем релаксацию со значением $20{,}67$ в точке $(10/3;\, 1)$: разрыв сократился с 21 до $20{,}67$, но целым решение ещё не стало, и понадобится следующий раунд.

ЗАМЕЧАНИЕ

Отсечения из одного семейства бывают разной силы. Веса $u = \left(\frac{1}{8}, \frac{1}{4}\right)$ дают $u^\top A = (1, 1)$ и $u^\top b = 4{,}5$, то есть

$$x_1 + x_2 \leqslant 4,$$

и это отсечение сильнее: оно срезает дробную вершину так, что новой вершиной сразу становится целая точка. Поиск сильных отсечений — отдельная большая тема; солверы перебирают несколько семейств и оставляют те, что реально подтягивают релаксацию.



Штриховкой отмечен кусок многогранника, который срезало отсечение. Вместе с ним исчезла дробная вершина $(3;\, 1{,}5)$, и новой вершиной стала целая точка $(4;\, 0)$ — тот самый оптимум ILP. Одно неравенство заменило дерево из пяти узлов.

ЗАМЕЧАНИЕ

Так везёт не всегда. Обычно отсечения лишь подтягивают релаксацию ближе к целочисленной оболочке $\operatorname{conv}\{x \in \mathbb{Z}^n : Ax \preceq b\}$, уменьшая разрыв, а остаток закрывается ветвлением. Схема «в каждом узле сначала добавляем отсечения, затем при необходимости ветвимся» и называется **branch-and-cut**; именно так устроены все современные MILP-солверы.

ЗАДАЧА 3

1. Проверь перебором, что все одиннадцать целых точек сквозного примера удовлетворяют неравенству $x_1 + x_2 \leqslant 4$.
2. Проверь, что отсечение из симплекс-таблицы $6x_1 + 5x_2 \leqslant 25$ тоже не задевает целых точек, и нарисуй его на том же рисунке. Какое из двух отсечений сильнее и в каком смысле?

3. Почему при округлении правой части вниз ни одна целая точка не теряется? Где в рассуждении используется целочисленность коэффициентов слева и неотрицательность переменных?
4. Почему отсечение $x_1 + x_2 \leqslant 4$ решило задачу без ветвления? Что для этого должно быть верно про новую вершину многогранника?
5. Что случится с ответом, если по ошибке добавить неравенство, отрезающее одну из целых точек? Как такую ошибку обнаружить?

3. ЕСЛИ КРАТКО

- Branch-and-bound: релаксация даёт оценку, дробная переменная даёт правило ветвления, рекорд даёт право не смотреть ветку.
- Эффективность метода целиком определяется качеством оценок и тем, как рано найден хороший рекорд; само дерево при этом может почти не строиться.
- Отсечение — неравенство, отрезающее дробный оптимум и не задевающее ни одной целой точки. Строится в два шага: неотрицательная комбинация ограничений плюс округление правой части вниз, законное потому, что слева стоит целое число.
- Веса комбинации не угадываются: строку берут из выражения дробной базисной переменной через небазисные. В текущей вершине небазисные равны нулю, поэтому такое отсечение всегда её отрезает.
- Branch-and-cut соединяет обе идеи и является стандартом в промышленных солверах; в сквозном примере одно отсечение заменило дерево из пяти узлов.