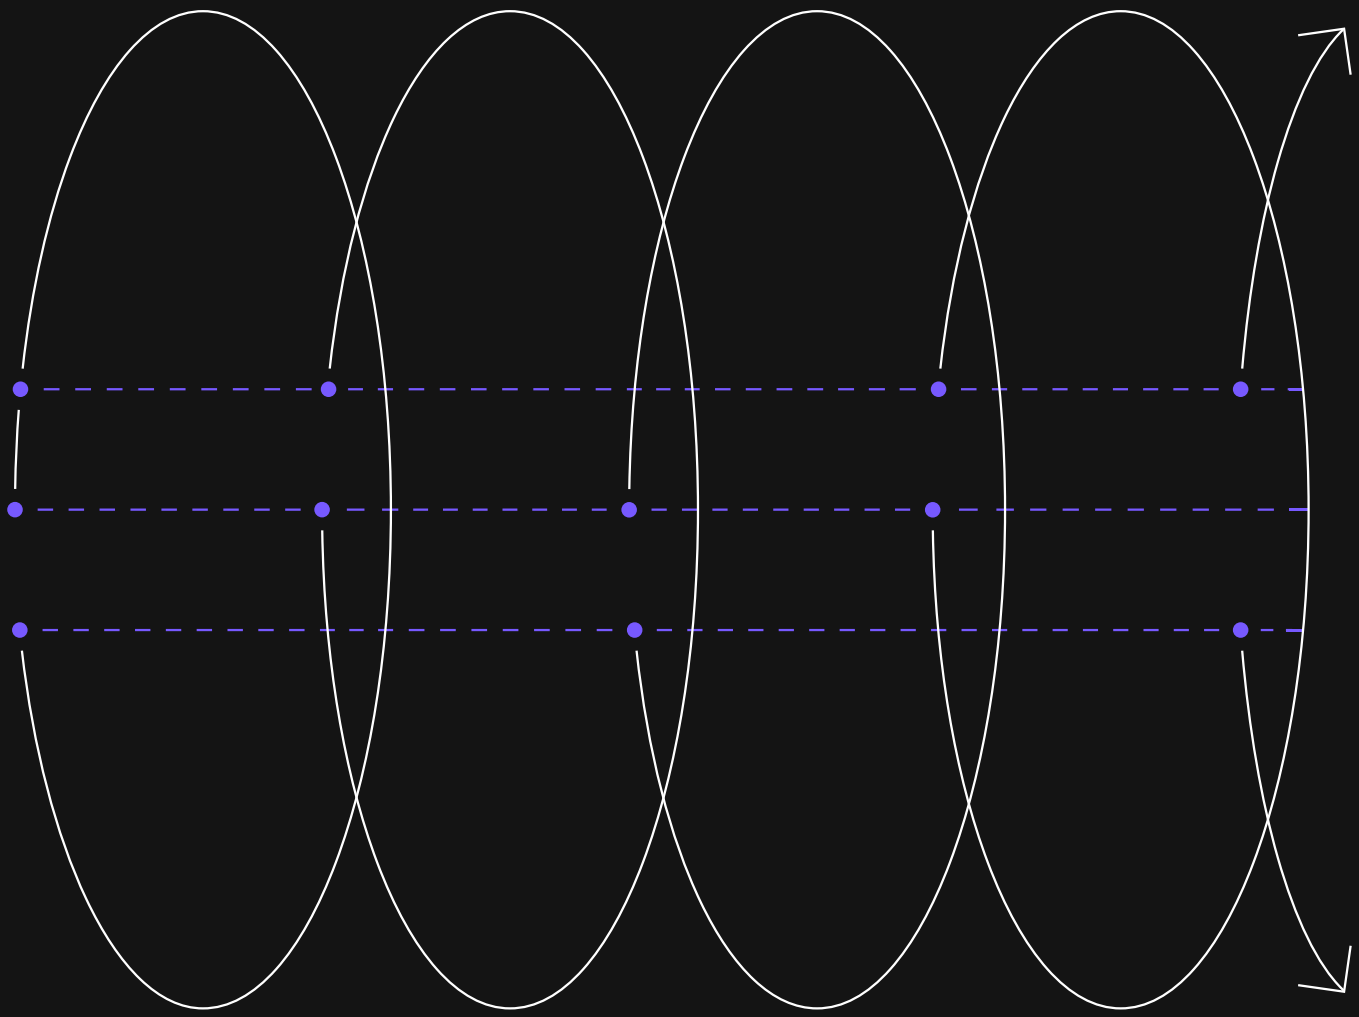
Машинное обучение | Лонгрид

Методы оптимизации | 07

Градиентный спуск и его сходимость



Градиентный спуск и скорость сходимости

Контекст

Анализ поведения градиентного спуска с постоянным шагом

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha f'(\mathbf{x}_k)$$

отвечает на три вопроса: при каком α значение f убывает, сколько итераций закладывать до допуска ε и что меняет ℓ_2-регуляризация. На слайдах сформулированы лемма о спуске и три теоремы о скорости. Доказательства теорем сходимости для выпуклой и сильно выпуклой функции в презентацию не вошли; здесь они собраны целиком.

Применение

Постоянный шаг $\alpha = 1/L$ можно поставить сразу, если L считается по гессиану: у квадратичной задачи, у наименьших квадратов и у логистической регрессии. Если известна ещё и сильная выпуклость, бюджет итераций пропорционален $\kappa \log(1/\varepsilon)$, а не $1/\varepsilon$. Штраф $\frac{\mu}{2}\|\boldsymbol{\theta}\|^2$ как раз добавляет эту сильную выпуклость.

Задача лонгрида

Доказать три теоремы с лекции при постоянном шаге $\alpha \in (0, 1/L]$ и прокомментировать ключевые результаты, представленные на лекции.

Краткий план

- L-гладкость, сильная выпуклость и константы типовых задач.
- Выпуклая скорость $1/T$ и её неулучшаемость для градиентного спуска.
- Линейная скорость при сильной выпуклости.
- Стационарная точка без выпуклости.

Базовая литература к доказательствам этой недели:

- Y. Nesterov, *Lectures on Convex Optimization*, Springer, 2018, §2.1;
- S. Bubeck, *Convex Optimization: Algorithms and Complexity*, 2015, §3, arXiv:1405.4980;
- H. Karimi, J. Nutini, M. Schmidt, *Linear convergence of gradient and proximal-gradient methods under the Polyak–Łojasiewicz condition*, ECML PKDD, 2016, arXiv:1608.04636.

Нижняя оценка порядка $T^{-1/2}$ для поиска стационарной точки: Y. Carmon, J. Duchi, O. Hinder, A. Sidford, *Lower bounds for finding stationary points I*, Mathematical Programming, 2020, arXiv:1710.11606.

Штрих обозначает градиент, как на лекции: $f'(\mathbf{x}) \in \mathbb{R}^n$. Норма евклидова. Пишем $f^* = \inf f$. Если минимум достигается, точка минимума обозначается $\mathbf{x}^*$. Выпуклость, сильная выпуклость и условие Поляка — Лоясиевича введены на неделе 4; ниже напоминается только то, что нужно для выкладок.

1. ТРИ МЕРЫ ОШИБКИ

Одна и та же итерация оценивается по-разному. Выбор величины зависит от того, что известно о f.

Величина	О чём говорит	Когда ею пользуемся
$f(\mathbf{x}_k) - f^*$	Зазор по значению	Выпуклые задачи
$\|\mathbf{x}_k - \mathbf{x}^*\|$	Зазор по аргументу	Есть единственный $\mathbf{x}^*$
$\|f'(\mathbf{x}_k)\|$	Близость к стационарности	Выпуклости нет

ЗАМЕЧАНИЕ

Первые две величины требуют знания минимума. Норма градиента считается в текущей точке и минимума не использует. Выпуклость как раз переводит малость градиента в малость зазора $f - f^*$: это содержание двух теорем ниже.

2. L-ГЛАДКОСТЬ

ОПРЕДЕЛЕНИЕ 1

Функция f **L-гладкая** ($L > 0$), если она дифференцируема и градиент липшицев:

$$\|f'(\mathbf{x}) - f'(\mathbf{y})\| \leqslant L\|\mathbf{x} - \mathbf{y}\| \qquad \forall\, \mathbf{x},\mathbf{y}.$$

Константа L одна на всё пространство.

ТЕОРЕМА 1

Пусть f дважды непрерывно дифференцируема. Тогда f L-гладкая если и только если $\|f''(\mathbf{x})\| \leqslant L$ при всех $\mathbf{x}$: все собственные значения гессиана лежат в $[-L,L]$. Если f ещё и выпукла, отрицательных собственных значений нет, и $0 \preceq f''(\mathbf{x}) \preceq L\mathbf{I}$.

ДОКАЗАТЕЛЬСТВО

Пусть $\|f''(\mathbf{z})\| \leqslant L$ всюду. По формуле Ньютона — Лейбница

$$f'(\mathbf{y}) - f'(\mathbf{x}) = \int_0^1 f''(\mathbf{x}_t)(\mathbf{y} - \mathbf{x})\,dt, \qquad \mathbf{x}_t = \mathbf{x} + t(\mathbf{y} - \mathbf{x}).$$

Норма интеграла не превосходит $\int_0^1 L\|\mathbf{y} - \mathbf{x}\|\,dt = L\|\mathbf{y} - \mathbf{x}\|$.

Обратно, пусть градиент L-липшицев. Для любого направления $\mathbf{v}$

$$\|f''(\mathbf{x})\mathbf{v}\| = \lim_{t\to 0} \frac{\|f'(\mathbf{x} + t\mathbf{v}) - f'(\mathbf{x})\|}{|t|} \leqslant L\|\mathbf{v}\|,$$

так что операторная норма гессиана не больше L.

Если f выпукла и дважды дифференцируема, вторая производная вдоль любой прямой неотрицательна: при фиксированных $\mathbf{x}$ и $\mathbf{v}$ функция $t \mapsto f(\mathbf{x} + t\mathbf{v})$ выпукла, поэтому её вторая производная $\mathbf{v}^\top f''(\mathbf{x})\mathbf{v} \geqslant 0$. Значит, $f''(\mathbf{x}) \succeq 0$, и вместе с верхней границей $0 \preceq f''(\mathbf{x}) \preceq L\mathbf{I}$.

ОПРЕДЕЛЕНИЕ 2

Дифференцируемая f **μ-сильно выпукла** ($\mu > 0$), если для всех $\mathbf{x},\mathbf{y}$

$$f(\mathbf{y}) \geqslant f(\mathbf{x}) + \langle f'(\mathbf{x}),\mathbf{y} - \mathbf{x}\rangle + \tfrac{\mu}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

Для $f \in C^2$ это то же самое, что $f''(\mathbf{x}) \succeq \mu\mathbf{I}$: эквивалентность доказана в лонгриде недели 4. **Число обусловленности** такой функции — $\kappa = L/\mu$.

Откуда брать L и μ

ТЕОРЕМА 2

1. У $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top\mathbf{A}\mathbf{x}$ с симметричной $\mathbf{A}$ гессиан равен $\mathbf{A}$, и $L = \lambda_{\max}(\mathbf{A})$, если это число положительно.
2. У $f(\boldsymbol{\theta}) = \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|^2$ гессиан равен $2\mathbf{X}^\top\mathbf{X}$, и $L = 2\lambda_{\max}(\mathbf{X}^\top\mathbf{X})$.

3. У $f(\boldsymbol{\theta}) = \sum_{i=1}^{m} \log\bigl(1 + e^{-y_i \mathbf{x}_i^\top \boldsymbol{\theta}}\bigr)$, $y_i \in \{\pm 1\}$, гессиан равен $\mathbf{X}^\top \mathbf{D}(\boldsymbol{\theta}) \mathbf{X}$ с $0 < D_{ii} \leqslant \frac{1}{4}$, и
$$L = \tfrac{1}{4} \lambda_{\max}(\mathbf{X}^\top \mathbf{X}).$$

Во всех трёх задачах f выпукла. Добавка $\frac{\mu}{2}\|\boldsymbol{\theta}\|^2$ сдвигает каждое собственное значение гессиана на μ: новая пара констант — $(L + \mu, \mu_{\text{old}} + \mu)$.

ДОКАЗАТЕЛЬСТВО

Первые два гессиана получаются дифференцированием. У квадратичной формы с симметричной матрицей градиент равен $\mathbf{A}\mathbf{x}$, гессиан — $\mathbf{A}$. У наименьших квадратов градиент равен $2\mathbf{X}^\top(\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$, гессиан — $2\mathbf{X}^\top\mathbf{X} \succeq 0$.

Для логистического слагаемого положим $z = y\mathbf{x}^\top\boldsymbol{\theta}$ и $\ell(z) = \log\bigl(1 + e^{-z}\bigr)$. Тогда $\ell'(z) = -\sigma(-z)$ и $\ell''(z) = \sigma(z)\bigl(1 - \sigma(z)\bigr)$, где $\sigma(z) = (1 + e^{-z})^{-1}$. Произведение $\sigma(1 - \sigma)$ на $(0,1)$ не превосходит $\frac{1}{4}$: максимум квадратичной функции $t(1 - t)$ на $[0,1]$ равен $\frac{1}{4}$. Вторая производная по $\boldsymbol{\theta}$ равна $\ell''(z)\,\mathbf{x}\mathbf{x}^\top$, потому что $y^2 = 1$. Сумма по объектам даёт $\mathbf{X}^\top\mathbf{D}\mathbf{X}$ с $D_{ii} = \ell''(z_i) \leqslant \frac{1}{4}$. Для любого $\mathbf{v}$

$$\mathbf{v}^\top\mathbf{X}^\top\mathbf{D}\mathbf{X}\mathbf{v} \;=\; \sum_i D_{ii}(\mathbf{x}_i^\top\mathbf{v})^2 \;\leqslant\; \tfrac{1}{4}\|\mathbf{X}\mathbf{v}\|^2 \;\leqslant\; \tfrac{1}{4}\lambda_{\max}(\mathbf{X}^\top\mathbf{X})\,\|\mathbf{v}\|^2.$$

Матрица $\mathbf{D}$ диагональна с положительными элементами, поэтому гессиан положительно полуопределён и f выпукла. Сильной выпуклости при этом может не быть даже при полном столбцовом ранге $\mathbf{X}$: при $\|\boldsymbol{\theta}\| \to \infty$ величины D_{ii} стремятся к нулю вдоль луча, и равномерной нижней границы $\mu > 0$ нет.

Гессиан функции $\frac{\mu}{2}\|\boldsymbol{\theta}\|^2$ равен $\mu\mathbf{I}$. Он прибавляется к гессиану f, и каждое собственное значение увеличивается на μ. Верхняя граница L становится $L + \mu$, нижняя μ_{old} становится $\mu_{\text{old}} + \mu$.

ЗАМЕЧАНИЕ

На графиках недели 4 больший коэффициент регуляризации давал более крутой линейный спад. Множитель градиентного спуска с шагом $1/(L + \mu)$ равен $1 - \mu/(L + \mu)$, если исходная функция была выпукла и L-гладка, но не сильно выпукла. Чем больше μ относительно L, тем дальше этот множитель от единицы.

ЛЕММА 1

Пусть f L-гладкая и $\mathbf{x}_+ = \mathbf{x} - \alpha f'(\mathbf{x})$ при $\alpha > 0$. Тогда

$$f(\mathbf{x}_+) \;\leqslant\; f(\mathbf{x}) - \alpha\Bigl(1 - \frac{\alpha L}{2}\Bigr)\|f'(\mathbf{x})\|^2.$$

При $0 < \alpha \leqslant 1/L$ множитель в скобках не меньше $\frac{1}{2}$, поэтому

$$f(\mathbf{x}_+) \;\leqslant\; f(\mathbf{x}) - \frac{\alpha}{2}\|f'(\mathbf{x})\|^2.$$

Пока градиент ненулевой, значение строго убывает. При $\alpha > 2/L$ коэффициент $1 - \alpha L/2$ отрицателен, и эта верхняя оценка убывания уже не даёт.

ДОКАЗАТЕЛЬСТВО

Подставим в лемму о спуске $\mathbf{y} = \mathbf{x} - \alpha f'(\mathbf{x})$:

$$\begin{aligned} f(\mathbf{x}_+) &\leqslant f(\mathbf{x}) + \langle f'(\mathbf{x}),\, -\alpha f'(\mathbf{x})\rangle + \tfrac{L}{2}\alpha^2 \|f'(\mathbf{x})\|^2 \\ &= f(\mathbf{x}) - \alpha\Bigl(1 - \frac{\alpha L}{2}\Bigr)\|f'(\mathbf{x})\|^2. \end{aligned}$$

На отрезке $\alpha \in (0,1/L]$ выполнено $\alpha L/2 \leqslant \tfrac{1}{2}$, поэтому $1 - \alpha L/2 \geqslant \tfrac{1}{2}$. Вычитаемое тогда не меньше $\tfrac{\alpha}{2}\|f'(\mathbf{x})\|^2$.

ЗАМЕЧАНИЕ

Коэффициент убыли $\varphi(\alpha) = \alpha(1 - \alpha L/2)$ на $(0,2/L)$ положителен и максимален при $\alpha = 1/L$, где $\varphi(1/L) = 1/(2L)$. Среди шагов, для которых теоремы ниже написаны, то есть среди $\alpha \in (0,1/L]$, и гарантия $\tfrac{\alpha}{2}\|f'\|^2$, и точный коэффициент $\varphi(\alpha)$ наибольшие при $\alpha = 1/L$. Квадратичная верхняя оценка как функция $\mathbf{y}$ имеет вершину ровно в точке $\mathbf{x} - \tfrac{1}{L}f'(\mathbf{x})$: это градиентный шаг с $\alpha = 1/L$. Для произвольного $\alpha > 0$ та же модель с кривизной $1/\alpha$ допустима леммой при $1/\alpha \geqslant L$.

ЛЕММА 2

Если f одновременно L-гладкая и μ-сильно выпуклая, то $\mu \leqslant L$. Множитель $1 - \mu/L$ неотрицателен.

ДОКАЗАТЕЛЬСТВО

Нижняя оценка из сильной выпуклости и верхняя оценка из леммы о спуске дают

$$\tfrac{\mu}{2}\|\mathbf{y} - \mathbf{x}\|^2 \leqslant f(\mathbf{y}) - f(\mathbf{x}) - \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x}\rangle \leqslant \tfrac{L}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

При $\mathbf{y} \neq \mathbf{x}$ отсюда $\mu \leqslant L$.

3. ВЫПУКЛАЯ L-ГЛАДКАЯ ФУНКЦИЯ

ТЕОРЕМА 3

Пусть f выпукла и L-гладкая, минимум достигается в $\mathbf{x}^*$, и $\alpha \in (0,1/L]$. После $T \geqslant 1$ шагов градиентного спуска

$$f(\mathbf{x}_T) - f^* \leqslant \frac{\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2\alpha T}.$$

При $\alpha = 1/L$ правая часть равна $L\|\mathbf{x}_0 - \mathbf{x}^*\|^2/(2T)$.

ДОКАЗАТЕЛЬСТВО

Обозначим $\mathbf{g}_k = f'(\mathbf{x}_k)$ и $R_k = \|\mathbf{x}_k - \mathbf{x}^*\|$. Следствие леммы о спуске при $\alpha \in (0,1/L]$ даёт

$$f(\mathbf{x}_{k+1}) \leqslant f(\mathbf{x}_k) - \frac{\alpha}{2}\|\mathbf{g}_k\|^2. \tag{1}$$

Последовательность $f(\mathbf{x}_k)$ убывает.

Выпуклость в форме касательной в точке $\mathbf{x}_k$, применённая к минимуму $\mathbf{x}^*$:

$$f(\mathbf{x}_k) - f^* \leqslant \langle \mathbf{g}_k, \mathbf{x}_k - \mathbf{x}^*\rangle. \tag{2}$$

Это единственное место доказательства, где нужна выпуклость.

Подставляем шаг $\mathbf{x}_{k+1} - \mathbf{x}^* = (\mathbf{x}_k - \mathbf{x}^*) - \alpha \mathbf{g}_k$:

$$R_{k+1}^2 \;=\; R_k^2 - 2\alpha \langle \mathbf{g}_k, \mathbf{x}_k - \mathbf{x}^* \rangle + \alpha^2 \|\mathbf{g}_k\|^2.$$

Оценка (2) заменяет скалярное произведение зазором по значению:

$$R_{k+1}^2 \;\leqslant\; R_k^2 - 2\alpha \big(f(\mathbf{x}_k) - f^*\big) + \alpha^2 \|\mathbf{g}_k\|^2.$$

Из (1) следует $\alpha \|\mathbf{g}_k\|^2 \leqslant 2\big(f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})\big)$, поэтому

$$\alpha^2 \|\mathbf{g}_k\|^2 \;\leqslant\; 2\alpha \big(f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})\big).$$

Подстановка этого слагаемого даёт

$$\begin{aligned} R_{k+1}^2 &\;\leqslant\; R_k^2 - 2\alpha \big(f(\mathbf{x}_k) - f^*\big) + 2\alpha \big(f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})\big) \\ &\;=\; R_k^2 - 2\alpha \big(f(\mathbf{x}_{k+1}) - f^*\big). \end{aligned}$$

Отсюда расстояние до минимума не растёт, и

$$f(\mathbf{x}_{k+1}) - f^* \;\leqslant\; \frac{1}{2\alpha}\big(R_k^2 - R_{k+1}^2\big).$$

Сумма по $k = 0, \dots, T-1$ справа схлопывается в $R_0^2/(2\alpha)$. Слева стоят зазоры $f(\mathbf{x}_1) - f^*, \dots, f(\mathbf{x}_T) - f^*$. Из (1) значения убывают, поэтому каждое из них не меньше $f(\mathbf{x}_T) - f^*$:

$$T\big(f(\mathbf{x}_T) - f^*\big) \;\leqslant\; \frac{\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2\alpha}.$$

СЛЕДСТВИЕ

В условиях теоремы допуск $f(\mathbf{x}_T) - f^* \leqslant \varepsilon$ достигается при

$$T \;\geqslant\; \frac{\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2\alpha\varepsilon}.$$

При $\alpha = 1/L$, $L = 10$, $R = \|\mathbf{x}_0 - \mathbf{x}^*\| = 1$ и $\varepsilon = 10^{-4}$ это $T \geqslant 5 \cdot 10^4$. Уменьшение шага увеличивает бюджет: в знаменателе стоит α.

ДОКАЗАТЕЛЬСТВО

Неравенство теоремы не превосходит ε, как только $R^2/(2\alpha T) \leqslant \varepsilon$. Подстановка $\alpha = 1/L$ даёт $T \geqslant LR^2/(2\varepsilon) = 10/(2 \cdot 10^{-4}) = 5 \cdot 10^4$.

ТЕОРЕМА 4

Порядок $1/T$ для градиентного спуска на классе выпуклых L-гладких функций неулучшаем. Точнее: для любых $L > 0$, $R > 0$ и целого $T \geqslant 1$ найдутся выпуклая L-гладкая f и старт с $\|\mathbf{x}_0 - \mathbf{x}^*\| = R$, такие что градиентный спуск с шагом $\alpha = 1/L$ удовлетворяет

$$f(\mathbf{x}_T) - f^* \;\geqslant\; \frac{LR^2}{4e^2 T}.$$

ДОКАЗАТЕЛЬСТВО

Возьмём $f(x) = \frac{a}{2}x^2$ на $\mathbb{R}$ с $a = L/(2T)$ и старт $x_0 = R$. Тогда $x^* = 0$, $f^* = 0$ и $\|x_0 - x^*\| = R$. Гессиан равен $a \leqslant L$, так что f выпукла и L-гладка. Шаг $\alpha = 1/L$

умножает координату на $1 - a/L = 1 - 1/(2T)$:

$$x_T \;=\; \Bigl(1 - \frac{1}{2T}\Bigr)^{T} R, \qquad f(x_T) \;=\; \frac{a}{2} x_T^2 \;=\; \frac{LR^2}{4T}\Bigl(1 - \frac{1}{2T}\Bigr)^{2T}.$$

Остаётся нижняя граница $(1 - 1/n)^n$ при $n = 2T \geqslant 2$. При $u \in (0,1)$ функция $\psi(u) = \ln(1-u) + u/(1-u)$ имеет $\psi(0) = 0$ и $\psi'(u) = u/(1-u)^2 \geqslant 0$, поэтому $\ln(1-u) \geqslant -u/(1-u)$. При $u = 1/n$

$$n \ln\Bigl(1 - \frac{1}{n}\Bigr) \;\geqslant\; -\frac{n}{n-1} \;\geqslant\; -2,$$

и $(1 - 1/n)^n \geqslant e^{-2}$. Следовательно, $f(x_T) \geqslant LR^2/(4e^2 T)$.

ЗАМЕЧАНИЕ

Функция в примере зависит от T: её собственное значение $L/(2T)$ тем меньше, чем длиннее горизонт. Смысл оценки именно такой. Верхняя граница теоремы одна на весь класс, и для каждого T в классе есть функция, на которой градиентный спуск после T шагов всё ещё оставляет зазор порядка LR^2/T. Заменить $1/T$ на $1/T^2$ сразу для всех выпуклых L-гладких функций нельзя.

Для произвольного метода первого порядка нижняя оценка на том же классе — уже порядка $1/T^2$, и её достигает ускоренный метод. Это теорема Нестерова; доказательство устроено как сопротивляющийся оракул в растущей размерности и относится к следующей лекции. Ссылки: Nesterov, *Lectures on Convex Optimization*, 2018, §2.1; Bubeck, *Convex Optimization: Algorithms and Complexity*, 2015, §3.

4. L-ГЛАДКАЯ μ-СИЛЬНО ВЫПУКЛАЯ ФУНКЦИЯ

ЛЕММА 3

Если f дифференцируема и μ-сильно выпукла, то $f^* > -\infty$ и выполнено условие Поляка — Лоясиевича с той же константой:

$$\|f'(\mathbf{x})\|^2 \;\geqslant\; 2\mu\bigl(f(\mathbf{x}) - f^*\bigr) \qquad \forall\, \mathbf{x}.$$

Минимум достигается в единственной точке.

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость:

$$f(\mathbf{y}) \;\geqslant\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x}\rangle + \tfrac{\mu}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

Правая часть как функция $\mathbf{y}$ — парабола. Её вершина лежит в $\mathbf{y} = \mathbf{x} - \frac{1}{\mu} f'(\mathbf{x})$, и значение в вершине равно $f(\mathbf{x}) - \frac{1}{2\mu}\|f'(\mathbf{x})\|^2$. Значит,

$$f(\mathbf{y}) \;\geqslant\; f(\mathbf{x}) - \tfrac{1}{2\mu}\|f'(\mathbf{x})\|^2$$

при всех $\mathbf{y}$, откуда $f^* > -\infty$ и

$$f^* \;\geqslant\; f(\mathbf{x}) - \tfrac{1}{2\mu}\|f'(\mathbf{x})\|^2.$$

Это и есть условие Поляка — Лоясиевича.

Правая часть сильной выпуклости при фиксированном $\mathbf{x}$ уходит в $+\infty$ вместе с $\|\mathbf{y}\|$. Множество уровня функции f ограничено и замкнуто, и непрерывная f достигает на нём минимума $\mathbf{x}^*$. В этой точке градиент равен нулю: иначе шаг $\mathbf{x}^* - tf'(\mathbf{x}^*)$ при малом $t > 0$ уменьшает f, потому что производная по t в нуле равна $-\|f'(\mathbf{x}^*)\|^2 < 0$. Подстановка $\mathbf{x} = \mathbf{x}^*$ и $f'(\mathbf{x}^*) = \mathbf{0}$ в сильную выпуклость даёт $f(\mathbf{y}) \geqslant f(\mathbf{x}^*) + \frac{\mu}{2}\|\mathbf{y} - \mathbf{x}^*\|^2$. Два разных минимума этой оценке противоречат.

ЗАМЕЧАНИЕ

Для скорости по значению хватает условия Поляка — Лоясиевича. Единственность $\mathbf{x}^*$ в выкладке следующей теоремы не используется. Обратный переход от этого условия к сильной выпуклости ложен: пример недели 4 невыпуклый.

ТЕОРЕМА 5

Пусть f L-гладкая и μ-сильно выпуклая, $\alpha \in (0,1/L]$. Тогда

$$f(\mathbf{x}_T) - f^* \;\leqslant\; (1 - \alpha\mu)^T \big(f(\mathbf{x}_0) - f^*\big).$$

При $\alpha = 1/L$ множитель равен $1 - \mu/L = 1 - 1/\kappa$.

ДОКАЗАТЕЛЬСТВО

При $\alpha \in (0,1/L]$

$$f(\mathbf{x}_{k+1}) \;\leqslant\; f(\mathbf{x}_k) - \frac{\alpha}{2}\|f'(\mathbf{x}_k)\|^2.$$

Условие Поляка — Лоясиевича заменяет квадрат нормы градиента:

$$f(\mathbf{x}_{k+1}) \;\leqslant\; f(\mathbf{x}_k) - \alpha\mu\big(f(\mathbf{x}_k) - f^*\big).$$

Вычитаем f^*:

$$f(\mathbf{x}_{k+1}) - f^* \;\leqslant\; (1 - \alpha\mu)\big(f(\mathbf{x}_k) - f^*\big).$$

Множитель неотрицателен, потому что $\alpha\mu \leqslant \mu/L \leqslant 1$. Индукция по k даёт $(1 - \alpha\mu)^T$.

СЛЕДСТВИЕ

Допуск $f(\mathbf{x}_T) - f^* \leqslant \varepsilon$ достигается при

$$T \;\geqslant\; \frac{1}{\alpha\mu} \ln \frac{f(\mathbf{x}_0) - f^*}{\varepsilon}.$$

При $\alpha = 1/L$ это $T \geqslant \kappa \ln(\Delta_0/\varepsilon)$, где $\Delta_0 = f(\mathbf{x}_0) - f^*$. Для $L = 10$, $\mu = 1$, $R = 1$ и $\varepsilon = 10^{-4}$ оценка $\Delta_0 \leqslant LR^2/2 = 5$ даёт $T \geqslant 10 \ln\big(5 \cdot 10^4\big) \approx 108$. Каждые следующие два знака точности стоят ещё порядка κ итераций.

ДОКАЗАТЕЛЬСТВО

Из $(1 - \alpha\mu)^T \Delta_0 \leqslant \varepsilon$ и неравенства $-\ln(1 - u) \geqslant u$ при $u = \alpha\mu \in (0,1]$ следует достаточное условие $T \geqslant \ln(\Delta_0/\varepsilon)/(\alpha\mu)$. При $\alpha = 1/L$ получаем множитель κ. Лемма о спуске в точке минимума, где градиент равен нулю, даёт $f(\mathbf{x}_0) \leqslant f^* + \frac{L}{2}R^2$, то есть $\Delta_0 \leqslant LR^2/2$. Численно $\ln(50000) \approx 10{,}82$, и $10 \cdot 10{,}82 = 108{,}2$. Переход от ε к $\varepsilon/100$ добавляет $\kappa \ln 100 \approx 4.6\,\kappa$ итераций.

СЛЕДСТВИЕ

В условиях теоремы при $\alpha = 1/L$

$$\tfrac{\mu}{2}\|\mathbf{x}_T - \mathbf{x}^*\|^2 \;\leqslant\; f(\mathbf{x}_T) - f^* \;\leqslant\; \Big(1 - \frac{1}{\kappa}\Big)^T \frac{L}{2}\|\mathbf{x}_0 - \mathbf{x}^*\|^2.$$

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость в точке $\mathbf{x}^*$, где $f'(\mathbf{x}^*) = \mathbf{0}$, даёт левое неравенство. Лемма о спуске в той же точке даёт $f(\mathbf{x}) \leqslant f^* + \frac{L}{2}\|\mathbf{x} - \mathbf{x}^*\|^2$. При $\mathbf{x} = \mathbf{x}_0$ это ограничивает Δ_0. Правая часть получается подстановкой этой границы и множителя $1 - 1/\kappa$ в теорему о линейной скорости.

5. БЕЗ ВЫПУКЛОСТИ

ТЕОРЕМА 6

Пусть f L-гладкая и $f^* > -\infty$. Выпуклость не предполагается. При $\alpha \in (0, 1/L]$

$$\min_{0 \leqslant k < T} \|f'(\mathbf{x}_k)\|^2 \;\leqslant\; \frac{2\bigl(f(\mathbf{x}_0) - f^*\bigr)}{\alpha T}.$$

При $\alpha = 1/L$

$$\min_{0 \leqslant k < T} \|f'(\mathbf{x}_k)\| \;\leqslant\; \sqrt{\frac{2L\bigl(f(\mathbf{x}_0) - f^*\bigr)}{T}}.$$

ДОКАЗАТЕЛЬСТВО

Следствие леммы о спуске:

$$f(\mathbf{x}_{k+1}) \;\leqslant\; f(\mathbf{x}_k) - \frac{\alpha}{2}\|f'(\mathbf{x}_k)\|^2.$$

Суммируем $k = 0, \ldots, T - 1$:

$$\frac{\alpha}{2}\sum_{k=0}^{T-1} \|f'(\mathbf{x}_k)\|^2 \;\leqslant\; f(\mathbf{x}_0) - f(\mathbf{x}_T) \;\leqslant\; f(\mathbf{x}_0) - f^*,$$

где второе неравенство — это $f(\mathbf{x}_T) \geqslant f^*$. Минимум не больше среднего:

$$\min_{0 \leqslant k < T} \|f'(\mathbf{x}_k)\|^2 \;\leqslant\; \frac{1}{T}\sum_{k=0}^{T-1} \|f'(\mathbf{x}_k)\|^2 \;\leqslant\; \frac{2\bigl(f(\mathbf{x}_0) - f^*\bigr)}{\alpha T}.$$

При $\alpha = 1/L$ извлекаем квадратный корень. Выпуклость не использовалась. Нижняя граница f^* нужна, чтобы сумма убыли была конечной.

СЛЕДСТВИЕ

Чтобы на траектории нашлась точка с $\|f'(\mathbf{x}_k)\| \leqslant \varepsilon$ при шаге $\alpha = 1/L$, достаточно

$$T \;\geqslant\; \frac{2L\bigl(f(\mathbf{x}_0) - f^*\bigr)}{\varepsilon^2}.$$

Уменьшение допуска по градиенту в 10 раз увеличивает бюджет в 100 раз. При $L = 10$, $f(\mathbf{x}_0) - f^* = 1$ и $\varepsilon = 10^{-2}$ получается $T \geqslant 2 \cdot 10^5$. Если известна только нижняя оценка $f_{\mathrm{lb}} \leqslant f^*$, в правой части теоремы можно поставить $f(\mathbf{x}_0) - f_{\mathrm{lb}}$: сумма убыли по-прежнему не превосходит этого числа.

ДОКАЗАТЕЛЬСТВО

Квадрат нормы в теореме не превосходит ε^2, как только $2L\Delta_0/T \leqslant \varepsilon^2$. Подстановка чисел даёт $T \geqslant 2 \cdot 10 \cdot 1/10^{-4} = 2 \cdot 10^5$. Замена f^* на меньшее число увеличивает правую часть и сохраняет неравенство.

ЗАМЕЧАНИЕ

Оценка стоит на лучшей точке траектории, а не на последней. Нормы градиента по k убывать не обязаны. По зазору $f(\mathbf{x}_T) - f^*$ теорема ничего не говорит: предел значений может быть локальным минимумом или седлом и лежать строго выше f^*. Порядок $T^{-1/2}$ по норме градиента на классе L-гладких функций, ограниченных снизу, неулучшаем для методов первого порядка. Доказательство этой нижней оценки — конструкция Carmon, Duchi, Hinder, Sidford (2020).

ПРИМЕР 1

Условие $f^* > -\infty$ существенно. У $f(x) = -x$ градиент постоянен, значит липшицев с любой константой L, но $f^* = -\infty$. Шаг $\alpha > 0$ даёт $x_{k+1} = x_k + \alpha$, значение уходит в $-\infty$, а $\|f'(x_k)\| = 1$ при всех k. Малой нормы градиента на траектории нет.

6. ТРИ РЕЖИМА И ВЫБОР ШАГА

Пусть $\Delta_0 = f(\mathbf{x}_0) - f^*$, $R = \|\mathbf{x}_0 - \mathbf{x}^*\|$, шаг $\alpha = 1/L$ и $\kappа = L/\mu$. Во всех трёх строках f L-гладкая, и доказательство начинается с одной и той же убыли $\frac{1}{2L}\|f'(\mathbf{x}_k)\|^2$ за шаг.

	Выпуклая	Сильно выпуклая	Без выпуклости
Дополнительно	Выпуклость, есть $\mathbf{x}^*$	μ-сильная выпуклость	$f^* > -\infty$
Гарантия	$f(\mathbf{x}_T) - f^*$	$f(\mathbf{x}_T) - f^*$	$\min_{k<T}\|f'\|$
Оценка	$\dfrac{LR^2}{2T}$	$\bigl(1 - 1/\kappа\bigr)^T \Delta_0$	$\sqrt{2L\Delta_0/T}$
Итераций до ε	$\dfrac{LR^2}{2\varepsilon}$	$\kappа \ln(\Delta_0/\varepsilon)$	$\dfrac{2L\Delta_0}{\varepsilon^2}$

ЗАМЕЧАНИЕ

Теоремы написаны для постоянного $\alpha \in (0, 1/L]$, и константа лучше всего при $\alpha = 1/L$. Если L известно, этот шаг ставится сразу. Если L неизвестно, бэктрекинг по условию Армихо подбирает шаг, для которого $f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geqslant c\|f'(\mathbf{x}_k)\|^2$ с некоторой $c > 0$. Порядки $1/T$, $(1 - c'\mu)^T$ и $T^{-1/2}$ при таком поиске сохраняются: в доказательствах используется именно эта убыль, а не конкретное значение $\alpha = 1/L$. Шаг меньше $1/L$ сходимости не ломает. В выпуклой оценке в знаменателе стоит α, в сильно выпуклой множитель равен $1 - \alpha\mu$, в невыпуклой в знаменателе снова стоит α. Во всех трёх формулах меньший шаг увеличивает число итераций.

ℓ_2-регуляризация переводит задачу из первой строки таблицы во вторую. Для логистического риска без штрафа сильной выпуклости нет, и теорема даёт $O(1/T)$, если минимум достигается. После добавки $\frac{\mu}{2}\|\boldsymbol{\theta}\|^2$ пара констант становится $(L + \mu, \mu)$, и зазор умножается на $1 - \mu/(L + \mu)$. Решается уже другая задача: точка минимума сдвигается.

7. ЕСЛИ КРАТКО

- L-гладкость — липшицев градиент. Для $f \in C^2$ это оценка $|\lambda(f'')| \leqslant L$. У выпуклой C^2-функции собственные значения лежат в $[0, L]$.
- Шаг $\alpha \leqslant 1/L$ уменьшает f хотя бы на $\frac{\alpha}{2}\|f'\|^2$. Шаг $1/L$ минимизирует верхнюю параболу и даёт лучшую константу в трёх теоремах.

- Выпуклая L-гладкая функция с достигнутым минимумом: $f(\mathbf{x}_T) - f^* \leqslant LR^2/(2T)$. Для градиентного спуска порядок $1/T$ на этом классе неулучшаем. Для методов первого порядка нижняя оценка — $1/T^2$.
- μ-сильная выпуклость даёт условие Поляка — Лоясиевича и множитель $1 - \mu/L$ за шаг. Число итераций пропорционально $\kappa \ln(1/\varepsilon)$. На квадратичной функции порог сходимости постоянного шага — $\alpha < 2/L$, а лучший шаг — $2/(L + \mu)$.
- Без выпуклости контролируется лучшая норма градиента на траектории, порядок $T^{-1/2}$. Нужна конечная нижняя граница f^*. Малый градиент бывает и у седла.

Что почитать

- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.1. Лемма о спуске, скорость $1/T$, линейная скорость, нижняя оценка $1/T^2$.
- S. Bubeck. *Convex Optimization: Algorithms and Complexity*. Foundations and Trends in Machine Learning, 2015, §3. arXiv:1405.4980.
- H. Karimi, J. Nutini, M. Schmidt. *Linear Convergence of Gradient and Proximal-Gradient Methods under the Polyak–Łojasiewicz Condition*. ECML PKDD, 2016. arXiv:1608.04636.
- Y. Carmon, J. Duchi, O. Hinder, A. Sidford. *Lower bounds for finding stationary points I*. Mathematical Programming, 184, 2020. arXiv:1710.11606.
- B. T. Polyak. *Gradient methods for minimizing functionals*. Zh. Vychisl. Mat. Mat. Fiz., 3(4):643–653, 1963.