ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Градиентный спуск и его сходимость

МЕТОДЫ ОПТИМИЗАЦИИ

НЕДЕЛЯ 7

План лекции

1. L-гладкость и сильная выпуклость
2. Лемма о спуске и её доказательство
3. Сходимость на выпуклой L-гладкой функции
4. Сходимость на L-гладкой μ-сильно выпуклой функции
5. Сходимость в невыпуклом случае

Зачем сегодняшние оценки

Градиентный спуск — базовый метод первого порядка. Теоремы ниже отвечают на три практических вопроса.

- Какой постоянный шаг α гарантирует убывание f.
- Сколько итераций закладывать до достижения порога ε.
- Что меняет ℓ_2-регуляризация: сублинейную оценку $1/k$ она заменяет линейной $(1 - \mu/L)^k$.

Связь с прошлыми лекциями

Выпуклость, сильная выпуклость и условие Поляка — Лоясиевича — неделя 4. Сегодня из этих свойств получаются скорости градиентного спуска.

Задача и итерация

$$f(\mathbf{x}) \;\to\; \min_{\mathbf{x}\in\mathbb{R}^n}, \qquad \mathbf{x}_{k+1} \;=\; \mathbf{x}_k - \alpha f'(\mathbf{x}_k), \qquad \alpha > 0.$$

- Ограничений нет: проекции и проксимальные шаги — отдельная лекция.
- Для шага градиентного спуска нужен только градиент в текущей точке.
- α сегодня постоянный. Линейный поиск (Армихо, Вульф) был на неделе 2; он даёт тот же тип убывания, но с другими константами.

Обозначения: $f^* = \inf f$, и если минимум достигается, то в точке $\mathbf{x}^*$.

Три способа измерять ошибку

Величина	О чём говорит	Когда ею пользуемся
$f(\mathbf{x}_k) - f^*$	зазор по значению	выпуклые задачи
$\|\mathbf{x}_k - \mathbf{x}^*\|$	зазор по аргументу	есть единственный $\mathbf{x}^*$
$\|f'(\mathbf{x}_k)\|$	близость к стационарности	выпуклости нет

Одна и та же итерация даёт разные гарантии. Выпуклость превращает малость градиента в малость зазора $f - f^*$.

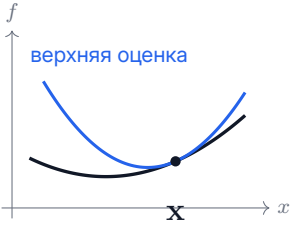
Только третий способ не требует знания минимума!

L-гладкость

Функция f **L-гладкая** ($L > 0$), если градиент липшицев:

$$\|f'(\mathbf{x}) - f'(\mathbf{y})\| \;\leq\; L\|\mathbf{x} - \mathbf{y}\| \qquad \forall\, \mathbf{x}, \mathbf{y}.$$

- Для $f \in C^2$ это то же самое, что $\|f''(\mathbf{x})\| \leq L$: все собственные значения гессиана лежат в $[-L, L]$.
- Если f ещё и выпукла, отрицательных собственных значений нет: $0 \preceq f''(\mathbf{x}) \preceq L\mathbf{I}$.
- Константа L глобальная



Откуда брать L и μ

У дважды гладкой f константа L — верхняя граница собственных значений f'', константа μ — нижняя.

Задача	Гессиан	L
$\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x}$	$\mathbf{A} = \mathbf{A}^\top$	$\lambda_{\max}(\mathbf{A})$
$\lVert \mathbf{X}\boldsymbol{\theta} - \mathbf{y} \rVert_2^2$	$2\mathbf{X}^\top \mathbf{X}$	$2\lambda_{\max}(\mathbf{X}^\top \mathbf{X})$
$\sum_i \log\left(1 + e^{-y_i \mathbf{x}_i^\top \boldsymbol{\theta}}\right)$	$\mathbf{X}^\top \mathbf{D} \mathbf{X},\ D_{ii} \le \frac{1}{4}$	$\frac{1}{4}\lambda_{\max}(\mathbf{X}^\top \mathbf{X})$

- Добавка $\frac{\mu}{2}\lVert \boldsymbol{\theta} \rVert_2^2$ сдвигает каждое собственное значение на μ: новая пара — $(L + \mu,\ \mu_{\text{old}} + \mu)$.
- Поэтому на графиках недели 4 больший μ давал более крутой линейный спад.

Сильная выпуклость

Дифференцируемая f **μ-сильно выпукла** ($\mu > 0$), если

$$f(\mathbf{y}) \;\geq\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x}\rangle + \tfrac{\mu}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

Для $f \in C^2$ то же самое: $f''(\mathbf{x}) \succeq \mu \mathbf{I}$.

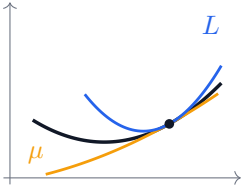
Что отсюда уже известно

- Минимум единственный, и $f(\mathbf{x}) \geq f^* + \frac{\mu}{2}\|\mathbf{x} - \mathbf{x}^*\|^2$.
- Условие Поляка — Лоясиевича с той же константой: $\|f'(\mathbf{x})\|^2 \geq 2\mu\big(f(\mathbf{x}) - f^*\big)$.
- Обратный переход к сильной выпуклости из PL не следует: пример недели 4 невыпуклый.

Две параболы и число обусловленности

Если f дифференцируемая и одновременно L-гладкая и μ-сильно выпуклая, график зажат между двумя параболами с общей касательной:

$$\tfrac{\mu}{2}\|\mathbf{y}-\mathbf{x}\|^2 \;\le\; f(\mathbf{y}) - f(\mathbf{x}) - \langle f'(\mathbf{x}), \mathbf{y}-\mathbf{x}\rangle \;\le\; \tfrac{L}{2}\|\mathbf{y}-\mathbf{x}\|^2.$$



- Для $f \in C^2$: $\mu\mathbf{I} \preceq f''(\mathbf{x}) \preceq L\mathbf{I}$.
- **Число обусловленности** $\kappa = L/\mu \ge 1$.
- Чем больше κ, тем сильнее линии уровня вытянуты и тем ближе к единице множитель $(1-\mu/L)$.
- В точке минимума зазор по аргументу и зазор по значению сравнимы: $\frac{\mu}{2}\|\mathbf{x}-\mathbf{x}^*\|^2 \le f(\mathbf{x}) - f^* \le \frac{L}{2}\|\mathbf{x}-\mathbf{x}^*\|^2$.

Лемма о спуске

Лемма

Если f L-гладкая, то для всех $\mathbf{x}, \mathbf{y}$

$$f(\mathbf{y}) \;\leq\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \tfrac{L}{2}\|\mathbf{y} - \mathbf{x}\|^2.$$

- Справа — квадратичная верхняя оценка с кривизной L.
- Выпуклость в лемме не используется. Она понадобится только в двух теоремах о зазоре $f - f^*$.
- Нижняя оценка кривизны μ — это сильная выпуклость. Верхняя оценка кривизны L — это сегодняшняя лемма.

Доказательство леммы

Вдоль отрезка $\mathbf{x}_t = \mathbf{x} + t(\mathbf{y} - \mathbf{x})$, $t \in [0, 1]$, формула Ньютона — Лейбница даёт

$$f(\mathbf{y}) - f(\mathbf{x}) \;=\; \int_0^1 \langle f'(\mathbf{x}_t),\, \mathbf{y} - \mathbf{x} \rangle \, dt.$$

Выделим градиент в точке $\mathbf{x}$:

$$f(\mathbf{y}) \;=\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \int_0^1 \langle f'(\mathbf{x}_t) - f'(\mathbf{x}),\, \mathbf{y} - \mathbf{x} \rangle \, dt.$$

Липшицевость градиента и $\|\mathbf{x}_t - \mathbf{x}\| = t\|\mathbf{y} - \mathbf{x}\|$ дают

$$\langle f'(\mathbf{x}_t) - f'(\mathbf{x}),\, \mathbf{y} - \mathbf{x} \rangle \;\le\; Lt\, \|\mathbf{y} - \mathbf{x}\|^2.$$

Доказательство леммы: интеграл

Подставляем оценку в интеграл:

$$\int_0^1 \langle f'(\mathbf{x}_t) - f'(\mathbf{x}),\, \mathbf{y} - \mathbf{x} \rangle \, dt \;\le\; \int_0^1 Lt \, \|\mathbf{y} - \mathbf{x}\|^2 \, dt \;=\; \tfrac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2.$$

Это и есть лемма о спуске.

Что именно использовано

- Дифференцируемость: чтобы написать производную вдоль отрезка.
- Липшицевость градиента с константой L: чтобы оценить подынтегральное выражение через $t\|\mathbf{y} - \mathbf{x}\|^2$.
- Выпуклость, существование минимума и величина шага α не входят в условие.

Один шаг градиентного спуска

Подставим в лемму точку $\mathbf{y} = \mathbf{x} - \alpha f'(\mathbf{x})$:

$$f\big(\mathbf{x} - \alpha f'(\mathbf{x})\big) \;\le\; f(\mathbf{x}) - \alpha\Big(1 - \frac{\alpha L}{2}\Big)\|f'(\mathbf{x})\|^2.$$

- При $0 < \alpha \le 1/L$ множитель в скобках не меньше $1/2$, поэтому

$$f(\mathbf{x}_+) \;\le\; f(\mathbf{x}) - \frac{\alpha}{2}\|f'(\mathbf{x})\|^2.$$

- Значение целевой функции гарантированно не растёт. Пока градиент ненулевой, оно строго убывает.
- При $\alpha > 2/L$ множитель $1 - \alpha L/2$ отрицательный: эта верхняя оценка уже не даёт убывание целевой функции.

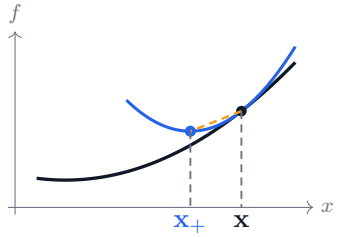
Q: почему для квадратичной функции с наибольшим собственным значением L шаг $\alpha > 2/L$ расходится?

Шаг $1/L$

Квадратичная верхняя оценка как функция $\mathbf{y}$ достигает минимума в точке

$$\mathbf{y} \;=\; \mathbf{x} - \frac{1}{L} f'(\mathbf{x}).$$

Это градиентный шаг с $\alpha = 1/L$.



- Для шага α получаем аналогичный результат с кривизной $1/\alpha$ в оценке сверху.
- Лемма разрешает такую модель при $1/\alpha \geq L$, то есть при $\alpha \leq 1/L$.
- Среди шагов $\alpha \in (0, 1/L]$ в теоремах ниже лучшая константа получается при $\alpha = 1/L$.

Одна лемма, три теоремы

При $\alpha \leq 1/L$ каждый шаг забирает хотя бы $\frac{\alpha}{2}\|f'(\mathbf{x}_k)\|^2$ из значения функции. Дальше эта убыль читается по-разному.

Дополнительное свойство	Что получается
выпуклость	$f(\mathbf{x}_T) - f^* = O(1/T)$
μ-сильная выпуклость	$f(\mathbf{x}_T) - f^* \leq (1 - \alpha\mu)^T \big(f(\mathbf{x}_0) - f^*\big)$
только L-гладкость	$\min\limits_{k<T} \|f'(\mathbf{x}_k)\| = O(T^{-1/2})$

Теорема: выпуклая L-гладкая функция

Теорема

Пусть f выпукла и L-гладкая, минимум достигается в $\mathbf{x}^*$, и $\alpha \in (0, 1/L]$. После T шагов

$$f(\mathbf{x}_T) - f^* \;\le\; \frac{\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{2\alpha T}.$$

При $\alpha = 1/L$ правая часть равна $L\|\mathbf{x}_0 - \mathbf{x}^*\|^2/(2T)$.

- Скорость **сублинейная**: зазор убывает как $1/T$.
- Допуск $f(\mathbf{x}_T) - f^* \le \varepsilon$ требует $T \ge \|\mathbf{x}_0 - \mathbf{x}^*\|^2/(2\alpha\varepsilon)$ итераций.
- Точка $\mathbf{x}^*$ входит в оценку через расстояние от точки старта $\|\mathbf{x}_0 - \mathbf{x}^*\|$.

Как читать оценку $1/T$

Пусть $R = \|\mathbf{x}_0 - \mathbf{x}^*\|$, $\alpha = 1/L$. Тогда $f(\mathbf{x}_T) - f^* \le LR^2/(2T)$.

- Уменьшить допуск в 10 раз — сделать в 10 раз больше итераций.
- Пример: $L = 10$, $R = 1$, $\varepsilon = 10^{-4}$ дают $T \ge 10/(2 \cdot 10^{-4}) = 5 \cdot 10^4$.
- Маленький шаг не спасает: в знаменателе стоит α. При $\alpha \ll 1/L$ итераций нужно пропорционально больше.
- Порядок $1/T$ неулучшаем для градиентного спуска. Для методов первого порядка нижняя оценка — $1/T^2$; её достигает ускоренный метод[1].

Чего в оценке нет

Линейного множителя $(1 - c)^T$. Без $\mu > 0$ «плоское дно» совместимо с выпуклостью, и геометрической оценки на всём классе нет.

[1] Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.1. S. Bubeck. *Convex Optimization: Algorithms and Complexity*, 2015, §3. arXiv:1405.4980.

Теорема: L-гладкая и μ-сильно выпуклая

Теорема

Пусть f L-гладкая и μ-сильно выпуклая, $\alpha \in (0, 1/L]$. Тогда

$$f(\mathbf{x}_T) - f^* \;\le\; (1 - \alpha\mu)^T \big(f(\mathbf{x}_0) - f^*\big).$$

При $\alpha = 1/L$ множитель равен $1 - \mu/L = 1 - 1/\kappa$.

- Скорость **линейная**: ошибка умножается на постоянное число меньше единицы.
- Минимум существует и единственен — это уже следствие сильной выпуклости.
- Допуск ε по значению: $T \ge \dfrac{1}{\alpha\mu} \log \dfrac{f(\mathbf{x}_0) - f^*}{\varepsilon}$. При $\alpha = 1/L$ это $T \ge \kappa \log(\Delta_0/\varepsilon)$, где $\Delta_0 = f(\mathbf{x}_0) - f^*$.

Как читать множитель $1 - 1/\kappa$

Зазор по аргументу сравнивается с зазором по значению:

$$\tfrac{\mu}{2}\|\mathbf{x}_T - \mathbf{x}^*\|^2 \;\le\; f(\mathbf{x}_T) - f^* \;\le\; \Bigl(1 - \frac{1}{\kappa}\Bigr)^T \frac{L}{2}\|\mathbf{x}_0 - \mathbf{x}^*\|^2.$$

- Те же $L = 10$, $R = 1$, допуск 10^{-4} по значению. Без сильной выпуклости вышло $T \ge 5 \cdot 10^4$.
- При $\mu = 1$, то есть $\kappa = 10$, и $\Delta_0 \le LR^2/2 = 5$: $T \ge 10 \log\bigl(5/10^{-4}\bigr) \approx 108$.
- Каждые следующие два знака точности стоят ещё порядка κ итераций, а не умножения всего бюджета на 100.

Зависимость от κ, а не от $\sqrt{\kappa}$, — свойство именно этого метода. Ускоренный градиентный метод на следующем занятии заменяет κ на $\sqrt{\kappa}$.

Проверка на квадратичной функции

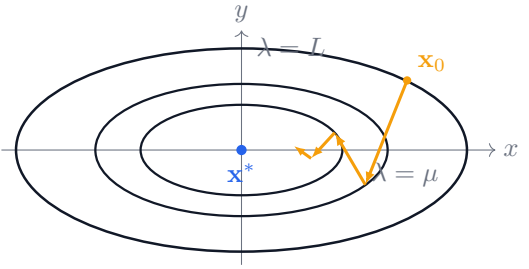
Пусть $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}$, $\mathbf{A} = \mathbf{A}^\top$, собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mu \geq 0$. Ошибка умножается на матрицу $\mathbf{I} - \alpha\mathbf{A}$:

$$\mathbf{x}_{k+1} - \mathbf{x}^* \;=\; (\mathbf{I} - \alpha\mathbf{A})(\mathbf{x}_k - \mathbf{x}^*).$$

- Сходимость по всем направлениям с $\lambda > 0$ равносильна $\alpha \in (0, 2/L)$. При $\alpha > 2/L$ множитель $|1 - \alpha L| > 1$: метод расходится.
- Шаг $\alpha = 1/L$ даёт худший множитель $1 - \mu/L$, если $\mu > 0$. Если $\mu = 0$, худший множитель равен 1: линейной оценки нет, остаётся $1/T$.
- Лучший постоянный шаг — $\alpha = 2/(L + \mu)$. Худший множитель тогда $(L - \mu)/(L + \mu) = (\kappa - 1)/(\kappa + 1)$. Зависимость от κ по-прежнему линейная.

Зигзаг при большом κ

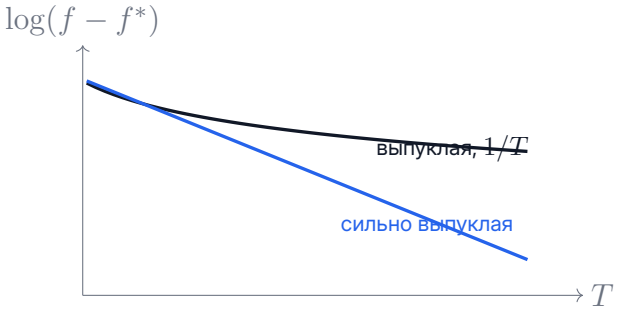
$f = \frac{1}{2}(\mu x^2 + L y^2)$, $\kappa = L/\mu = 6$, шаг $\alpha = 1.5/L$. По короткой оси множитель $1 - \alpha L = -1/2$, по длинной $1 - \alpha\mu = 3/4$.



- Длинная ось — дно оврага ($\lambda = \mu$), короткая — стенка ($\lambda = L$).
- Антиградиент смотрит в стенку. Множитель $1 - \alpha L < 0$ переносит точку на другую сторону.
- Вдоль оврага остаётся множитель $3/4$. При шаге $1/L$ перескока нет, но скорость вдоль дна всё равно $1 - 1/\kappa$.

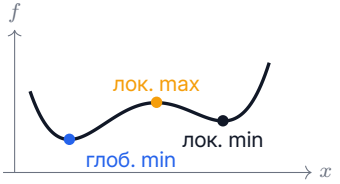
Две выпуклые скорости на одном графике

По вертикали — $\log(f - f^*)$. Линейная сходимость здесь для сильно выпуклой функции, а сублинейная $1/T$ для выпуклой.



- Вблизи начала траектории обе кривые похожи: решает начальный зазор.
- Дальше сильно выпуклый режим выигрывает за счёт постоянного множителя $1 - \mu/L$.
- ℓ_2-регуляризация как раз переводит задачу из верхней кривой в нижнюю.

Без выпуклости лемма всё ещё работает



- При $\alpha \leq 1/L$ последовательность $f(\mathbf{x}_k)$ по-прежнему убывает и, если f ограничена снизу, сходится.
- Предел значения может быть больше f^*.
- Стационарная точка бывает локальным минимумом и седлом.
- На неопределённой квадратичной форме шаг $1/L$ сходится к седлу: теорема эти точки не различает.

Теорема: стационарная точка

Теорема

Пусть f L-гладкая и $f^* > -\infty$, без предположения выпуклости. При $\alpha \in (0, 1/L]$

$$\min_{0 \le k < T} \|f'(\mathbf{x}_k)\|^2 \;\le\; \frac{2\big(f(\mathbf{x}_0) - f^*\big)}{\alpha T}.$$

При $\alpha = 1/L$

$$\min_{0 \le k < T} \|f'(\mathbf{x}_k)\| \;\le\; \sqrt{\frac{2L\big(f(\mathbf{x}_0) - f^*\big)}{T}}.$$

- Оценка стоит на **лучшей** точке траектории. Нормы градиента по k не обязаны убывать монотонно.
- Скорость по норме градиента — $O(T^{-1/2})$. По зазору $f - f^*$ скорости нет.

Доказательство в невыпуклом случае

Снова следствие леммы, $\alpha \in (0, 1/L]$:

$$f(\mathbf{x}_{k+1}) \;\leq\; f(\mathbf{x}_k) - \frac{\alpha}{2}\|f'(\mathbf{x}_k)\|^2.$$

Суммируем $k = 0, \ldots, T-1$:

$$\frac{\alpha}{2}\sum_{k=0}^{T-1}\|f'(\mathbf{x}_k)\|^2 \;\leq\; f(\mathbf{x}_0) - f(\mathbf{x}_T) \;\leq\; f(\mathbf{x}_0) - f^*.$$

Минимум не больше среднего:

$$\min_{0\leq k<T}\|f'(\mathbf{x}_k)\|^2 \;\leq\; \frac{1}{T}\sum_{k=0}^{T-1}\|f'(\mathbf{x}_k)\|^2 \;\leq\; \frac{2\big(f(\mathbf{x}_0) - f^*\big)}{\alpha T}.$$

Выпуклость не использовалась. Нижняя граница f^* нужна, чтобы сумма убыли была конечной.

Как читать оценку по градиенту

Пусть $\alpha = 1/L$, $\Delta_0 = f(\mathbf{x}_0) - f^*$ и нужно $\|f'(\mathbf{x}_k)\| \le \varepsilon$ хотя бы в одной точке траектории. Тогда

$$T \;\ge\; \frac{2L\Delta_0}{\varepsilon^2}.$$

- Уменьшить допуск по градиенту в 10 раз — увеличить бюджет итераций в 100 раз.
- Пример: $L = 10$, $\Delta_0 = 1$, $\varepsilon = 10^{-2}$ дают $T \ge 2 \cdot 10 \cdot 1/10^{-4} = 2 \cdot 10^5$.
- Это оценка числа итераций до стационарности, а не до глобального минимума.

Три режима

$\Delta_0 = f(\mathbf{x}_0) - f^*$, $R = \|\mathbf{x}_0 - \mathbf{x}^*\|$, шаг $\alpha = 1/L$, $\kappa = L/\mu$.

	Выпуклая	Сильно выпуклая	Без выпуклости
Дополнительно	выпуклость	μ-сильная выпуклость	$f^* > -\infty$
Гарантия	$f(\mathbf{x}_T) - f^*$	$f(\mathbf{x}_T) - f^*$	$\min_{k<T} \|f'\|$
Оценка	$\dfrac{LR^2}{2T}$	$\big(1 - 1/\kappa\big)^T \Delta_0$	$\sqrt{2L\Delta_0/T}$
Итераций	$O(LR^2/\varepsilon)$	$O\big(\kappa \log(\Delta_0/\varepsilon)\big)$	$O(L\Delta_0/\varepsilon^2)$

Во всех трёх строках f L-гладкая, и доказательство начинается с одной и той же убыли $\frac{1}{2L}\|f'(\mathbf{x}_k)\|^2$ за шаг.

Выбор шага

- Теоремы этой лекции написаны для постоянного $\alpha \in (0, 1/L]$. Константа лучше всего при $\alpha = 1/L$.
- Если L известно, как у квадратичной задачи или у наименьших квадратов, этот шаг можно поставить сразу.
- Если L неизвестно, бэктрекинг по условию Армихо (неделя 2) подбирает шаг, для которого выполнено то же убывание $f(\mathbf{x}_k) - f(\mathbf{x}_{k+1}) \geq c\|f'(\mathbf{x}_k)\|^2$. Порядки $1/T$, $(1 - c\mu)^T$ и $T^{-1/2}$ сохраняются.
- Шаг меньше $1/L$ не ломает сходимость, но замедляет её: в выпуклой оценке в знаменателе стоит α, в сильно выпуклой множитель равен $1 - \alpha\mu$.

Что запомнить

- L-гладкость — липшицев градиент. Для $f \in C^2$ все $|\lambda(f'')| \le L$.
- Лемма о спуске: график не выше параболы кривизны L. Выпуклость для неё не нужна.
- Шаг $\alpha \le 1/L$ уменьшает f хотя бы на $\frac{\alpha}{2}\|f'\|^2$. Шаг $1/L$ минимизирует эту параболу.
- Выпуклая L-гладкая: $f(\mathbf{x}_T) - f^* \le LR^2/(2T)$.
- Плюс μ-сильная выпуклость: зазор умножается на $1 - \mu/L$ каждый шаг. Число итераций пропорционально $\kappa \log(1/\varepsilon)$.
- Без выпуклости контролируется лучшая норма градиента, порядок $T^{-1/2}$. Стационарная точка может быть седлом.

Источники

- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.1.
- S. Bubeck. *Convex Optimization: Algorithms and Complexity*, 2015, §3. arXiv:1405.4980
- Y. Carmon, J. Duchi, O. Hinder, A. Sidford. *Lower bounds for finding stationary points I*. Mathematical Programming, 2020. arXiv:1710.11606
- H. Karimi, J. Nutini, M. Schmidt. *Linear convergence of gradient and proximal-gradient methods under the Polyak–Łojasiewicz condition*. ECML PKDD, 2016. arXiv:1608.04636

Дальше

- Ускоренный градиентный метод Нестерова
- Та же L-гладкая выпуклая задача: порядок $1/T^2$ вместо $1/T$
- Та же сильно выпуклая задача: $\sqrt{\kappa}$ вместо κ
- Почему одного постоянного шага по антиградиенту для этого уже не хватает

