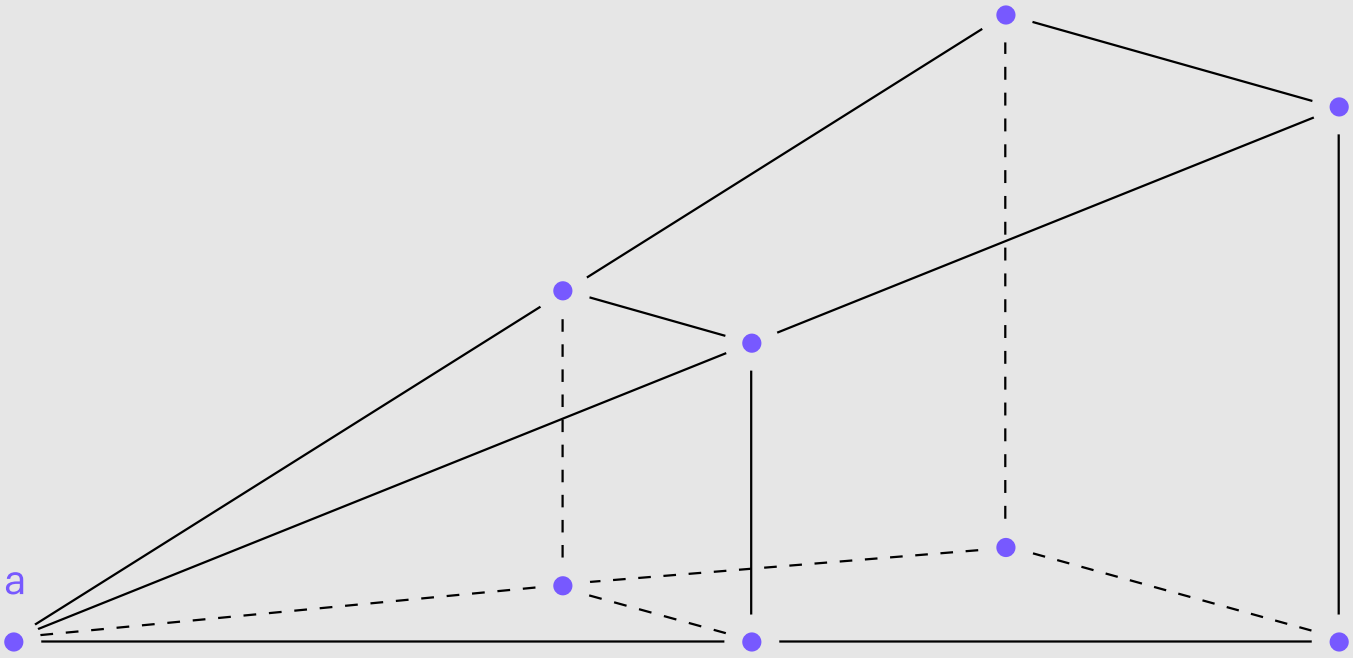
Машинное обучение | Домашнее задание

Методы оптимизации | 08

Ускоренные градиентные методы. Идея метода сопряжённых градиентов



Ускорение градиентного спуска

Контекст

На слайдах три метода сравниваются с градиентным спуском недели 7: сопряжённые градиенты, тяжёлый шарик Поляка и ускорение Нестерова. Для каждого выписаны теоремы сходимости. Вывод коэффициента сходимости и проверка свойств, которые алгоритм сохраняет после шага, в презентацию не вошли.

Применение

Сопряжённые градиенты решают большую систему с симметричной положительно определённой матрицей, даже когда доступна только операция умножения на матрицу и нет её явного хранения. Тяжёлый шарик с формулой Поляка — тот же порядок сходимости на квадратичной задаче, если μ и L уже известны. Метод Нестерова — единственный из трёх, оценка сходимости которого действует на любой гладкой выпуклой задаче, а не только на квадратичной.

Задача лонгрида

Доказать теоремы со слайдов и их следствия: скорость сходимости сопряжённых градиентов, спектральный радиус тяжёлого шарика, обе оценки для метода Нестерова и формулу для β^{PR}.

Краткий план

- Сопряжённые градиенты: инварианты, конечная остановка, многочлен Чебышёва
- Откуда берётся β^{PR}
- Тяжёлый шарик: радиус, рост в начале, что ломается вне квадратичной задачи
- Нестеров: $1 - 1/\sqrt{\kappa}$ и $2LR^2/(k+1)^2$

Штрих обозначает градиент: $f'(\mathbf{x}) \in \mathbb{R}^n$. Норма евклидова, если явно не написана другая. Пишем $f^* = \inf f$ и, когда минимум достигается, $\mathbf{x}^*$ для его точки. $\Delta_0 = f(\mathbf{x}_0) - f^*$, $R = \|\mathbf{x}_0 - \mathbf{x}^*\|$, $\kappa = L/\mu$. Логарифм в оценках числа итераций натуральный: на слайдах он обозначен $\log$.

1. КОЭФФИЦИЕНТЫ СХОДИМОСТИ ИЗ ТАБЛИЦЫ

ТЕОРЕМА 1

Пусть $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}$, $\mathbf{A} = \mathbf{A}^\top$, и собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mu > 0$. Градиентный шаг $\mathbf{x}_+ = \mathbf{x} - \alpha f'(\mathbf{x})$ с постоянным α сходится при $0 < \alpha < 2/L$. Величина $\max_{\lambda \in [\mu,L]} |1 - \alpha\lambda|$ минимальна при

$$\alpha = \frac{2}{L + \mu}$$

и равна $(\kappa - 1)/(\kappa + 1)$. При шаге $1/L$ та же величина равна $1 - 1/\kappa$.

ДОКАЗАТЕЛЬСТВО

$f'(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ и $\mathbf{A}\mathbf{x}^* = \mathbf{b}$, поэтому

$$\mathbf{x}_+ - \mathbf{x}^* = (\mathbf{I} - \alpha\mathbf{A})(\mathbf{x} - \mathbf{x}^*).$$

В ортонормированном собственном базисе координата с собственным значением λ умножается на $1 - \alpha\lambda$. Евклидова норма ошибки умножается не больше чем на $\max_i |1 - \alpha\lambda_i|$.

На отрезке $[\mu, L]$ функция $|1 - \alpha\lambda|$ выпукла по λ, максимум сидит в одном из концов. При $0 < \alpha < 2/L$ оба конца строго меньше единицы: $1 - \alpha\mu \in (0,1)$ и $\alpha L - 1 \in$

$(0,1)$. При $\alpha \geqslant 2/L$ множитель на $\lambda = L$ не меньше единицы, и есть начальные данные, для которых ошибка не стремится к нулю.

Минимум по α величины $\max\{|1-\alpha\mu|, |1-\alpha L|\}$ достигается, когда концы равны: $1-\alpha\mu = \alpha L - 1$, то есть $\alpha(L+\mu) = 2$. Общее значение

$$1 - \frac{2\mu}{L+\mu} = \frac{L-\mu}{L+\mu} = \frac{\kappa-1}{\kappa+1}.$$

При $\alpha = 1/L$ концы равны $1-\mu/L = 1-1/\kappa$ и 0, максимум равен $1-1/\kappa$.

ЗАМЕЧАНИЕ

Множитель теоремы относится к вектору $\mathbf{x}_k - \mathbf{x}^*$. Зазор по значению на этой квадратичной функции равен $\frac{1}{2}\|\mathbf{x}-\mathbf{x}^*\|_{\mathbf{A}}^2$ (лемма ниже), поэтому за одну итерацию он умножается на квадрат того же числа. У шага $1/L$ это $(1-1/\kappa)^2$, у шага $2/(L+\mu)$ — $((\kappa-1)/(\kappa+1))^2$.

Строка таблицы про шаг $1/L$ цитирует другую оценку: теорему недели 7 о зазоре $f - f^*$ на всём классе гладких сильно выпуклых функций, с множителем $1-1/\kappa$, без квадрата. На одной только квадратичной задаче шаг $1/L$ сжимает зазор быстрее, чем говорит эта общая оценка.

ЛЕММА 1

Пусть $0 < \rho < 1$ и ошибка за шаг умножается на ρ. Чтобы умножить её на $1/e$, нужно

$$T = \frac{1}{-\ln\rho}$$

итераций. Если $\rho = 1-u$ и $0 < u < 1$, то $-\ln(1-u) = u + u^2/2 + \cdots$, поэтому T близко к $1/u$ при малом u.

ДОКАЗАТЕЛЬСТВО

$\rho^T = e^{-1}$ равносильно $T\ln\rho = -1$. Разложение $-\ln(1-u)$ — ряд Тейлора.

Отсюда четыре строки таблицы при большом κ.

- Шаг $1/L$, множитель зазора $1-1/\kappa$: $u = 1/\kappa$, около κ итераций.
- Лучший постоянный шаг, множитель вектора ошибки $(\kappa-1)/(\kappa+1) = 1-2/(\kappa+1)$: около $(\kappa+1)/2$ итераций, в таблице $\kappa/2$.
- Нестеров, множитель зазора $1-1/\sqrt{\kappa}$: около $\sqrt{\kappa}$ итераций.
- Сопряжённые градиенты и тяжёлый шарик, множитель $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1) = 1-2/(\sqrt{\kappa}+1)$: около $(\sqrt{\kappa}+1)/2$ итераций, в таблице $\sqrt{\kappa}/2$.

При $\kappa = 10^4$ множитель сопряжённых градиентов равен $99/101$. Тогда $-\ln(99/101) \approx 0{,}02000$, и до уменьшения $\mathbf{A}$-нормы в e раз нужно 50 итераций с точностью до долей шага. Приближение $1/u$ здесь уже почти точное.

ЗАМЕЧАНИЕ

У сопряжённых градиентов и у тяжёлого шарика выписанный множитель сжимает норму ошибки, а не сам зазор $f - f^*$. Зазор равен половине квадрата $\mathbf{A}$-нормы, поэтому умножается на квадрат множителя, примерно $e^{-4/\sqrt{\kappa}}$. Уменьшение зазора в e раз на квадратичной задаче стоит около $\sqrt{\kappa}/4$ итераций. Таблица считает итерации по множителю, который стоит в соответствующей теореме, без этого квадрата. Сравнение «вдвое выгоднее, чем $1-1/\sqrt{\kappa}$» на слайде — сравнение именно этих выписанных множителей: $2/\sqrt{\kappa}$ против $1/\sqrt{\kappa}$ в показателе экспоненты.

2. ЛИНЕЙНЫЕ СОПРЯЖЁННЫЕ ГРАДИЕНТЫ

В этом подразделе

$$f(\mathbf{x}) = \tfrac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}, \qquad \mathbf{A} = \mathbf{A}^\top \succ 0,$$

собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$, $\mathbf{x}^*$ — решение $\mathbf{A}\mathbf{x} = \mathbf{b}$. Итерация со слайда: $\mathbf{g}_0 = \mathbf{A}\mathbf{x}_0 - \mathbf{b}$, $\mathbf{d}_0 = -\mathbf{g}_0$,

$$\begin{aligned} \alpha_k &= \frac{\|\mathbf{g}_k\|^2}{\mathbf{d}_k^\top \mathbf{A}\mathbf{d}_k}, & \mathbf{x}_{k+1} &= \mathbf{x}_k + \alpha_k \mathbf{d}_k, \\ \mathbf{g}_{k+1} &= \mathbf{g}_k + \alpha_k \mathbf{A}\mathbf{d}_k, & \beta_k &= \frac{\|\mathbf{g}_{k+1}\|^2}{\|\mathbf{g}_k\|^2}, \\ \mathbf{d}_{k+1} &= -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k. \end{aligned} \tag{1}$$

Пока $\mathbf{g}_k \neq \mathbf{0}$, знаменатель α_k положителен: это проверяется вместе со свойствами ниже, потому что направление $\mathbf{d}_k$ оказывается ненулевым.

ЛЕММА 2

$$f(\mathbf{x}) - f^* = \tfrac{1}{2}\|\mathbf{x} - \mathbf{x}^*\|_{\mathbf{A}}^2, \qquad \|\mathbf{v}\|_{\mathbf{A}} = \sqrt{\mathbf{v}^\top \mathbf{A}\mathbf{v}}.$$

ДОКАЗАТЕЛЬСТВО

Подстановка $\mathbf{b} = \mathbf{A}\mathbf{x}^*$ даёт

$$\begin{aligned} f(\mathbf{x}) - f(\mathbf{x}^*) &= \tfrac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{x}^{*\top}\mathbf{A}\mathbf{x} + \tfrac{1}{2}\mathbf{x}^{*\top}\mathbf{A}\mathbf{x}^* \\ &= \tfrac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top \mathbf{A}(\mathbf{x} - \mathbf{x}^*). \end{aligned}$$

Значит, минимум f на любом аффинном подпространстве — это то же самое, что минимум $\mathbf{A}$-нормы ошибки. У строго выпуклой квадратичной функции он единственный, и это в точности та точка подпространства, где градиент ортогонален направляющему подпространству.

ЛЕММА 3

Пусть на шаге k выполнено $\langle \mathbf{g}_k, \mathbf{d}_k \rangle = -\|\mathbf{g}_k\|^2$ и $\mathbf{d}_k \neq \mathbf{0}$. Тогда α_k из (1) — точный минимум f вдоль прямой $\mathbf{x}_k + t\mathbf{d}_k$, и $\langle \mathbf{g}_{k+1}, \mathbf{d}_k \rangle = 0$.

ДОКАЗАТЕЛЬСТВО

Производная $t \mapsto f(\mathbf{x}_k + t\mathbf{d}_k)$ равна

$$\langle \mathbf{g}_k + t\mathbf{A}\mathbf{d}_k, \mathbf{d}_k \rangle = -\|\mathbf{g}_k\|^2 + t\,\mathbf{d}_k^\top \mathbf{A}\mathbf{d}_k.$$

Она обнуляется при $t = \alpha_k$. Вторая производная $\mathbf{d}_k^\top \mathbf{A}\mathbf{d}_k > 0$, это минимум. Подстановка $\mathbf{g}_{k+1} = \mathbf{g}_k + \alpha_k \mathbf{A}\mathbf{d}_k$ даёт $\langle \mathbf{g}_{k+1}, \mathbf{d}_k \rangle = 0$.

ТЕОРЕМА 2

Пока $\mathbf{g}_k \neq \mathbf{0}$, в точной арифметике верно следующее.

1. $\langle \mathbf{g}_k, \mathbf{d}_k \rangle = -\|\mathbf{g}_k\|^2$, шаг α_k точный, и $\mathbf{d}_k \neq \mathbf{0}$.
2. Градиенты ортогональны: $\langle \mathbf{g}_i, \mathbf{g}_j \rangle = 0$ при $i \neq j$, $i, j \leqslant k$.
3. Направления сопряжены: $\mathbf{d}_i^\top \mathbf{A}\mathbf{d}_j = 0$ при $i \neq j$, $i, j \leqslant k$.
4. $\operatorname{span}\{\mathbf{d}_0, \ldots, \mathbf{d}_k\} = \operatorname{span}\{\mathbf{g}_0, \ldots, \mathbf{g}_k\}$ совпадает с подпространством Крылова

$$\mathcal{K}_{k+1} = \operatorname{span}\{\mathbf{g}_0, \mathbf{A}\mathbf{g}_0, \ldots, \mathbf{A}^k \mathbf{g}_0\}.$$

5. $\mathbf{x}_k$ минимизирует f на $\mathbf{x}_0 + \operatorname{span}\{\mathbf{d}_0, \ldots, \mathbf{d}_{k-1}\}$ при $k \geqslant 1$, и $f(\mathbf{x}_k) < f(\mathbf{x}_{k-1})$.

В $\mathbb{R}^n$ найдётся $m \leqslant n$ с $\mathbf{g}_m = \mathbf{0}$, и тогда $\mathbf{x}_m = \mathbf{x}^*$.

ДОКАЗАТЕЛЬСТВО

Индукция по k. При $k=0$ направление $\mathbf{d}_0=-\mathbf{g}_0$, первое свойство верно, а ортогональность и сопряжённость пар пусты. Пространства $\operatorname{span}\{\mathbf{d}_0\}$ и $\operatorname{span}\{\mathbf{g}_0\}=\mathcal{K}_1$ совпадают.

Пусть все пять свойств верны до номера k, и $\mathbf{g}_k\neq\mathbf{0}$. Из первого свойства $\langle\mathbf{g}_k,\mathbf{d}_k\rangle=-\|\mathbf{g}_k\|^2\neq 0$, поэтому $\mathbf{d}_k\neq\mathbf{0}$. Лемма о точном шаге применима, $\langle\mathbf{g}_{k+1},\mathbf{d}_k\rangle=0$, и $f(\mathbf{x}_{k+1})<f(\mathbf{x}_k)$: производная вдоль $\mathbf{d}_k$ в точке $\mathbf{x}_k$ равна $-\|\mathbf{g}_k\|^2<0$.

Проверим $\mathbf{g}_{k+1}\perp\mathbf{d}_j$ при $j\leqslant k$. Для $j=k$ это точный шаг. Для $j<k$

$$\langle\mathbf{g}_{k+1},\mathbf{d}_j\rangle=\langle\mathbf{g}_k,\mathbf{d}_j\rangle+\alpha_k\mathbf{d}_k^{\top}\mathbf{A}\mathbf{d}_j=\langle\mathbf{g}_k,\mathbf{d}_j\rangle,$$

сопряжённость обнуляет второе слагаемое. По индукции $\mathbf{d}_j\in\operatorname{span}\{\mathbf{g}_0,\ldots,\mathbf{g}_j\}$ и $\mathbf{g}_k$ ортогонален всем предыдущим градиентам, так что $\langle\mathbf{g}_k,\mathbf{d}_j\rangle=0$. Следовательно, $\mathbf{g}_{k+1}$ ортогонален $\operatorname{span}\{\mathbf{d}_0,\ldots,\mathbf{d}_k\}=\operatorname{span}\{\mathbf{g}_0,\ldots,\mathbf{g}_k\}$.

Сопряжённость нового направления с предыдущими. Из $\mathbf{g}_{k+1}-\mathbf{g}_k=\alpha_k\mathbf{A}\mathbf{d}_k$ и уже доказанной ортогональности

$$\mathbf{g}_{k+1}^{\top}\mathbf{A}\mathbf{d}_k=\frac{\|\mathbf{g}_{k+1}\|^2}{\alpha_k}.$$

Вместе с $\alpha_k=\|\mathbf{g}_k\|^2/(\mathbf{d}_k^{\top}\mathbf{A}\mathbf{d}_k)$ и определением β_k

$$\mathbf{d}_{k+1}^{\top}\mathbf{A}\mathbf{d}_k=-\mathbf{g}_{k+1}^{\top}\mathbf{A}\mathbf{d}_k+\beta_k\mathbf{d}_k^{\top}\mathbf{A}\mathbf{d}_k=0.$$

Для $j<k$ используем $\mathbf{A}\mathbf{d}_j=(\mathbf{g}_{j+1}-\mathbf{g}_j)/\alpha_j$. Оба градиента в правой части ортогональны $\mathbf{g}_{k+1}$, и $\mathbf{d}_k^{\top}\mathbf{A}\mathbf{d}_j=0$ по индукции, поэтому $\mathbf{d}_{k+1}^{\top}\mathbf{A}\mathbf{d}_j=0$.

Формула $\mathbf{d}_{k+1}=-\mathbf{g}_{k+1}+\beta_k\mathbf{d}_k$ даёт $\langle\mathbf{g}_{k+1},\mathbf{d}_{k+1}\rangle=-\|\mathbf{g}_{k+1}\|^2$. Если $\mathbf{g}_{k+1}\neq\mathbf{0}$, то $\mathbf{d}_{k+1}\neq\mathbf{0}$. Та же формула вместе с индукционным равенством пространств до номера k показывает, что $\operatorname{span}\{\mathbf{d}_0,\ldots,\mathbf{d}_{k+1}\}$ и $\operatorname{span}\{\mathbf{g}_0,\ldots,\mathbf{g}_{k+1}\}$ совпадают. Дальше $\mathbf{g}_{k+1}=\mathbf{g}_k+\alpha_k\mathbf{A}\mathbf{d}_k$. Направление $\mathbf{d}_k$ лежит в $\mathcal{K}_{k+1}$, поэтому $\mathbf{A}\mathbf{d}_k$ и $\mathbf{g}_{k+1}$ лежат в $\mathcal{K}_{k+2}$. Новое направление сопряжено со всеми предыдущими и потому не лежит в их оболочке: размерность равна $k+2$. Подпространство Крылова $\mathcal{K}_{k+2}$ не шире, поэтому пространства совпадают и с ним.

Точка $\mathbf{x}_{k+1}$ лежит в $\mathbf{x}_0+\operatorname{span}\{\mathbf{d}_0,\ldots,\mathbf{d}_k\}$, и её градиент ортогонален этому подпространству. Для строго выпуклой квадратичной функции это и есть минимум f на аффинном подпространстве.

Ненулевых попарно ортогональных векторов в $\mathbb{R}^n$ не больше n. Цепочка $\mathbf{g}_0,\mathbf{g}_1,\ldots$ обрывается: $\mathbf{g}_m=\mathbf{0}$ при некотором $m\leqslant n$. Тогда $\mathbf{A}\mathbf{x}_m=\mathbf{b}$.

ЗАМЕЧАНИЕ

Монотонно убывает f, а с ним и $\mathbf{A}$-норма ошибки. Евклидова норма невязки $\|\mathbf{g}_k\|=\|\mathbf{A}(\mathbf{x}_k-\mathbf{x}^*)\|$ может вырасти: $\mathbf{A}$-норма и евклидова норма по-разному взвешивают собственные направления. Рост $\|\mathbf{g}_k\|$ при убывании f теореме не противоречит. В машинной арифметике скалярные произведения, которые индукция обнуляет, накапливают ошибку округления. Конечная остановка за n шагов при этом пропадает, и метод останавливают по относительной невязке.

Подпространство Крылова даёт представление ошибки многочленом. Любая точка $\mathbf{x}_0 + \mathcal{K}_k$ имеет вид

$$\mathbf{x}_0 + \sum_{j=0}^{k-1} c_j \mathbf{A}^j \mathbf{g}_0.$$

Поскольку $\mathbf{g}_0 = \mathbf{A}(\mathbf{x}_0 - \mathbf{x}^*)$,

$$\mathbf{x} - \mathbf{x}^* = q(\mathbf{A})(\mathbf{x}_0 - \mathbf{x}^*)$$

для некоторого многочлена q степени не выше k с $q(0) = 1$. Верно и обратное: каждый такой многочлен даёт точку того же аффинного подпространства. Метод на шаге k выбирает точку с наименьшей $\mathbf{A}$-нормой ошибки, поэтому

$$\|\mathbf{x}_k - \mathbf{x}^*\|_{\mathbf{A}} = \min_{\substack{q(0)=1 \\ \deg q \leqslant k}} \|q(\mathbf{A})(\mathbf{x}_0 - \mathbf{x}^*)\|_{\mathbf{A}}. \tag{2}$$

ТЕОРЕМА 3

В обозначениях выше

$$\|\mathbf{x}_k - \mathbf{x}^*\|_{\mathbf{A}} \leqslant 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|_{\mathbf{A}}.$$

В точной арифметике дополнительно $\mathbf{x}_n = \mathbf{x}^*$.

ДОКАЗАТЕЛЬСТВО

Конечная остановка уже доказана. Для скорости достаточно одного многочлена в (2). Многочлен Чебышёва T_k задаётся формулой $T_k(\cosh\theta) = \cosh(k\theta)$ и на $[-1,1]$ не превосходит 1 по модулю. Положим

$$t(\lambda) = \frac{2\lambda - (L+\mu)}{L-\mu}, \qquad q(\lambda) = \frac{T_k\big(t(\lambda)\big)}{T_k\big(t(0)\big)}.$$

Отображение t переводит $[\mu, L]$ в $[-1,1]$, а $q(0) = 1$, степень q равна k. На спектре $|q(\lambda)| \leqslant 1/|T_k(t(0))|$. В собственном базисе

$$\|q(\mathbf{A})\mathbf{v}\|_{\mathbf{A}} \leqslant \max_{\lambda \in [\mu, L]} |q(\lambda)|\, \|\mathbf{v}\|_{\mathbf{A}},$$

поэтому правая часть (2) не больше $\|\mathbf{x}_0 - \mathbf{x}^*\|_{\mathbf{A}} / |T_k(t(0))|$.

Значение в нуле отрицательное и большое по модулю:

$$t(0) = -\frac{L+\mu}{L-\mu} = -\frac{\kappa+1}{\kappa-1}.$$

Чётность $T_k(-s) = (-1)^k T_k(s)$ убирает знак. Пусть $\sigma = (\sqrt{\kappa}+1)/(\sqrt{\kappa}-1) > 1$ и $\theta = \ln\sigma$. Тогда

$$\cosh\theta = \frac{\sigma + \sigma^{-1}}{2} = \frac{\kappa+1}{\kappa-1},$$

потому что $\sigma + \sigma^{-1} = 2(\kappa+1)/(\kappa-1)$. Отсюда

$$T_k\left(\frac{\kappa+1}{\kappa-1}\right) = \cosh(k\theta) = \frac{\sigma^k + \sigma^{-k}}{2} \geqslant \frac{1}{2}\sigma^k.$$

Значит

$$\max_{\lambda\in[\mu,L]}|q(\lambda)|\leqslant 2\sigma^{-k}=2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^{k}.$$

ЗАМЕЧАНИЕ

Этот многочлен — минимаксный среди многочленов с $q(0)=1$: на отрезке $[\mu,L]$ меньшую равномерную норму получить нельзя. Оценка теоремы зависит от спектра только через концы μ и L. Если различных собственных значений всего m, многочлен $\prod_{i=1}^{m}(1-\lambda/\lambda_i)$ имеет степень m, равен единице в нуле и обнуляет ошибку. Метод заканчивает работу не позже m-го шага, даже если $m\ll n$. Кластеры собственных значений укорачивают реальную траекторию относительно оценки через одно только κ.

СЛЕДСТВИЕ

$$\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}=1-\frac{2}{\sqrt{\kappa}+1}.$$

При большом κ это число близко к $e^{-2/\sqrt{\kappa}}$, и $\mathbf{A}$-норма ошибки уменьшается в e раз примерно за $\sqrt{\kappa}/2$ итераций.

3. ФОРМУЛА ПОЛАКА — РИБЬЕРА

Для неквадратичной $f\in C^2$ схема та же, но $\mathbf{A}\mathbf{d}_k$ и точный α_k заменяются линейным поиском. $\mathbf{d}_0=-f'(\mathbf{x}_0)$,

$$\mathbf{x}_{k+1}=\mathbf{x}_k+\alpha_k\mathbf{d}_k,\qquad \mathbf{d}_{k+1}=-f'(\mathbf{x}_{k+1})+\beta_k\mathbf{d}_k.$$

Пишем $\mathbf{g}_k=f'(\mathbf{x}_k)$ и $\mathbf{y}_k=\mathbf{g}_{k+1}-\mathbf{g}_k$.

ЛЕММА 4

$$\mathbf{y}_k=\left(\int_0^1 f''(\mathbf{x}_k+t\alpha_k\mathbf{d}_k)\,dt\right)\alpha_k\mathbf{d}_k.$$

ДОКАЗАТЕЛЬСТВО

Производная отображения $t\mapsto f'(\mathbf{x}_k+t\alpha_k\mathbf{d}_k)$ равна $f''(\mathbf{x}_k+t\alpha_k\mathbf{d}_k)\,\alpha_k\mathbf{d}_k$. Интеграл от 0 до 1 равен $\mathbf{g}_{k+1}-\mathbf{g}_k$.

На квадратичной задаче интеграл равен $\mathbf{A}$, и $\mathbf{y}_k=\alpha_k\mathbf{A}\mathbf{d}_k$. Сопряжённость $\mathbf{d}_{k+1}^{\top}\mathbf{A}\mathbf{d}_k=0$ превращается в требование $\langle\mathbf{d}_{k+1},\mathbf{y}_k\rangle=0$. Его и переносят на неквадратичную функцию: средний гессиан вдоль шага занимает место $\mathbf{A}$.

ТЕОРЕМА 4

Пусть $\langle\mathbf{d}_k,\mathbf{y}_k\rangle\neq 0$ и направление выбрано из условия $\langle\mathbf{d}_{k+1},\mathbf{y}_k\rangle=0$. Тогда

$$\beta_k=\frac{\langle\mathbf{g}_{k+1},\mathbf{y}_k\rangle}{\langle\mathbf{d}_k,\mathbf{y}_k\rangle}.$$

Если шаг вдоль $\mathbf{d}_k$ точный и, при $k\geqslant 1$, шаг вдоль $\mathbf{d}_{k-1}$ тоже точный, знаменатель равен $\|\mathbf{g}_k\|^2$, и

$$\beta_k=\beta_k^{\mathrm{PR}}=\frac{\langle\mathbf{g}_{k+1},\mathbf{y}_k\rangle}{\|\mathbf{g}_k\|^2}.$$

ДОКАЗАТЕЛЬСТВО

Подстановка $\mathbf{d}_{k+1}=-\mathbf{g}_{k+1}+\beta_k\mathbf{d}_k$ в $\langle\mathbf{d}_{k+1},\mathbf{y}_k\rangle=0$ сразу даёт формулу Хестенса — Стифеля, первое равенство.

Точный шаг вдоль $\mathbf{d}_k$ означает $\langle \mathbf{g}_{k+1}, \mathbf{d}_k \rangle = 0$. Поэтому

$$\langle \mathbf{d}_k, \mathbf{y}_k \rangle = \langle \mathbf{d}_k, \mathbf{g}_{k+1} \rangle - \langle \mathbf{d}_k, \mathbf{g}_k \rangle = -\langle \mathbf{d}_k, \mathbf{g}_k \rangle.$$

При $k = 0$ направление $\mathbf{d}_0 = -\mathbf{g}_0$, и правая часть равна $\|\mathbf{g}_0\|^2$. При $k \geqslant 1$ используем $\mathbf{d}_k = -\mathbf{g}_k + \beta_{k-1}\mathbf{d}_{k-1}$ и точный предыдущий шаг $\langle \mathbf{g}_k, \mathbf{d}_{k-1} \rangle = 0$:

$$\langle \mathbf{d}_k, \mathbf{g}_k \rangle = -\|\mathbf{g}_k\|^2 + \beta_{k-1}\langle \mathbf{d}_{k-1}, \mathbf{g}_k \rangle = -\|\mathbf{g}_k\|^2.$$

Знаменатель равен $\|\mathbf{g}_k\|^2$.

ЗАМЕЧАНИЕ

Если $\mathbf{g}_{k+1} = \mathbf{g}_k$, то $\mathbf{y}_k = \mathbf{0}$. Условие сопряжённости выполнено при любом β_k, а формула Полака — Рибьера даёт $\beta_k = 0$ и $\mathbf{d}_{k+1} = -\mathbf{g}_{k+1}$. На квадратичной задаче с точным шагом теорема про ортогональность градиентов даёт $\langle \mathbf{g}_{k+1}, \mathbf{g}_k \rangle = 0$, числитель равен $\|\mathbf{g}_{k+1}\|^2$, и β_k^{PR} совпадает с β_k линейного метода.

Условия Вульфа заменяют точный минимум вдоль прямой двумя неравенствами: достаточное убывание f и кривизна, из-за которой новое направление уже не так сильно убывает. Равенство $\langle \mathbf{g}_{k+1}, \mathbf{d}_k \rangle = 0$ становится приближённым, и β^{PR} приближает коэффициент Хестенса — Стифеля. В главе 5 Nocedal — Wright для сопряжённых градиентов берут константу кривизны около $0{,}1$: более слабое условие хуже держит качество направления.

Рабочий вариант со слайда, $\beta_k = \max\{\beta_k^{\mathrm{PR}}, 0\}$, при отрицательном коэффициенте отбрасывает старое направление и заново идёт по $-\mathbf{g}_{k+1}$.

4. ТЯЖЁЛЫЙ ШАРИК

Итерация

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha f'(\mathbf{x}_k) + \beta(\mathbf{x}_k - \mathbf{x}_{k-1}), \qquad \mathbf{x}_{-1} = \mathbf{x}_0.$$

Запись через скорость $\mathbf{v}_0 = \mathbf{0}$, $\mathbf{v}_{k+1} = \beta\mathbf{v}_k - \alpha f'(\mathbf{x}_k)$, $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{v}_{k+1}$ — та же формула: $\mathbf{v}_{k+1} = \mathbf{x}_{k+1} - \mathbf{x}_k$.

ТЕОРЕМА 5

Пусть $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}$ и собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mu > 0$. При параметрах Поляка

$$\alpha = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \qquad \beta = \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^2$$

каждая координата ошибки в собственном базисе удовлетворяет рекурсии второго порядка, и оба корня характеристического уравнения имеют модуль

$$\sqrt{\beta} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Есть постоянная C, зависящая только от $\mathbf{A}$, такая что

$$\|\mathbf{x}_k - \mathbf{x}^*\| \leqslant C(1 + k)\left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|.$$

Число итераций до точности ε по этой норме имеет порядок $\sqrt{\kappa}\ln(1/\varepsilon)$.

ДОКАЗАТЕЛЬСТВО

Ошибка $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ удовлетворяет

$$\mathbf{e}_{k+1} = \bigl(\mathbf{I} - \alpha\mathbf{A} + \beta\mathbf{I}\bigr)\mathbf{e}_k - \beta\mathbf{e}_{k-1},$$

потому что $f'(\mathbf{x}_k) = \mathbf{A}\mathbf{e}_k$ и $\mathbf{e}_{-1} = \mathbf{e}_0$. В собственном базисе координата u_k с собственным значением λ подчиняется

$$u_{k+1} = (1 + \beta - \alpha\lambda)u_k - \beta u_{k-1}.$$

Характеристическое уравнение

$$r^2 - (1 + \beta - \alpha\lambda)r + \beta = 0.$$

Произведение корней равно β. Достаточно показать, что дискриминант на $[\mu,L]$ неположителен: тогда корни комплексно сопряжены или совпадают, и модуль каждого равен $\sqrt{\beta}$.

Проверка на концах: $\alpha = 4/(\mu(\sqrt{\kappa}+1)^2)$ и $\beta = (\sqrt{\kappa}-1)^2/(\sqrt{\kappa}+1)^2$, так что $\sqrt{\beta} = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$. Сумма

$$1 + \beta = \frac{2(\kappa+1)}{(\sqrt{\kappa}+1)^2}.$$

Вычитание $\alpha\mu = 4/(\sqrt{\kappa}+1)^2$ даёт

$$1 + \beta - \alpha\mu = \frac{2(\kappa-1)}{(\sqrt{\kappa}+1)^2} = 2\sqrt{\beta}.$$

Вычитание $\alpha L = 4\kappa/(\sqrt{\kappa}+1)^2$ даёт $1 + \beta - \alpha L = -2\sqrt{\beta}$. Коэффициент $1 + \beta - \alpha\lambda$ линеен по λ и пробегает $[-2\sqrt{\beta},2\sqrt{\beta}]$, когда λ пробегает $[\mu,L]$. Дискриминант $(1 + \beta - \alpha\lambda)^2 - 4\beta \leqslant 0$.

Внутри интервала корни различны, решение есть $\sqrt{\beta}^k$, умноженное на ограниченную комбинацию синуса и косинуса. На концах корень двукратный, $r = \pm\sqrt{\beta}$, и общее решение имеет вид $(a + bk)r^k$. Начальные условия $u_{-1} = u_0$ фиксируют a и b линейно через u_0. В ортонормированном базисе евклидова норма складывается из координат, и появляется множитель $C(1+k)\sqrt{\beta}^k$.

Пусть $\rho = \sqrt{\beta}$. Неравенство $(1+k)\rho^k \leqslant \varepsilon$ выполняется, как только

$$k \geqslant \frac{\ln(1/\varepsilon)}{-\ln\rho} + \frac{\ln(1+k)}{-\ln\rho}.$$

Второе слагаемое растёт медленнее первого. Поскольку $-\ln\rho = -\ln\bigl(1 - 2/(\sqrt{\kappa}+1)\bigr)$ имеет порядок $2/\sqrt{\kappa}$, ведущий член — порядка $\sqrt{\kappa}\ln(1/\varepsilon)$.

ЗАМЕЧАНИЕ

Множитель $(1+k)\rho^k$ в начале траектории может расти. Отношение соседних членов больше единицы, пока $k + 2 < 1/(1-\rho)$. При большом κ это окно имеет длину

порядка $\sqrt{\kappa}/2$. Поэтому и $\|\mathbf{x}_k - \mathbf{x}^*\|$, и $f(\mathbf{x}_k)$ могут сначала вырасти: спектральный радиус описывает асимптотику, а не монотонность с первого шага. У градиентного спуска с шагом $1/L$ такого окна нет, значение f убывает на каждом шаге.

СЛЕДСТВИЕ

При $\kappa = 1$ параметры Поляка дают $\beta = 0$ и $\alpha = 1/L$: метод совпадает с градиентным спуском. При $\kappa > 1$ шаг α больше $1/L$. Его отношение к границе устойчивости градиентного спуска $2/L$ равно

$$\frac{\alpha}{2/L} = \frac{2}{\left(1 + \kappa^{-1/2}\right)^2}$$

и при большом κ близко к двум. Инерция как раз и позволяет взять шаг длиннее этой границы.

ЗАМЕЧАНИЕ

Вне квадратичной задачи

Пара α,β подобрана по постоянной матрице $\mathbf{A}$. Lessard, Recht, Packard (SIOPT, 2016) строят гладкую сильно выпуклую функцию с $\kappa = 25$, на которой тяжёлый шарик с этими параметрами имеет цикл периода 3 и к минимуму не сходится. Спектральный радиус квадратичной модели на этот пример не переносится.

Если $0 \leqslant \beta < 1$ и шаг уменьшить до $0 < \alpha \leqslant (1 - \beta)/L$, сходимость на выпуклой L-гладкой функции возвращается. Ghadimi, Feyzmahdavian, Johansson (arXiv:1412.7457) доказывают для такого шага скорость порядка $1/k$, того же порядка, что у градиентного спуска. Множителя $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ при этом уже нет: его даёт шаг длины около $4/L$, а не $(1 - \beta)/L$.

5. НЕСТЕРОВ, ИЗВЕСТНЫ L И μ

Схема со слайда: $\mathbf{x}_{-1} = \mathbf{x}_0$,

$$\mathbf{y}_k = \mathbf{x}_k + \beta(\mathbf{x}_k - \mathbf{x}_{k-1}), \qquad \mathbf{x}_{k+1} = \mathbf{y}_k - \frac{1}{L} f'(\mathbf{y}_k), \qquad \beta = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}. \tag{3}$$

Ниже $\alpha = 1/\sqrt{\kappa} = \sqrt{\mu/L}$, так что $\beta = (1 - \alpha)/(1 + \alpha)$. Коэффициент β тяжёлого шарика — квадрат этого числа. Доказательство держится на вспомогательной точке, которая собирается из двух последних итераций и отдельно не хранится:

$$\mathbf{z}_k = \mathbf{x}_k + \frac{1 - \alpha}{\alpha}(\mathbf{x}_k - \mathbf{x}_{k-1}), \qquad \mathbf{z}_0 = \mathbf{x}_0. \tag{4}$$

ЛЕММА 5

Для схемы (3) и точки (4)

$$\mathbf{y}_k = \frac{\mathbf{x}_k + \alpha \mathbf{z}_k}{1 + \alpha},$$

и та же последовательность $\mathbf{z}_k$ удовлетворяет

$$\mathbf{z}_{k+1} = (1 - \alpha)\mathbf{z}_k + \alpha \mathbf{y}_k - \frac{\alpha}{\mu} f'(\mathbf{y}_k).$$

ДОКАЗАТЕЛЬСТВО

Из (4) разность $\mathbf{x}_k - \mathbf{x}_{k-1}$ равна $\frac{\alpha}{1-\alpha}(\mathbf{z}_k - \mathbf{x}_k)$. Коэффициент перед ней в формуле $\mathbf{y}_k$ равен

$$\beta \cdot \frac{\alpha}{1-\alpha} = \frac{1-\alpha}{1+\alpha} \cdot \frac{\alpha}{1-\alpha} = \frac{\alpha}{1+\alpha}.$$

Поэтому

$$\mathbf{y}_k = \mathbf{x}_k + \frac{\alpha}{1+\alpha}(\mathbf{z}_k - \mathbf{x}_k) = \frac{\mathbf{x}_k + \alpha\mathbf{z}_k}{1+\alpha}.$$

Точка, которую формула (4) назначает на следующем шаге,

$$\mathbf{z}_{k+1} = \mathbf{x}_{k+1} + \frac{1-\alpha}{\alpha}(\mathbf{x}_{k+1} - \mathbf{x}_k) = \frac{1}{\alpha}\mathbf{x}_{k+1} - \frac{1-\alpha}{\alpha}\mathbf{x}_k.$$

Подстановка $\mathbf{x}_{k+1} = \mathbf{y}_k - \mathbf{g}_k/L$, $\mathbf{g}_k = f'(\mathbf{y}_k)$, даёт

$$\mathbf{z}_{k+1} = \frac{1}{\alpha}\mathbf{y}_k - \frac{1-\alpha}{\alpha}\mathbf{x}_k - \frac{1}{\alpha L}\mathbf{g}_k.$$

Первые два слагаемых равны $(1-\alpha)\mathbf{z}_k + \alpha\mathbf{y}_k$. В одну сторону, после подстановки $\mathbf{y}_k$,

$$\frac{1}{\alpha}\mathbf{y}_k - \frac{1-\alpha}{\alpha}\mathbf{x}_k = \frac{\mathbf{x}_k + \alpha\mathbf{z}_k}{\alpha(1+\alpha)} - \frac{1-\alpha}{\alpha}\mathbf{x}_k = \frac{\alpha\mathbf{x}_k + \mathbf{z}_k}{1+\alpha},$$

потому что коэффициент при $\mathbf{x}_k$ упрощается так:

$$\frac{1}{\alpha(1+\alpha)} - \frac{1-\alpha}{\alpha} = \frac{1-(1-\alpha^2)}{\alpha(1+\alpha)} = \frac{\alpha^2}{\alpha(1+\alpha)} = \frac{\alpha}{1+\alpha}.$$

В другую сторону

$$(1-\alpha)\mathbf{z}_k + \alpha\mathbf{y}_k = (1-\alpha)\mathbf{z}_k + \frac{\alpha}{1+\alpha}\mathbf{x}_k + \frac{\alpha^2}{1+\alpha}\mathbf{z}_k = \frac{\alpha\mathbf{x}_k + \mathbf{z}_k}{1+\alpha},$$

где коэффициент при $\mathbf{z}_k$ равен $(1-\alpha)(1+\alpha) + \alpha^2 = 1$, делённому на $1+\alpha$. Остаётся множитель при градиенте. Из $\alpha^2 = \mu/L$ следует $1/(\alpha L) = \alpha/\mu$.

ЛЕММА 6

Пусть f дифференцируема и μ-сильно выпукла, $\mathbf{g} = f'(\mathbf{y})$. Тогда для любого $\mathbf{w}$

$$f(\mathbf{y}) \leqslant f(\mathbf{w}) + \langle \mathbf{g}, \mathbf{y} - \mathbf{w} \rangle - \tfrac{\mu}{2}\|\mathbf{y} - \mathbf{w}\|^2. \tag{5}$$

Если к тому же f L-гладкая и $\mathbf{x}_+ = \mathbf{y} - \mathbf{g}/L$, то

$$f(\mathbf{x}_+) \leqslant f(\mathbf{y}) - \tfrac{1}{2L}\|\mathbf{g}\|^2. \tag{6}$$

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость в точке $\mathbf{y}$:

$$f(\mathbf{w}) \geqslant f(\mathbf{y}) + \langle \mathbf{g}, \mathbf{w} - \mathbf{y} \rangle + \tfrac{\mu}{2}\|\mathbf{w} - \mathbf{y}\|^2.$$

Перенос $f(\mathbf{y})$ влево даёт (5).

L-гладкость параболу, которая является оценкой сверху. Подстановка шага $\mathbf{x}_+ - \mathbf{y} = -\mathbf{g}/L$ приводит к

$$f(\mathbf{x}_+) \leqslant f(\mathbf{y}) + \langle \mathbf{g}, -\mathbf{g}/L\rangle + \tfrac{L}{2}\|\mathbf{g}/L\|^2 = f(\mathbf{y}) - \tfrac{1}{2L}\|\mathbf{g}\|^2,$$

и это (6).

ЛЕММА 7

Пусть f L-гладкая и μ-сильно выпуклая, $\mathbf{g} = f'(\mathbf{y})$ и $\mathbf{x}_+ = \mathbf{y} - \mathbf{g}/L$. Тогда для любого $\mathbf{w}$

$$f(\mathbf{x}_+) \leqslant f(\mathbf{w}) + \langle \mathbf{g}, \mathbf{y} - \mathbf{w}\rangle - \tfrac{\mu}{2}\|\mathbf{y} - \mathbf{w}\|^2 - \tfrac{1}{2L}\|\mathbf{g}\|^2.$$

ДОКАЗАТЕЛЬСТВО

Оценка (5) даёт первые три члена для $f(\mathbf{y})$. Оценка (6) добавляет $-\|\mathbf{g}\|^2/(2L)$.

ТЕОРЕМА 6

Пусть f L-гладкая и μ-сильно выпуклая, минимум $\mathbf{x}^*$ существует, шаг и β взяты из (3). Тогда

$$f(\mathbf{x}_k) - f^* \leqslant L\left(1 - \frac{1}{\sqrt{\kappa}}\right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|^2.$$

Более точная постоянная в той же оценке — $(L+\mu)/2$ вместо L. Точность ε по значению функции достигается при

$$k \geqslant \sqrt{\kappa}\,\ln\bigl(LR^2/\varepsilon\bigr).$$

ДОКАЗАТЕЛЬСТВО

Положим

$$V_k = f(\mathbf{x}_k) - f^* + \tfrac{\mu}{2}\|\mathbf{z}_k - \mathbf{x}^*\|^2.$$

Достаточно доказать $V_{k+1} \leqslant (1-\alpha)V_k$. Пишем $\mathbf{g} = f'(\mathbf{y}_k)$, $\mathbf{x}_+ = \mathbf{x}_{k+1}$, $\mathbf{z} = \mathbf{z}_k$, $\mathbf{y} = \mathbf{y}_k$ и $\mathbf{z}_+ = \mathbf{z}_{k+1}$.

Лемму о шаге применяем дважды: в точке $\mathbf{w} = \mathbf{x}_k$ с весом $1-\alpha$ и в точке $\mathbf{w} = \mathbf{x}^*$ с весом α. Выпуклая комбинация сохраняет неравенство:

$$\begin{aligned} f(\mathbf{x}_+) - f^* \leqslant{}& (1-\alpha)\bigl(f(\mathbf{x}_k) - f^*\bigr) \\ &+ \bigl\langle \mathbf{g}, (1-\alpha)(\mathbf{y} - \mathbf{x}_k) + \alpha(\mathbf{y} - \mathbf{x}^*)\bigr\rangle \\ &- \tfrac{\mu}{2}\Bigl((1-\alpha)\|\mathbf{y} - \mathbf{x}_k\|^2 + \alpha\|\mathbf{y} - \mathbf{x}^*\|^2\Bigr) - \tfrac{1}{2L}\|\mathbf{g}\|^2. \end{aligned} \tag{7}$$

Рекурсия для $\mathbf{z}$ даёт

$$\mathbf{z}_+ - \mathbf{x}^* = (1-\alpha)(\mathbf{z} - \mathbf{x}^*) + \alpha(\mathbf{y} - \mathbf{x}^*) - \frac{\alpha}{\mu}\mathbf{g}.$$

Квадрат нормы раскрывается в три члена. Умножение на $\mu/2$ превращает перекрёстный член в

$$-\alpha\bigl\langle (1-\alpha)(\mathbf{z} - \mathbf{x}^*) + \alpha(\mathbf{y} - \mathbf{x}^*), \mathbf{g}\bigr\rangle,$$

а член с $\|\mathbf{g}\|^2$ — в $\alpha^2\|\mathbf{g}\|^2/(2\mu) = \|\mathbf{g}\|^2/(2L)$, где снова $\alpha^2 = \mu/L$.

Этот перекрёстный член гасится скалярным произведением из (7). Для этого нужно тождество

$$(1-\alpha)(\mathbf{y}-\mathbf{x}_k)+\alpha(\mathbf{y}-\mathbf{x}^*)=\alpha\big((1-\alpha)(\mathbf{z}-\mathbf{x}^*)+\alpha(\mathbf{y}-\mathbf{x}^*)\big).$$

Оно проверяется подстановкой $\mathbf{y}=(\mathbf{x}_k+\alpha\mathbf{z})/(1+\alpha)$. Тогда $\mathbf{y}-\mathbf{x}_k=\frac{\alpha}{1+\alpha}(\mathbf{z}-\mathbf{x}_k)$ и $\mathbf{y}-\mathbf{x}^*=\frac{1}{1+\alpha}(\mathbf{x}_k-\mathbf{x}^*)+\frac{\alpha}{1+\alpha}(\mathbf{z}-\mathbf{x}^*)$. Правая часть равна

$$\alpha(1-\alpha)(\mathbf{z}-\mathbf{x}^*)+\frac{\alpha^2}{1+\alpha}(\mathbf{x}_k-\mathbf{x}^*)+\frac{\alpha^3}{1+\alpha}(\mathbf{z}-\mathbf{x}^*).$$

Коэффициент при $\mathbf{z}-\mathbf{x}^*$ упрощается до $\alpha/(1+\alpha)$, и правая часть совпадает с

$$\frac{\alpha^2}{1+\alpha}(\mathbf{x}_k-\mathbf{x}^*)+\frac{\alpha}{1+\alpha}(\mathbf{z}-\mathbf{x}^*).$$

Левая часть равна

$$\alpha(\mathbf{y}-\mathbf{x}^*)+\frac{\alpha(1-\alpha)}{1+\alpha}(\mathbf{z}-\mathbf{x}_k).$$

После подстановки $\mathbf{y}$ коэффициент при $\mathbf{x}_k-\mathbf{x}^*$ равен $\alpha/(1+\alpha)-\alpha(1-\alpha)/(1+\alpha)=\alpha^2/(1+\alpha)$, а коэффициент при $\mathbf{z}-\mathbf{x}^*$ равен $\alpha^2/(1+\alpha)+\alpha(1-\alpha)/(1+\alpha)=\alpha/(1+\alpha)$. Части совпадают. Члены $\|\mathbf{g}\|^2/(2L)$ тоже взаимно уничтожаются. Остаётся

$$\begin{aligned}V_{k+1}\leqslant{}&(1-\alpha)\big(f(\mathbf{x}_k)-f^*\big)+\tfrac{\mu}{2}\|(1-\alpha)(\mathbf{z}-\mathbf{x}^*)+\alpha(\mathbf{y}-\mathbf{x}^*)\|^2\\&-\tfrac{\mu}{2}(1-\alpha)\|\mathbf{y}-\mathbf{x}_k\|^2-\tfrac{\mu\alpha}{2}\|\mathbf{y}-\mathbf{x}^*\|^2.\end{aligned}\tag{8}$$

Обозначим $\mathbf{u}=\mathbf{z}-\mathbf{x}^*$, $\mathbf{v}=\mathbf{x}_k-\mathbf{x}^*$ и $\mathbf{w}=\mathbf{u}-\mathbf{v}=\mathbf{z}-\mathbf{x}_k$. Тогда

$$\mathbf{y}-\mathbf{x}^*=\frac{\mathbf{v}+\alpha\mathbf{u}}{1+\alpha}=\mathbf{u}-\frac{\mathbf{w}}{1+\alpha},\qquad \mathbf{y}-\mathbf{x}_k=\frac{\alpha}{1+\alpha}\mathbf{w},$$

и

$$(1-\alpha)\mathbf{u}+\alpha(\mathbf{y}-\mathbf{x}^*)=\mathbf{u}-\frac{\alpha}{1+\alpha}\mathbf{w}.$$

Подстановка в разность между правой частью (8) и $(1-\alpha)(\mu/2)\|\mathbf{u}\|^2$ сводится к выражению

$$E=\Big\|\mathbf{u}-\frac{\alpha}{1+\alpha}\mathbf{w}\Big\|^2-(1-\alpha)\|\mathbf{u}\|^2-(1-\alpha)\Big\|\frac{\alpha}{1+\alpha}\mathbf{w}\Big\|^2-\alpha\Big\|\mathbf{u}-\frac{\mathbf{w}}{1+\alpha}\Big\|^2.$$

Раскрытие даёт нулевые коэффициенты при $\|\mathbf{u}\|^2$ и при $\langle\mathbf{u},\mathbf{w}\rangle$. Коэффициент при $\|\mathbf{w}\|^2$ равен

$$\frac{\alpha^2-(1-\alpha)\alpha^2-\alpha}{(1+\alpha)^2}=\frac{\alpha(\alpha^2-1)}{(1+\alpha)^2}=-\frac{\alpha(1-\alpha)}{1+\alpha}.$$

Значит $E=-\frac{\alpha(1-\alpha)}{1+\alpha}\|\mathbf{z}-\mathbf{x}_k\|^2\leqslant 0$, и $V_{k+1}\leqslant(1-\alpha)V_k$.

Отсюда $V_k\leqslant(1-\alpha)^kV_0$. В начале $\mathbf{z}_0=\mathbf{x}_0$, поэтому

$$V_0=\Delta_0+\tfrac{\mu}{2}R^2\leqslant\tfrac{L}{2}R^2+\tfrac{\mu}{2}R^2=\tfrac{L+\mu}{2}R^2\leqslant LR^2.$$

Зазор $f(\mathbf{x}_k) - f^*$ не превосходит V_k. Поскольку $1 - \alpha \leqslant e^{-\alpha}$, неравенство $L(1-\alpha)^k R^2 \leqslant \varepsilon$ выполнено при $k \geqslant \alpha^{-1} \ln\bigl(LR^2/\varepsilon\bigr)$.

ПРИМЕР 1

На слайде $L = 10$, $R = 1$, $\mu = 1$, $\kappa = 10$, допуск 10^{-4}. Оценка теоремы даёт $10\,(1 - 1/\sqrt{10})^k \leqslant 10^{-4}$. Здесь $1 - 1/\sqrt{10} \approx 0{,}684$, $\ln\bigl(10^5\bigr) \approx 11{,}51$, $-\ln(0{,}684) \approx 0{,}380$, частное около $30{,}3$. Достаточно $k \geqslant 31$. Более точная постоянная $(L+\mu)/2 = 5{,}5$ уменьшает этот бюджет ещё немного; слайд оставляет множитель L.

ЗАМЕЧАНИЕ

Множитель $1 - 1/\sqrt{\kappa} = 1 - \alpha$ слабее множителя сопряжённых градиентов $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1) = 1 - 2/(\sqrt{\kappa} + 1)$: в показателе экспоненты стоит $1/\sqrt{\kappa}$, а не $2/\sqrt{\kappa}$. Зато в доказательстве использованы только L-гладкость и μ-сильная выпуклость. Квадрат гессиана и подпространство Крылова не нужны.

6. НЕСТЕРОВ, μ НЕИЗВЕСТНА

Схема со слайда: $t_0 = 1$, $\mathbf{y}_0 = \mathbf{x}_0$,

$$\begin{aligned} \mathbf{x}_{k+1} &= \mathbf{y}_k - \frac{1}{L} f'(\mathbf{y}_k), \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\ \mathbf{y}_{k+1} &= \mathbf{x}_{k+1} + \frac{t_k - 1}{t_{k+1}} (\mathbf{x}_{k+1} - \mathbf{x}_k). \end{aligned} \tag{9}$$

При $k = 0$ коэффициент $(t_0 - 1)/t_1 = 0$: первый шаг совпадает с градиентным.

ЛЕММА 8

Последовательность t_k удовлетворяет $t_{k+1}(t_{k+1} - 1) = t_k^2$ и $t_k \geqslant (k+2)/2$. В частности, $t_{k-1} \geqslant (k+1)/2$ при $k \geqslant 1$.

ДОКАЗАТЕЛЬСТВО

Из формулы шага $2t_{k+1} - 1 = \sqrt{1 + 4t_k^2}$. Возведение в квадрат даёт $t_{k+1}^2 - t_{k+1} = t_k^2$. Дальше

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2} \geqslant \frac{1 + 2t_k}{2} = t_k + \tfrac{1}{2},$$

поэтому $t_k \geqslant t_0 + k/2 = (k+2)/2$.

Коэффициент $(t_k - 1)/t_{k+1}$ стремится к единице, потому что t_k растёт линейно. В начале инерция нулевая, потом метод разгоняется.

ЛЕММА 9

Пусть f выпуклая и L-гладкая, $\mathbf{g} = f'(\mathbf{y})$ и $\mathbf{x}_+ = \mathbf{y} - \mathbf{g}/L$. Тогда для любого $\mathbf{u}$

$$f(\mathbf{x}_+) \leqslant f(\mathbf{u}) + \tfrac{L}{2}\Bigl(\|\mathbf{y} - \mathbf{u}\|^2 - \|\mathbf{x}_+ - \mathbf{u}\|^2\Bigr).$$

ДОКАЗАТЕЛЬСТВО

Выпуклость даёт $f(\mathbf{y}) \leqslant f(\mathbf{u}) + \langle \mathbf{g}, \mathbf{y} - \mathbf{u} \rangle$. Лемма о спуске даёт $f(\mathbf{x}_+) \leqslant f(\mathbf{y}) - \|\mathbf{g}\|^2/(2L)$. Правая часть совпадает с заявленной, потому что

$$\tfrac{L}{2}\Bigl(\|\mathbf{y} - \mathbf{u}\|^2 - \|\mathbf{y} - \mathbf{u} - \mathbf{g}/L\|^2\Bigr) = \langle \mathbf{g}, \mathbf{y} - \mathbf{u} \rangle - \tfrac{1}{2L}\|\mathbf{g}\|^2.$$

ТЕОРЕМА 7

Пусть f выпуклая и L-гладкая, минимум $\mathbf{x}^*$ достигается, итерация задана формулой (9). Тогда при $k \geqslant 1$

$$f(\mathbf{x}_k) - f^* \leqslant \frac{2L\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{(k+1)^2}.$$

ДОКАЗАТЕЛЬСТВО

Пишем $\delta(\mathbf{x}) = f(\mathbf{x}) - f^*$ и $\mathbf{g}_k = f'(\mathbf{y}_k)$. Для $k \geqslant 1$ введём

$$\mathbf{u}_k = t_{k-1}(\mathbf{x}_k - \mathbf{x}^*) - (t_{k-1} - 1)(\mathbf{x}_{k-1} - \mathbf{x}^*).$$

При $k = 1$ множитель $t_0 - 1$ равен нулю, так что $\mathbf{u}_1 = \mathbf{x}_1 - \mathbf{x}^*$. Формула инерции для $\mathbf{y}_k$, $k \geqslant 1$, переписывается так:

$$t_k(\mathbf{y}_k - \mathbf{x}^*) = (t_k - 1)(\mathbf{x}_k - \mathbf{x}^*) + \mathbf{u}_k. \tag{10}$$

Действительно, $\mathbf{y}_k = \mathbf{x}_k + \frac{t_{k-1}-1}{t_k}(\mathbf{x}_k - \mathbf{x}_{k-1})$, и умножение на t_k собирает в точности правую часть. Отсюда же

$$\mathbf{u}_{k+1} = t_k(\mathbf{x}_{k+1} - \mathbf{x}^*) - (t_k - 1)(\mathbf{x}_k - \mathbf{x}^*) = \mathbf{u}_k - \frac{t_k}{L}\mathbf{g}_k,$$

потому что $\mathbf{x}_{k+1} = \mathbf{y}_k - \mathbf{g}_k/L$ и $t_k(\mathbf{y}_k - \mathbf{x}^*)$ заменяется по (10).

Лемму о шаге применяем в точках $\mathbf{u} = \mathbf{x}_k$ и $\mathbf{u} = \mathbf{x}^*$. Первое неравенство умножаем на $t_k - 1$, второе оставляем с весом 1, затем умножаем сумму на t_k и пользуемся $t_k(t_k - 1) = t_{k-1}^2$:

$$\begin{aligned} t_k^2\,\delta(\mathbf{x}_{k+1}) \leqslant\; & t_{k-1}^2\,\delta(\mathbf{x}_k) \\ & + \tfrac{L}{2}\,t_k\Big((t_k - 1)\|\mathbf{y}_k - \mathbf{x}_k\|^2 + \|\mathbf{y}_k - \mathbf{x}^*\|^2 \\ & \quad - (t_k - 1)\|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \|\mathbf{x}_{k+1} - \mathbf{x}^*\|^2\Big). \end{aligned} \tag{11}$$

Скобка, умноженная на t_k, равна $\|\mathbf{u}_k\|^2 - \|\mathbf{u}_{k+1}\|^2$. Чтобы это увидеть, сдвинем $\mathbf{x}^*$ в нуль; общий случай отличается только параллельным переносом. Тогда $\mathbf{u}_k = t_k\mathbf{y}_k - (t_k - 1)\mathbf{x}_k$ и $\mathbf{u}_{k+1} = t_k\mathbf{x}_{k+1} - (t_k - 1)\mathbf{x}_k$, и

$$\begin{aligned} &\|\mathbf{u}_k\|^2 - \|\mathbf{u}_{k+1}\|^2 \\ &\quad = t_k^2\|\mathbf{y}_k\|^2 - t_k^2\|\mathbf{x}_{k+1}\|^2 - 2t_k(t_k - 1)\langle \mathbf{y}_k - \mathbf{x}_{k+1}, \mathbf{x}_k\rangle. \end{aligned}$$

Та же величина получается раскрытием

$$t_k\Big((t_k - 1)\|\mathbf{y}_k - \mathbf{x}_k\|^2 + \|\mathbf{y}_k\|^2 - (t_k - 1)\|\mathbf{x}_{k+1} - \mathbf{x}_k\|^2 - \|\mathbf{x}_{k+1}\|^2\Big).$$

Подстановка в (11) даёт

$$t_k^2\,\delta(\mathbf{x}_{k+1}) + \tfrac{L}{2}\|\mathbf{u}_{k+1}\|^2 \leqslant t_{k-1}^2\,\delta(\mathbf{x}_k) + \tfrac{L}{2}\|\mathbf{u}_k\|^2.$$

Левая часть — величина ϕ_{k+1}, правая — ϕ_k, если положить

$$\phi_k = t_{k-1}^2\,\delta(\mathbf{x}_k) + \tfrac{L}{2}\|\mathbf{u}_k\|^2, \qquad k \geqslant 1.$$

Неравенство $\phi_{k+1} \leqslant \phi_k$ доказано для $k \geqslant 1$.

Начальное значение считается отдельно, первым градиентным шагом. Лемма о шаге в точке $\mathbf{x}^*$ при $\mathbf{y}_0 = \mathbf{x}_0$ даёт

$$\delta(\mathbf{x}_1) \leqslant \tfrac{L}{2}\Big(R^2 - \|\mathbf{x}_1 - \mathbf{x}^*\|^2\Big),$$

то есть $\phi_1 = \delta(\mathbf{x}_1) + \tfrac{L}{2}\|\mathbf{u}_1\|^2 \leqslant \tfrac{L}{2}R^2$.

Для всех $k \geqslant 1$ получаем $\phi_k \leqslant \phi_1 \leqslant LR^2/2$. Отбрасывание неотрицательного квадрата оставляет

$$\delta(\mathbf{x}_k) \leqslant \frac{LR^2}{2t_{k-1}^2} \leqslant \frac{LR^2}{2} \cdot \frac{4}{(k+1)^2} = \frac{2LR^2}{(k+1)^2},$$

где использовано $t_{k-1} \geqslant (k+1)/2$.

ПРИМЕР 2

При $L = 10$, $R = 1$ и допуске 10^{-4} неравенство $2LR^2/(k+1)^2 \leqslant 10^{-4}$ превращается в $(k+1)^2 \geqslant 2 \cdot 10^5$. Тогда $k+1 \geqslant \sqrt{2 \cdot 10^5} \approx 447{,}2$, то есть $k+1 \geqslant 448$. Градиентный спуск на той же выпуклой задаче требует $T \geqslant LR^2/(2\varepsilon) = 5 \cdot 10^4$. Уменьшение допуска в 100 раз умножает бюджет Нестерова на 10, а бюджет градиентного спуска — на 100.

ЗАМЕЧАНИЕ

Проверка L

Лемма о спуске с шагом $1/L$ — это в точности неравенство со слайда

$$f\left(\mathbf{y} - \frac{1}{L}f'(\mathbf{y})\right) \leqslant f(\mathbf{y}) - \frac{1}{2L}\|f'(\mathbf{y})\|^2.$$

Если пробная константа меньше настоящей константы Липшица градиента, проверка может не пройти. Удвоение L, пока проверка не выполнена, за конечное число попыток даёт допустимый шаг: настоящая константа Липшица конечна. Завышенная L шаг только укорачивает. Заниженная L, при которой проверка уже не выполняется, верхнюю параболу леммы о спуске не соблюдает, и обе теоремы этого раздела на такой шаг не опираются.

ЗАМЕЧАНИЕ

Рестарт

На сильно выпуклой функции схема с растущим t_k сохраняет оценку $1/k^2$, но не переключается сама на множитель $1 - 1/\sqrt{\kappa}$. O'Donoghue, Candès (FoCM, 2015) показывают, что перезапуск этой схемы с фиксированным периодом порядка $\sqrt{\kappa}$ возвращает линейную скорость с корнем из κ. Чтобы не подставлять μ в длину периода, они перезапускают метод по ходу траектории. Правило со слайда — их градиентный тест: если

$$\langle f'(\mathbf{y}_k), \mathbf{x}_k - \mathbf{x}_{k-1}\rangle > 0,$$

инерция смотрит в одну сторону с градиентом в упреждённой точке. Тогда полагают $t_k = 1$ и $\mathbf{y}_k = \mathbf{x}_k$, и разгон начинается заново. Статья объясняет, почему период порядка $\sqrt{\kappa}$ достаточен; сам тест μ не использует. Имеет смысл хранить точку с наименьшим уже посчитанным значением f: последняя итерация схемы с t_k не обязана быть лучшей на траектории.

Что почитать

- J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed. Springer, 2006, глава 5. Линейный метод, теорема 5.5 о скорости, нелинейные формулы Флетчера — Ривса, Полака — Рибьера и Хестенса — Стифеля, практические константы Вульфа.
- Б. Т. Поляк. *Некоторые методы ускорения сходимости итерационных методов.* ЖВМ и МФ, 1964, т. 4, № 5. Тяжёлый шарик и параметры, при которых спектральный радиус равен $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$.
- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.2. Оценки $1/k^2$ и $1-1/\sqrt{\kappa}$; на слайдах разобраны схемы из этого параграфа.
- B. O'Donoghue, E. Candès. *Adaptive Restart for Accelerated Gradient Schemes.* Foundations of Computational Mathematics, 2015. Рестарт с периодом порядка $\sqrt{\kappa}$ и градиентный тест, который этот период заменяет.
- L. Lessard, B. Recht, A. Packard. *Analysis and Design of Optimization Algorithms via Integral Quadratic Constraints.* SIAM Journal on Optimization, 2016. Пример с $\kappa = 25$, на котором параметры Поляка зацикливаются.
- E. Ghadimi, H. R. Feyzmahdavian, M. Johansson. *Global convergence of the Heavy-ball method for convex optimization.* 2015, arXiv:1412.7457. Шаг $\alpha \leqslant (1-\beta)/L$ возвращает скорость порядка $1/k$.
- I. Sutskever, J. Martens, G. Dahl, G. Hinton. *On the importance of initialization and momentum in deep learning.* ICML, 2013. Моментум в обучении сетей — та же двухточечная рекурсия, что у тяжёлого шарика, с фиксированным β около $0{,}9$. Это не пара (α,β) из формулы Поляка: μ и L мини-батча в шаг не подставляются.