ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Ускоренные градиентные методы. Идея метода сопряжённых градиентов

МЕТОДЫ ОПТИМИЗАЦИИ

НЕДЕЛЯ 8

План лекции

1. Почему градиентного спуска не хватает
2. Метод сопряжённых градиентов
3. Метод тяжёлого шарика
4. Ускоренный метод Нестерова
5. Какой из трёх запускать

Где градиентный спуск тратит итерации

На неделе 7 для L-гладкой f и шага $\alpha = 1/L$, $\kappa = L/\mu$ получили следующие оценки сходимости:

- выпуклая задача, $R = \|\mathbf{x}_0 - \mathbf{x}^*\|$:

$$f(\mathbf{x}_T) - f^* \le \frac{LR^2}{2T}.$$

  Достижение точности ε стоит $T \ge LR^2/(2\varepsilon)$ итераций.

- μ-сильно выпуклая, $\Delta_0 = f(\mathbf{x}_0) - f^*$: зазор умножается на $1 - 1/\kappa$,

$$f(\mathbf{x}_T) - f^* \le \left(1 - \frac{1}{\kappa}\right)^T \Delta_0.$$

  Достижение точности ε стоит $T \ge \kappa \log(\Delta_0/\varepsilon)$ итераций.

Что меняют методы этой лекции

Пусть целевая функция такова, что $\kappa = 10^4$. Ниже — сколько итераций нужно, чтобы умножить ошибку на $1/e$.

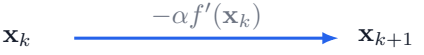
Метод	Множитель	Итераций для уменьшения ошибки в $1/e$ раз
Градиентный спуск, шаг $1/L$	$1 - 1/\kappa$	$\kappa = 10^4$
Лучший постоянный шаг, $2/(L+\mu)$	$(\kappa-1)/(\kappa+1)$	$\kappa/2 = 5 \cdot 10^3$
Нестеров	$1 - 1/\sqrt{\kappa}$	$\sqrt{\kappa} = 10^2$
Сопряжённые градиенты, тяжёлый шарик	$(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$	$\sqrt{\kappa}/2 = 50$

- На квадратичной сильно выпуклой задаче все три метода сегодняшней лекции убирают корень из κ.
- На классе гладких сильно выпуклых задач так умеет только метод Нестерова.

Общая идея

Градиентный спуск строит точку только из $\mathbf{x}_k$ и $f'(\mathbf{x}_k)$. Ускорение появляется, когда шаг помнит предыдущее направление.

градиентный спуск



тяжёлый шарик



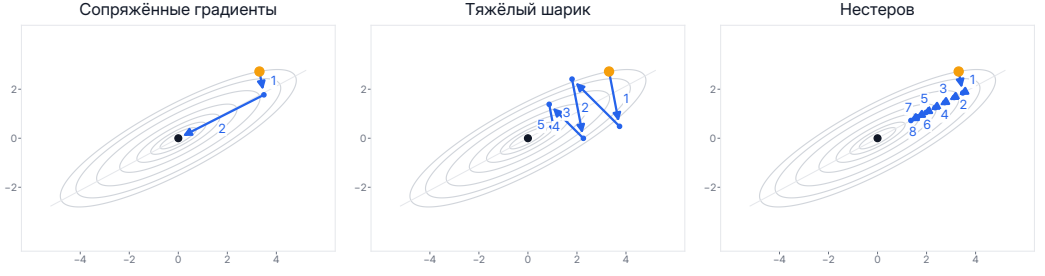
Нестеров



Сопряжённые градиенты помнят направление иначе: следующий вектор $\mathbf{A}$-ортогонален предыдущим. Для этого задача должна быть квадратичной.

Пример

Линии уровня $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x}$, собственные значения 1 и 16. Старт в точке $(4{,}2;\ 0{,}85)$ — оранжевая точка, минимум — чёрная. Номер около стрелки — номер итерации.



- Сопряжённые градиенты попадают в минимум за две итерации.
- Тяжёлый шарик по очереди бьёт в противоположные стенки.
- Метод Нестерова укорачивает шаги вдоль дна оврага и не перескакивает через стенку.

Квадратичная задача

$$f(\mathbf{x}) \;=\; \tfrac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}, \qquad \mathbf{A} = \mathbf{A}^\top \succ 0.$$

Минимум совпадает с решением $\mathbf{A}\mathbf{x} = \mathbf{b}$. Градиент $\mathbf{g}(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ — невязка с обратным знаком.

- Одна итерация требует одного умножения на $\mathbf{A}$. Саму матрицу хранить не нужно: достаточно процедуры «вектор на вход, $\mathbf{A}\mathbf{v}$ на выход».
- Собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\kappa = L/\mu$.
- Сюда попадают нормальные уравнения, система в методе Ньютона и любой квадратичный штраф с положительным гессианом.

Схема метода сопряжённых градиентов

$\mathbf{g}_0 = \mathbf{A}\mathbf{x}_0 - \mathbf{b}$, $\mathbf{d}_0 = -\mathbf{g}_0$. Дальше

$$\alpha_k = \frac{\|\mathbf{g}_k\|^2}{\mathbf{d}_k^\top \mathbf{A}\mathbf{d}_k}, \qquad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k,$$

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \alpha_k \mathbf{A}\mathbf{d}_k, \qquad \beta_k = \frac{\|\mathbf{g}_{k+1}\|^2}{\|\mathbf{g}_k\|^2},$$

$$\mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k.$$

- α_k — точный минимум f вдоль $\mathbf{d}_k$. Отдельного линейного поиска нет.
- Умножение $\mathbf{A}\mathbf{d}_k$ используется и в шаге, и в невязке: второй раз его не считают.
- Хранятся три вектора: точка, невязка, направление.

Что верно после каждого шага

Пока арифметика точная и $\mathbf{g}_k \neq \mathbf{0}$:

- градиенты ортогональны: $\langle \mathbf{g}_{k+1}, \mathbf{g}_j \rangle = 0$ при $j \leq k$;
- направления сопряжены: $\mathbf{d}_i^{\top} \mathbf{A} \mathbf{d}_j = 0$ при $i \neq j$;
- $f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$, и $\mathbf{x}_{k+1}$ — минимум f на $\mathbf{x}_0 + \operatorname{span}\{\mathbf{d}_0, \ldots, \mathbf{d}_k\}$.

Конечная остановка

В $\mathbb{R}^n$ ненулевых попарно ортогональных градиентов не больше n. Значит, $\mathbf{g}_m = \mathbf{0}$ при некотором $m \leq n$, и $\mathbf{x}_m = \mathbf{x}^*$. На размерностях 10^5–10^7 до n не доходят: останавливаются по невязке раньше.

Теорема: скорость до остановки

Теорема

Пусть собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mu > 0$, $\kappa = L/\mu$. Тогда

$$\|\mathbf{x}_k - \mathbf{x}^*\|_{\mathbf{A}} \;\le\; 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^{k} \|\mathbf{x}_0 - \mathbf{x}^*\|_{\mathbf{A}},$$

где $\|\mathbf{v}\|_{\mathbf{A}} = \sqrt{\mathbf{v}^\top \mathbf{A}\mathbf{v}}$. В точной арифметике дополнительно $\mathbf{x}_n = \mathbf{x}^*$.[1]

- Для этой f зазор по значению — та же величина: $f(\mathbf{x}) - f^* = \tfrac{1}{2}\|\mathbf{x} - \mathbf{x}^*\|_{\mathbf{A}}^2$.
- Множитель совпадает с оптимальным множителем тяжёлого шарика и примерно вдвое выгоднее, чем $1 - 1/\sqrt{\kappa}$ у Нестерова.

[1] J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed., теорема 5.5.

Как читать множитель

$$\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} \;=\; 1-\frac{2}{\sqrt{\kappa}+1} \;\approx\; e^{-2/\sqrt{\kappa}}.$$

- При $\kappa = 10^4$ множитель равен $99/101 \approx 0{,}980$. Ошибка в $\mathbf{A}$-норме уменьшается в e раз примерно за 50 итераций. У градиентного спуска с шагом $1/L$ на это уходит 10^4 итераций.
- Оценка зависит от спектра только через κ. Если собственные значения собраны в несколько кластеров, метод заканчивает работу быстрее оценки: каждое новое направление учитывает кластер целиком.

Что смотреть при запуске

- Критерий остановки — относительная невязка $\|\mathbf{g}_k\| / \|\mathbf{g}_0\|$.
- $\|\mathbf{g}_k\|$ может вырасти от шага к шагу. Монотонно убывает f, то есть $\mathbf{A}$-норма ошибки. Рост невязки сам по себе — не повод для рестарта.
- В машинной арифметике ортогональность постепенно теряется, конечная остановка пропадает.
- Для наименьших квадратов матрица $\mathbf{X}^\top \mathbf{X}$ имеет квадрат числа обусловленности $\mathbf{X}$. Явные нормальные уравнения портят задачу ещё до первого шага. Умножение на $\mathbf{X}^\top \mathbf{X}$ считают двумя умножениями, на $\mathbf{X}$ и на $\mathbf{X}^\top$, не собирая матрицу.

Когда брать метод сопряжённых градиентов

- Система $\mathbf{Ax} = \mathbf{b}$ большая, $\mathbf{A}$ симметричная и положительно определённая, и есть быстрое умножение на $\mathbf{A}$. Это основной солвер такого класса: разреженные системы; операторы из физики; гессиан, заданный произведением простых матриц.
- Система Ньютона, когда гессиан не собирают, а умеют умножать на вектор. Внутри шага Ньютона сопряжённые градиенты останавливают раньше времени: невязка Ньютона не обязана быть машинным нулём.
- Параметры α и β метод находит сам. Знать μ и L для запуска не нужно: они входят только в теорему.

Нелинейные сопряжённые градиенты

Та же рекурсия, если заменить $\mathbf{A}\mathbf{d}_k$ и точный α_k линейным поиском. $\mathbf{d}_0 = -f'(\mathbf{x}_0)$,

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k, \qquad \mathbf{d}_{k+1} = -f'(\mathbf{x}_{k+1}) + \beta_k \mathbf{d}_k.$$

α_k — шаг по условиям Вульфа вдоль $\mathbf{d}_k$.

$$\beta_k^{\mathrm{PR}} = \frac{\langle f'(\mathbf{x}_{k+1}),\, f'(\mathbf{x}_{k+1}) - f'(\mathbf{x}_k)\rangle}{\|f'(\mathbf{x}_k)\|^2}.$$

- Рабочий вариант — метод Полака — Рибьера с границей для β: $\beta_k = \max\{\beta_k^{\mathrm{PR}}, 0\}$. Отрицательный β означает, что старое направление уже мешает, и его отбрасывают.
- Необходимо хранить два-три вектора. Метод остаётся выбором, когда лишних векторов нет, градиент точный и линейный поиск приемлем.

Зачем инерция

- Тяжёлый шарик добавляет к градиентному шагу долю предыдущего перемещения. Вдоль дна эти доли складываются. Поперёк стенки они смотрят в разные стороны и гасят друг друга.
- Метод Бориса Поляка, 1964. На квадратичной задаче он получает тот же множитель, что и сопряжённые градиенты, но хранит только предыдущую точку: сопряжённые направления и умножение на $\mathbf{A}$ не нужны.
- Цена простоты: μ и L входят в формулы шага. Ошиблись в них — множитель теоремы больше не действует.

Схема и параметры

$$\mathbf{x}_{k+1} \;=\; \mathbf{x}_k - \alpha f'(\mathbf{x}_k) + \beta(\mathbf{x}_k - \mathbf{x}_{k-1}), \qquad \mathbf{x}_{-1} = \mathbf{x}_0.$$

На квадратичной f с собственными значениями в $[\mu, L]$ параметры Поляка

$$\alpha \;=\; \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \qquad \beta \;=\; \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^2.$$

- При большом κ шаг $\alpha \approx 4/L$. Это вдвое больше границы устойчивости градиентного спуска. Инерция как раз и удерживает такой шаг.
- При $\kappa = 1$ получается $\beta = 0$ и $\alpha = 1/L$: метод совпадает с градиентным спуском.
- Эквивалентная запись через скорость: $\mathbf{v}_{k+1} = \beta\mathbf{v}_k - \alpha f'(\mathbf{x}_k)$, $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{v}_{k+1}$, $\mathbf{v}_0 = \mathbf{0}$.

Теорема: квадратичная функция

Теорема

Пусть $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}$ и собственные значения $\mathbf{A}$ лежат в $[\mu, L]$, $\mu > 0$. С параметрами на предыдущем слайде спектральный радиус равен

$$\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Число итераций до достижения точности ε имеет порядок $\sqrt{\kappa}\,\log(1/\varepsilon)$.[2]

- Это асимптотика и $\|\mathbf{x}_k - \mathbf{x}^*\|$ может сначала вырасти.
- На системе $\mathbf{A}\mathbf{x} = \mathbf{b}$ сопряжённые градиенты практичнее: тот же порядок, конечная остановка и никакого μ на входе. Тяжёлый шарик короче в коде, когда умножения на $\mathbf{A}$ нет, а есть только градиент, и κ уже оценено.

[2] Б. Т. Поляк. *Некоторые методы ускорения сходимости итерационных методов.* ЖВМ и МФ, 1964, т. 4, №5.

За пределами квадратичной задачи

Параметры предыдущей теоремы подобраны по спектру постоянной матрицы $\mathbf{A}$.

- На гладкой сильно выпуклой функции, которая квадратичной не является, те же α и β сходимости не гарантируют. Есть пример с $\kappa = 25$: итерация зацикливается на трёх точках и к минимуму не идёт.[3]
- Если взять шаг порядка $(1 - \beta)/L$, сходимость на гладкой выпуклой функции возвращается. Доказанная скорость при этом уже порядка градиентного спуска, без $\sqrt{\kappa}$.
- Практическое правило: формула Поляка — для квадратичной модели и для окрестности минимума, где гессиан почти постоянен. На всём классе гладких выпуклых функций берётся метод Нестерова.

[3] L. Lessard, B. Recht, A. Packard. *Analysis and Design of Optimization Algorithms via Integral Quadratic Constraints.* SIAM J. Optimization, 2016.

Градиент после упреждения

У тяжёлого шарика градиент считается в $\mathbf{x}_k$, а инерция используется для итогового шага.

- Нестеров сначала делает упреждение $\mathbf{y}_k = \mathbf{x}_k + \beta(\mathbf{x}_k - \mathbf{x}_{k-1})$ и только потом считает градиент в $\mathbf{y}_k$.
- Если инерция уже проскочила минимум, градиент в упреждённой точке смотрит назад и уменьшает шаг до того, как точка туда попала.
- Эта перестановка, вместе с другим β и шагом $1/L$, даёт теорему на всём классе L-гладких выпуклых функций. Квадратичность не нужна, достаточно L-гладкости.

Схема, когда известны L и μ

$$\begin{aligned} \mathbf{y}_k &= \mathbf{x}_k + \beta(\mathbf{x}_k - \mathbf{x}_{k-1}), \\ \mathbf{x}_{k+1} &= \mathbf{y}_k - \frac{1}{L} f'(\mathbf{y}_k), \end{aligned} \qquad \beta = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}, \qquad \mathbf{x}_{-1} = \mathbf{x}_0.$$

- Шаг всегда $1/L$, как у градиентного спуска на неделе 7.
- β тяжёлого шарика — квадрат этого коэффициента. При $\kappa = 10^4$ здесь $\beta \approx 0{,}980$, у Поляка $\beta \approx 0{,}961$.

Теорема: L-гладкая и μ-сильно выпуклая

Теорема

Пусть f L-гладкая и μ-сильно выпуклая, $\kappa = L/\mu$, шаг равен $1/L$, а $\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$. Тогда

$$f(\mathbf{x}_k) - f^* \;\le\; L\left(1 - \frac{1}{\sqrt{\kappa}}\right)^{k} \|\mathbf{x}_0 - \mathbf{x}^*\|^2.$$

Достижение точности ε по значению функции происходит за $k \ge \sqrt{\kappa}\,\log\bigl(LR^2/\varepsilon\bigr)$ итераций[4].

- На неделе 7 в той же задаче стояло κ вместо $\sqrt{\kappa}$.
- Множитель $1 - 1/\sqrt{\kappa}$ чуть слабее, чем $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$ у сопряжённых градиентов. Зато теорема не требует квадратичной f.

[4] Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.2.

Схема, когда μ неизвестна

Постоянный β без μ брать не из чего. Коэффициент меняется по шагам и μ не использует. $t_0 = 1$, $\mathbf{y}_0 = \mathbf{x}_0$:

$$\mathbf{x}_{k+1} = \mathbf{y}_k - \frac{1}{L} f'(\mathbf{y}_k),$$
$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2},$$
$$\mathbf{y}_{k+1} = \mathbf{x}_{k+1} + \frac{t_k - 1}{t_{k+1}} (\mathbf{x}_{k+1} - \mathbf{x}_k).$$

- При $k = 0$ коэффициент $(t_0 - 1)/t_1 = 0$: первый шаг снова градиентный.
- t_k растёт как $k/2$, поэтому коэффициент $(t_k - 1)/t_{k+1}$ стремится к единице. В начале метод осторожный, потом разгоняется.
- Это схема для L-гладкой выпуклой задачи. Если μ на самом деле положительно, постоянный β из предыдущего слайда сходится быстрее, но только при точном знании μ.

Теорема: выпуклая L-гладкая функция

Теорема

Пусть f выпуклая и L-гладкая, минимум достигается, шаг равен $1/L$, коэффициент инерции считается через t_k. Тогда при $k \geq 1$

$$f(\mathbf{x}_k) - f^* \;\leq\; \frac{2L\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{(k+1)^2}.$$

- Порядок $1/k^2$. У градиентного спуска на том же классе — $1/k$.
- Уменьшить точность в 100 раз значит увеличить бюджет в 10 раз, а не в 100.

Те же числа, что на неделе 7

Выпуклая задача, $L = 10$, $R = 1$, точность 10^{-4} по значению функции.

- Градиентный спуск: $LR^2/(2T) \le 10^{-4}$ даёт $T \ge 5 \cdot 10^4$.
- Нестеров: $2LR^2/(k+1)^2 \le 10^{-4}$ даёт $k + 1 \ge \sqrt{2 \cdot 10^5} \approx 448$.

Сильно выпуклая задача, те же $L = 10$, $R = 1$, $\mu = 1$, так что $\kappa = 10$.

- Градиентный спуск с шагом $1/L$: около 108 итераций, как на неделе 7.
- Нестеров: $10\,(1 - 1/\sqrt{10})^k \le 10^{-4}$ даёт $k \ge 31$.

При $\kappa = 10$ выигрыш умеренный. Он становится кратным, когда κ — тысячи: отношение бюджетов растёт как $\sqrt{\kappa}$.

Как запускать

- L завышена — шаг $1/L$ короче нужного, оценка просто становится хуже, сходимость остаётся. L занижена — верхняя парабола с недели 7 уже не верхняя, и метод может разойтись.
- Если L неизвестна, её увеличивают, пока не выполнено убывание модели:

$$f\left(\mathbf{y} - \frac{1}{L} f'(\mathbf{y})\right) \;\leq\; f(\mathbf{y}) - \frac{1}{2L}\|f'(\mathbf{y})\|^2.$$

  Это то же неравенство, что лемма о спуске. Обычно L удваивают, пока проверка не пройдёт, и иногда уменьшают между итерациями.
- Схема с t_k на сильно выпуклой функции характерно колеблется. Практический рестарт: если $\langle f'(\mathbf{y}_k),\, \mathbf{x}_k - \mathbf{x}_{k-1}\rangle > 0$, инерция смотрит против градиента. Тогда полагают $t_k = 1$ и $\mathbf{y}_k = \mathbf{x}_k$. Так $\sqrt{\kappa}$ часто получается без знания μ[5].
- Имеет смысл хранить точку с наименьшим значением f. Последняя итерация схемы с t_k не всегда лучшая на траектории.

[5] B. O'Donoghue, E. Candès. *Adaptive Restart for Accelerated Gradient Schemes.* Foundations of Computational Mathematics, 2015.

Когда брать метод Нестерова

- f гладкая и выпуклая, градиент точный, гессиан недоступен или слишком дорог. Нужна скорость лучше $1/k$ и быстрая реализация.
- μ достоверно известна — можно использовать постоянный β. μ неизвестна — используется схема с t_k и рестарт по скалярному произведению.

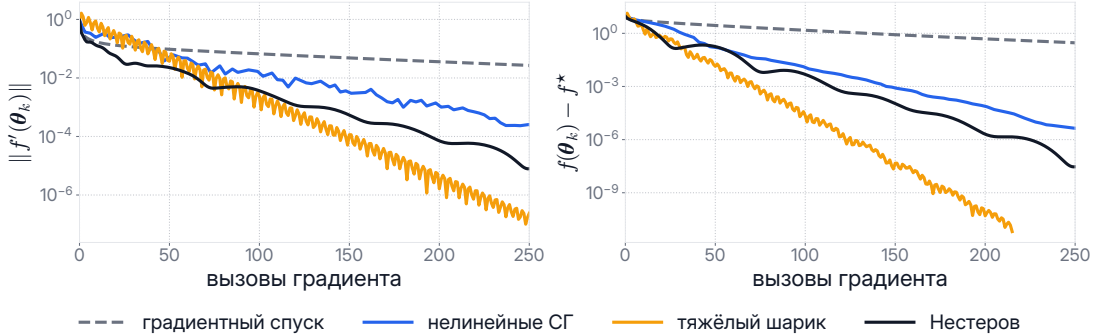
Обзор методов

Метод	Вход	Гарантия
Сопряжённые градиенты	умножение на $\mathbf{A} \succ 0$	$(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$, $\leq n$
Тяжёлый шарик	f', μ, L	тот же множитель
Нестеров, μ известна	f', μ, L	$1 - 1/\sqrt{\kappa}$
Нестеров, μ неизвестна	f', L	$2LR^2/(k+1)^2$

Первые две строки — только квадратичная задача. Третья — гладкая сильно выпуклая, четвёртая — гладкая выпуклая.

Одна логистическая задача

Сумма $\log\left(1 + e^{-y_i \mathbf{x}_i^\top \boldsymbol{\theta}}\right)$ и штраф $\frac{\mu}{2}\|\boldsymbol{\theta}\|^2$. Выборка $m = 120$, $n = 20$, старт в нуле, $\kappa = L/\mu = 100$, $L = \frac{1}{4}\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) + \mu$. $f^\star$ — оптимум той же задачи в `cvxpy`.



По горизонтали — число вызовов градиента. У градиентного спуска и Нестерова шаг $1/L$ и один градиент на итерацию; Нестеров считает его в упреждённой точке. Тяжёлый шарик с формулой Поляка на этой выборке быстрее всех, и норма градиента у него колеблется. Нелинейные сопряжённые градиенты — Полак — Рибьер с шагом по Вульфу: на одну итерацию уходит несколько вызовов.

Как выбрать метод

1. Система с положительно определённой симметричной матрицей и честным умножением на неё.
2. Гладкая выпуклая задача, доступен только градиент, нужна доказанная скорость. Нестеров с шагом $1/L$. Без надёжного μ — растущий коэффициент t_k и рестарт. Занижать L нельзя!
3. Квадратичная модель с уже известными μ и L, умножения на матрицу нет. Тяжёлый шарик с формулой Поляка.

Что запомнить

- Узкое место градиентного спуска на овраге — множитель $1 - 1/\kappa$. Методы из этой лекции заменяют его величиной порядка $1 - 1/\sqrt{\kappa}$.
- Сопряжённые градиенты — метод для квадратичной положительно определённой задачи. Точный шаг, конечная остановка, скорость $\sqrt{\kappa}$ ещё до неё. Невязка не монотонна, значение функции монотонно.
- Тяжёлый шарик с параметрами Поляка даёт ту же асимптотику на квадратичной задаче и тот же код, что моментум в стохастическом градиенте. На общем гладком сильно выпуклом классе эти параметры могут зациклиться.
- Нестеров считает градиент в упреждённой точке. Выпуклая задача: $2LR^2/(k+1)^2$. Сильно выпуклая: $1 - 1/\sqrt{\kappa}$. Из трёх методов лишь эти оценки действуют на всей гладкой выпуклой задаче, а не только на квадратичной.

Источники

- J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed. Springer, 2006, глава 5.
- Б. Т. Поляк. *Некоторые методы ускорения сходимости итерационных методов.* ЖВМ и МФ, 1964, т. 4, №5.
- Y. Nesterov. *Lectures on Convex Optimization*. Springer, 2018, §2.2.
- B. O'Donoghue, E. Candès. *Adaptive Restart for Accelerated Gradient Schemes.* Foundations of Computational Mathematics, 2015.
- L. Lessard, B. Recht, A. Packard. *Analysis and Design of Optimization Algorithms via Integral Quadratic Constraints.* SIAM Journal on Optimization, 2016.
- I. Sutskever, J. Martens, G. Dahl, G. Hinton. *On the importance of initialization and momentum in deep learning.* ICML, 2013.

Дальше

- Методы второго порядка: шаг Ньютона использует гессиан, а не только спектр через κ.
- Та же система Ньютона большой размерности решается методом сопряжённых градиентов.
- Квазиньютоновские методы с ограниченной памятью — практический сосед нелинейных сопряжённых градиентов, когда гессиан недоступен, а несколько прошлых шагов хранить можно.

