ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Метод Ньютона и квазиньютоновские методы

МЕТОДЫ ОПТИМИЗАЦИИ

НЕДЕЛЯ 9

План лекции

1. Шаг Ньютона из квадратичной модели
2. Тот же метод для нелинейных уравнений и фрактал Ньютона
3. Локальная сходимость классического метода Ньютона
4. Расходимость, если точка старта далёка от минимума
5. Демпфированный метод Ньютона
6. Квазиньютоновские методы. BFGS
7. Когда размерность очень большая: L-BFGS
8. Что из этого запускать

Что меняется по сравнению с неделей 8

Градиентный спуск, тяжёлый шарик и Нестеров строят шаг из градиента и одного числа: $1/L$ или κ. Гессиан туда входит только своими предельными собственными значениями μ и L.

- Метод Ньютона подставляет в модель весь $f''(\mathbf{x}_k)$, а не оценку сверху $L\mathbf{I}$.
- На квадратичной задаче с положительно определённой матрицей модель совпадает с f. Один шаг попадает в минимум.
- Платить приходится линейной системой размера n. При небольшом n её факторизуют на каждом шаге. При большом n ту же систему решают итерационно: это домашнее задание.

Квадратичная модель в текущей точке

В точке $\mathbf{x}_k$ функция дважды дифференцируема. Для приращения $\mathbf{d}$

$$m_k(\mathbf{d}) = f(\mathbf{x}_k) + \langle \mathbf{g}_k, \mathbf{d} \rangle + \tfrac{1}{2}\mathbf{d}^\top \mathbf{H}_k \mathbf{d},$$

где $\mathbf{g}_k = f'(\mathbf{x}_k)$ и $\mathbf{H}_k = f''(\mathbf{x}_k)$.

- Это многомерная формула Тейлора, остаток — третьи производные на $\|\mathbf{d}\|^3$.
- Если $\mathbf{H}_k \succ 0$, у параболоида один минимум. Его градиент по $\mathbf{d}$ в точке минимума равен нулю и поэтому мы можем найти направление:

$$\mathbf{g}_k + \mathbf{H}_k \mathbf{d} = \mathbf{0}, \qquad \mathbf{d}_k = -\mathbf{H}_k^{-1} \mathbf{g}_k.$$

Шаг Ньютона и шаг градиентного спуска

Классический метод Ньютона:

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k = \mathbf{x}_k - f''(\mathbf{x}_k)^{-1} f'(\mathbf{x}_k).$$

Градиентный спуск минимизирует другую модель:

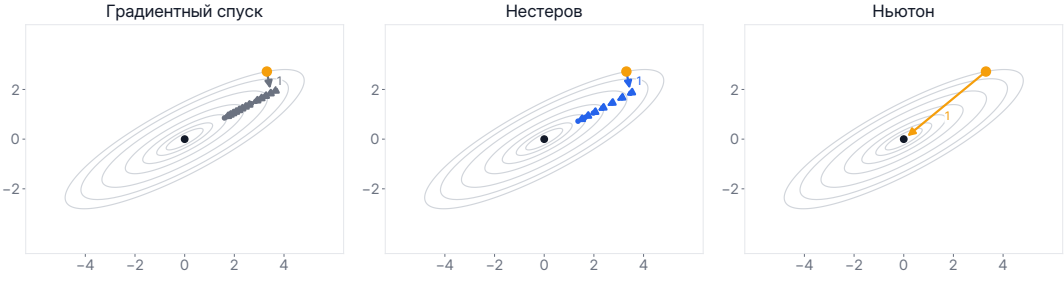
$$f(\mathbf{x}_k) + \langle \mathbf{g}_k, \mathbf{d} \rangle + \frac{1}{2\alpha} \|\mathbf{d}\|^2.$$

Её минимум — $\mathbf{d} = -\alpha \mathbf{g}_k$.

- При $\alpha = 1/L$ сфера опирается на худшую кривизну так как $f''(\mathbf{x}_k) \preceq L\mathbf{I}$
- Метод Ньютона берёт кривизну по каждому направлению свою.

Один шаг на квадратичной задаче

Та же функция, что на неделе 8: $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x}$, собственные значения 1 и 16. Оранжевая точка — старт, чёрная — минимум.



- Градиентный спуск с шагом $1/L$ за одну итерацию оказывается на дне оврага и дальше медленно колеблется между его сенками.
- Метод Нестерова уменьшает число итераций, но их по-прежнему несколько.
- Модель в методе Ньютона совпадает с f, поэтому направление спуска на первом шаге сразу приводит в минимум.

Та же формула для системы уравнений

Для $F(\mathbf{x}) = \mathbf{0}$ с обратимым якобианом метод Ньютона —

$$\mathbf{x}_{k+1} = \mathbf{x}_k - F'(\mathbf{x}_k)^{-1} F(\mathbf{x}_k).$$

Если подставить сюда $F = f'$, то $F' = f''$, и формула совпадает с шагом из квадратичной модели.

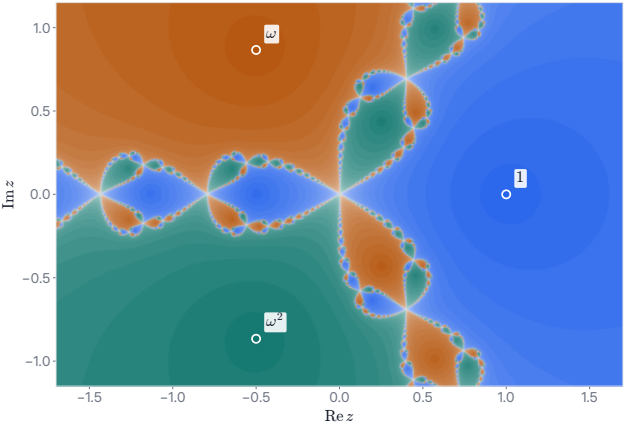
- Ищется стационарная точка $f'(\mathbf{x}) = \mathbf{0}$, не обязательно минимум.
- Линейная модель $F(\mathbf{x}_k) + F'(\mathbf{x}_k)\mathbf{d} = \mathbf{0}$ — то же самое, что условие минимума квадратичной модели m_k.

Чем два метода совпадают

- На каждой итерации одна линейная система с матрицей якобиана.
- Если в корне якобиан (гессиан) невырожден, а в окрестности липшицева, и старт достаточно близко, сходимость квадратичная: ошибка следующего шага порядка квадрата текущей.
- Если точка старта далека от решения, гарантий сходимости нет. Множество точек, из которых итерация приходит в данный корень, может быть устроено гораздо сложнее шара. Это так называемый фрактал Ньютона.

Фрактал Ньютона для $z^3 = 1$

Три корня: 1, ω, ω^2. Цвет — к какому корню сошёлся метод.



A. Cayley, *The Newton–Fourier imaginary problem*, Amer. J. Math. 2 (1879); P. Blanchard, *The Dynamics of Newton's Method*, AMS, 1994.

Что на фрактале важно для оптимизации

- Вокруг каждого корня есть открытый участок своего цвета: это и есть «достаточно близко» из теоремы о квадратичной сходимости.
- Граница между цветами — не гладкая кривая. В любой окрестности точки на границе встречаются старты всех трёх цветов.
- Для $F = f'$ картина та же. Близость к минимуму в евклидовой норме не гарантирует, что полный шаг Ньютона останется в его бассейне.
- Отсюда два разных утверждения: локально полный шаг сходится очень быстро, но глобально его надо дополнительно проверять.

Отличия задачи минимизации и поиска корня

- Якобиан F' не обязан быть симметричным. Гессиан симметричен всегда. В строгом локальном минимуме $f''(\mathbf{x}^*) \succ 0$, и
$$\langle \mathbf{g}, \mathbf{d} \rangle = -\mathbf{g}^\top f''(\mathbf{x})^{-1}\mathbf{g} < 0.$$
- Корень $f' = \mathbf{0}$ бывает минимумом, максимумом или седлом. Метод для уравнений их не различает.
- У минимизации есть функция заслуги f: по ней укорачивают шаг. У системы уравнений заслуга — норма невязки $\|F\|$.

Классический метод

Классический метод Ньютона — это шаг на каждой итерации вида

$$\mathbf{x}_{k+1} = \mathbf{x}_k - f''(\mathbf{x}_k)^{-1} f'(\mathbf{x}_k).$$

Отдельного размера шага α_k нет: в координатах модели он уже равен единице.

- Если $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}$ и $\mathbf{A} \succ 0$, то $\mathbf{x}_1 = \mathbf{x}^*$ из любой точки.
- На неквадратичной функции тот же шаг законен только там, где модель ещё похожа на f.

Теорема: квадратичная сходимость

Теорема

Пусть $f'(\mathbf{x}^*) = \mathbf{0}$, матрица $f''(\mathbf{x}^*)$ обратима, а f'' липшицева в окрестности $\mathbf{x}^*$: $\|f''(\mathbf{x}) - f''(\mathbf{y})\| \le M\|\mathbf{x} - \mathbf{y}\|$. Тогда найдётся $\varepsilon > 0$ такое, что при $\|\mathbf{x}_0 - \mathbf{x}^*\| < \varepsilon$ итерация определена и

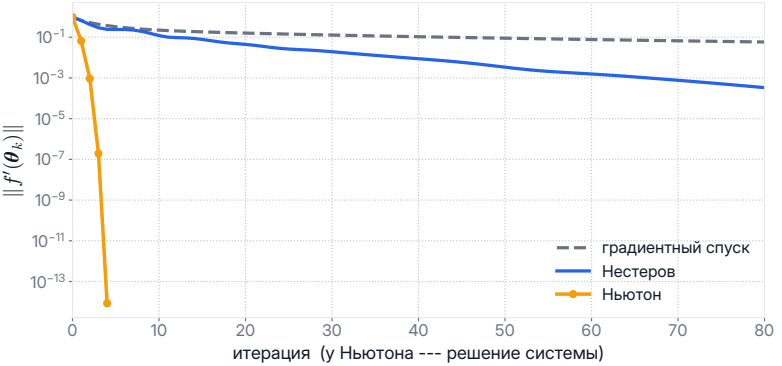
$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\| \le C\|\mathbf{x}_k - \mathbf{x}^*\|^2.$$

Если дополнительно $f''(\mathbf{x}^*) \succ 0$, предел — строгий локальный минимум.[1]

[1] J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed., теорема 3.5.

Как выглядит квадратичная фаза

Регуляризованная логистическая регрессия, $m = 250$, $n = 40$, $\kappa = L/\mu = 200$, старт в нуле.



- Норма градиента: $9{,}9 \cdot 10^{-1}$, $6{,}6 \cdot 10^{-2}$, $9{,}3 \cdot 10^{-4}$, $1{,}9 \cdot 10^{-7}$, $8{,}5 \cdot 10^{-15}$.
- За те же 80 итераций градиентный спуск доходит до $5{,}8 \cdot 10^{-2}$, метод Нестерова — до $3{,}3 \cdot 10^{-4}$.

Цена одной итерации

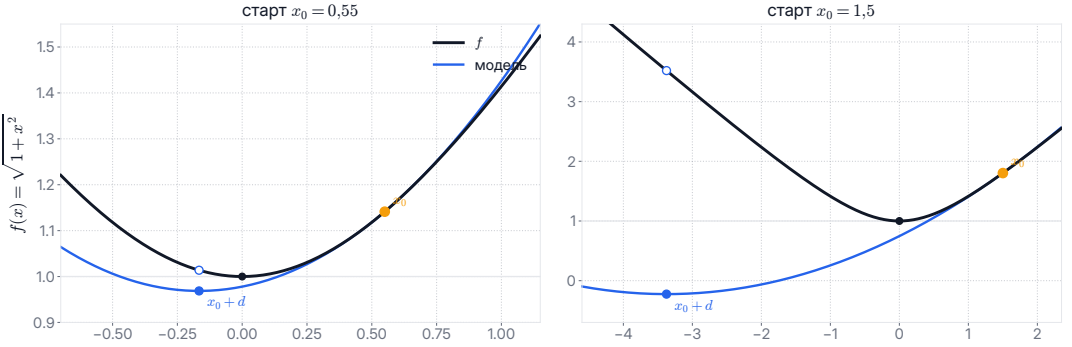
Один шаг метода Ньютона — факторизация плотного гессиана. Разложение Холецкого стоит порядка $n^3/3$ операций, решение двух треугольных систем после — порядка n^2. Хранится n^2 чисел.

	память	факторизация
$n = 10^3$	8 МБ	$3 \cdot 10^8$
$n = 10^4$	800 МБ	$3 \cdot 10^{11}$
$n = 10^5$	80 ГБ	$3 \cdot 10^{14}$

- На прошлом рисунке $n = 40$: пять факторизаций — около 10^5 операций. Матрица помещается в кэш.
- Та же схема при $n = 10^4$ дороже в $(10^4/40)^3 = 250^3 \approx 1{,}6 \cdot 10^7$ раз за каждый шаг.
- При $n = 10^5$ матрица занимает 80 ГБ, и плотный гессиан уже не факторизуют.

Модель точна локально и неверна вдали

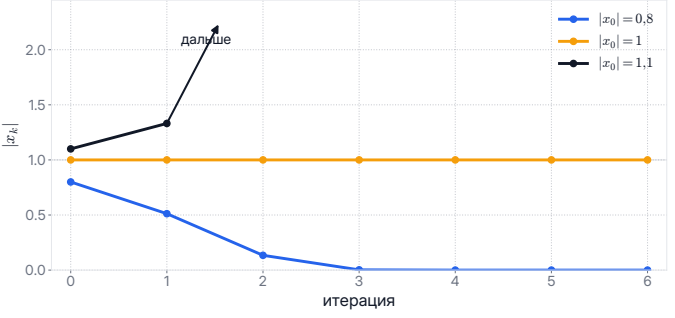
Синяя кривая — квадратичная модель в оранжевой точке. Залитый синий круг — её минимум, пустой — значение f в этой же точке.



- При $x_0 = 0{,}55$ модель чуть оптимистична, но предложенная точка ближе к нулю, и f убывает.
- При $x_0 = 1{,}5$ минимум модели лежит ниже $f^* = 1$, а f в точке $-3{,}375$ равно примерно $3{,}5$ против $f(1{,}5) \approx 1{,}8$ и шаг увеличивает функцию.

Три старта одной формулы

Функция $f(x) = \sqrt{1 + x^2}$. Полный шаг Ньютона на ней даёт итерацию $x_{k+1} = -x_k^3$. У расходящегося старта на рисунке видно только начало: дальше $|x_3| \approx 13$, затем тысячи.



- Гессиан положительно определён, минимум единственный, функция ограничена снизу.
- $\mathbf{H}_k \succ 0$ гарантирует спуск для бесконечно малого шага вдоль $\mathbf{d}_k$, не для $\alpha = 1$.
- Кривизна в старте может быть гораздо меньше, чем у минимума.
- Практический вывод: полный шаг пробуют первым, но оставляют себе право его укоротить.

Рецепт: демпфированный Ньютон

Пока норма градиента не мала:

1. Посчитать $\mathbf{g}_k$ и $\mathbf{H}_k$. Если $\mathbf{H}_k \not\succ 0$, заменить $\mathbf{H}_k$ на $\mathbf{H}_k + \tau\mathbf{I}$ так, чтобы наименьшее собственное значение стало положительным.
2. Решить $\mathbf{H}_k\mathbf{d}_k = -\mathbf{g}_k$.
3. Положить $\alpha = 1$. Пока нарушено условие Армихо, заменять α на $\alpha/2$.
4. Принять $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha\mathbf{d}_k$.

Сначала из любой точки, затем квадратично

Теорема

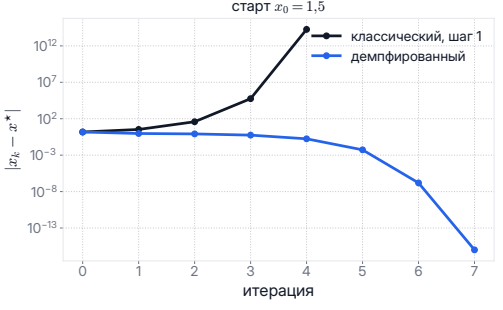
Пусть всюду $\mu \mathbf{I} \preceq f''(\mathbf{x}) \preceq L\mathbf{I}$ с $\mu > 0$ и гессиан липшицев. Тогда демпфированный Ньютон с пробой $\alpha = 1$ и условием Армихо из любой точки сходится к единственному минимуму. Начиная с некоторой итерации принимается $\alpha_k = 1$, и хвост сходимости квадратичный.[2]

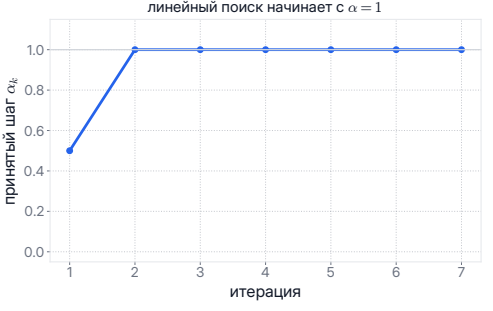
У $f(x) = \sqrt{1 + x^2}$ вторая производная убывает к нулю, так что $\mu = 0$ и теорема её не накрывает. Укорочение шага всё равно спасает этот пример.

[2] J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed., теорема 3.6.

Демпфирование делает сходимость глобальной

Та же $f(x) = \sqrt{1 + x^2}$, старт $x_0 = 1{,}5$.





- Классический метод: $1{,}5$, $-3{,}4$, 38, $-5{,}7 \cdot 10^{4}$, $1{,}8 \cdot 10^{14}$.
- Демпфированный принимает $\alpha_1 = 1/2$, дальше все шаги равны 1. Ошибка идёт $1{,}5$, $0{,}94$, $0{,}82$, $0{,}56$, $0{,}18$, $5 \cdot 10^{-3}$, $1{,}5 \cdot 10^{-7}$, $4 \cdot 10^{-21}$.

Идея квазиньютоновских методов

- Метод Ньютона требует $O(n^3)$ вычислений на каждой итерации
- Также необходимо хранить плотную матрицу $n \times n$

Нужна ли сама матрица для вычисления направления?

- Поиск направления — решение линейной системы
- Что можно записать как $[f''(\mathbf{x}_k)]^{-1}\,\mathbf{g}_k$
- Если у нас есть приближение $\mathbf{B}_k \approx f''(\mathbf{x}_k)$ такое что $\mathbf{H}_k = \mathbf{B}_k^{-1}$ можно вычислить аналитически, то достаточно обновлять эти оценки и умножать на них $\mathbf{g}_k$

Секущее уравнение

Шаг и приращение градиента:

$$\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k, \qquad \mathbf{y}_k = f'(\mathbf{x}_{k+1}) - f'(\mathbf{x}_k).$$

По формуле Ньютона — Лейбница

$$\mathbf{y}_k = \left(\int_0^1 f''(\mathbf{x}_k + t\mathbf{s}_k)\, dt \right) \mathbf{s}_k.$$

Средний гессиан вдоль шага переводит $\mathbf{s}_k$ в $\mathbf{y}_k$. Это и требуют от приближения:

$$\mathbf{B}_{k+1}\mathbf{s}_k = \mathbf{y}_k, \qquad \mathbf{H}_{k+1}\mathbf{y}_k = \mathbf{s}_k.$$

Для настоящей квадратичной функции равенство точное, и $\mathbf{B}$ совпадает с постоянным гессианом после накопления n независимых шагов.

Формула BFGS

Среди симметричных матриц, удовлетворяющих секущему уравнению, BFGS выбирает ближайшую к $\mathbf{B}_k$ в взвешенной норме Фробениуса. В коде обновляют обратную матрицу. При $\rho_k = 1/(\mathbf{y}_k^\top \mathbf{s}_k)$

$$\mathbf{H}_{k+1} = \left(\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^\top\right) \mathbf{H}_k \left(\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^\top\right) + \rho_k \mathbf{s}_k \mathbf{s}_k^\top .$$

- Обновление — две поправки ранга один. Стоимость порядка n^2, память тоже порядка n^2.
- Направление $\mathbf{d}_k = -\mathbf{H}_k \mathbf{g}_k$ после этого считается умножением, без факторизации.

Условия Вульфа и определённость

Если $\mathbf{H}_k \succ 0$ и $\mathbf{y}_k^{\top}\mathbf{s}_k > 0$, то и $\mathbf{H}_{k+1} \succ 0$. Тогда $\mathbf{d}_k$ — направление спуска.

- Условие Армихо кривизну $\mathbf{y}^{\top}\mathbf{s} > 0$ не обеспечивает. Его заменяют слабыми условиями Вульфа, $0 < c_1 < c_2 < 1$:

$$f(\mathbf{x} + \alpha\mathbf{d}) \le f(\mathbf{x}) + c_1\alpha\langle \mathbf{g}, \mathbf{d}\rangle,$$

$$\langle f'(\mathbf{x} + \alpha\mathbf{d}), \mathbf{d}\rangle \ge c_2\langle \mathbf{g}, \mathbf{d}\rangle.$$

- Отсюда $\mathbf{y}^{\top}\mathbf{s} \ge \alpha(c_2 - 1)\langle \mathbf{g}, \mathbf{d}\rangle > 0$. Обычный выбор: $c_1 = 10^{-4}$, $c_2 = 0{,}9$.
- Первую матрицу берут $\mathbf{H}_0 = \gamma\mathbf{I}$. После первого удачного шага масштаб $\gamma = (\mathbf{s}^{\top}\mathbf{y})/(\mathbf{y}^{\top}\mathbf{y})$ подгоняют под увиденную кривизну.

Сверхлинейная, не квадратичная

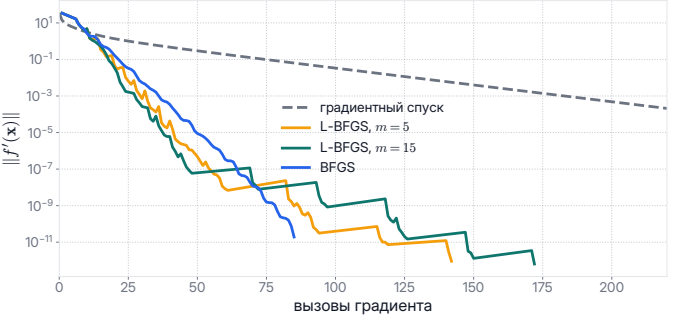
- Если с некоторого момента $\alpha_k = 1$ и

$$\frac{\left\| \left(\mathbf{B}_k - f''(\mathbf{x}^*) \right) \mathbf{s}_k \right\|}{\|\mathbf{s}_k\|} \to 0,$$

  скорость сверхлинейная: $\|\mathbf{x}_{k+1} - \mathbf{x}^*\| / \|\mathbf{x}_k - \mathbf{x}^*\| \to 0$.
- На квадратичной задаче с точным поиском вдоль прямой BFGS порождает сопряжённые направления и останавливается не позже n-го шага. Для такой задачи дешевле метод сопряжённых градиентов: три вектора вместо плотной матрицы.
- BFGS берут, когда гессиан меняется от точки к точке, а доступен только градиент.

BFGS и короткая память на одной задаче

$f(\mathbf{x}) = \sum_i \cosh x_i + \frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x}$, $n = 30$, $\kappa(f''(0)) \approx 25$, старт $0{,}8 \cdot \mathbf{1}$.



- BFGS доводит норму градиента до 10^{-11} за 85 вызовов. L-BFGS с $m = 5$ и $m = 15$ приходят туда же: пяти пар уже хватает.
- Плоские участки — несколько градиентов внутри одного поиска Вульфа. Норма градиента не обязана убывать на каждом вызове.
- Градиентный спуск с шагом $1/L$, $L = \cosh 0{,}8 + 25$, за 220 вызовов всё ещё около $2 \cdot 10^{-4}$.

Память плотной матрицы

BFGS хранит $\mathbf{H}_k$ явно.

	$n = 10^5$	$n = 10^6$
BFGS, n^2 чисел	80 ГБ	8 ТБ
L-BFGS, $m = 10$, $2mn$ чисел	16 МБ	160 МБ

- L-BFGS не собирает $\mathbf{H}_k$. Хранятся только последние m пар $(\mathbf{s}_i, \mathbf{y}_i)$. Обычный диапазон — $m = 5, \ldots, 20$.
- Направление по-прежнему $-\mathbf{H}_k \mathbf{g}_k$, но произведение считают из этих пар за один проход.

Что подставляют вместо начальной матрицы

В двух циклах ниже участвует только начальное приближение $\mathbf{H}_k^{(0)} = \gamma_k \mathbf{I}$,

$$\gamma_k = \frac{\mathbf{s}_{k-1}^\top \mathbf{y}_{k-1}}{\mathbf{y}_{k-1}^\top \mathbf{y}_{k-1}}.$$

- Если $\mathbf{y} \approx f''\mathbf{s}$, то $\mathbf{y}^\top\mathbf{y}/\mathbf{s}^\top\mathbf{y}$ — отношение Рэлея для гессиана. Значит, γ_k оценивает обратную кривизну вдоль последнего шага.
- Пока пар нет, направление равно $-\mathbf{g}$: это градиентный спуск с поиском Вульфа.

Два цикла: умножение на вектор без формирования матрицы

Пары занумерованы от старой к новой: $i = k - m, \dots, k - 1$, $\rho_i = 1/(\mathbf{y}_i^\top \mathbf{s}_i)$. Произведение $\mathbf{H}_k \mathbf{v}$:

1. $\mathbf{q} \leftarrow \mathbf{v}$.
2. Для $i = k-1, k-2, \dots, k-m$: $\alpha_i = \rho_i \mathbf{s}_i^\top \mathbf{q}$, затем $\mathbf{q} \leftarrow \mathbf{q} - \alpha_i \mathbf{y}_i$.
3. $\mathbf{r} \leftarrow \gamma_k \mathbf{q}$.
4. Для $i = k-m, \dots, k-1$: $\beta = \rho_i \mathbf{y}_i^\top \mathbf{r}$, затем $\mathbf{r} \leftarrow \mathbf{r} + \mathbf{s}_i(\alpha_i - \beta)$.

Результат $\mathbf{r}$ и есть $\mathbf{H}_k \mathbf{v}$. Направление шага — этот вектор при $\mathbf{v} = \mathbf{g}_k$, взятый со знаком минус.

- Циклы — та же рекурсия BFGS, развёрнутая для умножения на вектор.

Почему это быстро

- Первый цикл — m скалярных произведений и m сложений векторов, второй — столько же, плюс умножение на γ_k. Вместе порядка $4mn$ операций.
- Плотное умножение на $\mathbf{H}_k$ стоит $2n^2$. При $n = 10^5$ и $m = 10$ два цикла дешевле примерно в $5 \cdot 10^3$ раз.
- Пары старше m выбрасывают: они приближают гессиан в точке, из которой алгоритм уже ушёл. Свежие $\mathbf{s}, \mathbf{y}$ важнее.
- Поэтому $m = 5$ на прошлом рисунке не отстаёт от полной матрицы. Память и скорость одной итерации, а не точность аппроксимации, — причина переходить на L-BFGS.
- Поиск Вульфа, проба $\alpha = 1$ и отказ от пары при $\mathbf{y}^\top \mathbf{s} \le 0$ те же, что у BFGS.

Сводка

Метод	На шаге	Память	У минимума
Градиентный спуск	$-\alpha \mathbf{g}$	$O(n)$	линейная, $1 - 1/\kappa$
Ньютон	$-\mathbf{H}^{-1}\mathbf{g}$	$O(n^2)$	квадратичная
BFGS	$-\mathbf{H}_k\mathbf{g}$	$O(n^2)$	сверхлинейная
L-BFGS	два цикла, m пар	$O(mn)$	как BFGS при небольшом m

Квадратичная и сверхлинейная скорости — локальные. Глобально их держит поиск: Армихо у Ньютона, Вульф у BFGS и L-BFGS.

Что запомнить

- Шаг Ньютона — минимум квадратичной модели. На квадратичной задаче он точный. Локально ошибка возводится в квадрат, число верных знаков удваивается.
- Для уравнений формула та же, но гессиан симметричен и около минимума положительно определён, а область допустимых стартовых точек может иметь фрактальную границу.
- Полный шаг нельзя ставить всегда: у $\sqrt{1+x^2}$ он расходится при $|x_0| > 1$, хотя гессиан положительно определён всюду. Демпфирование пробует $\alpha = 1$ и укорачивает его по условиям Армихо.
- BFGS приближает обратный гессиан из пар $(\mathbf{s}, \mathbf{y})$ и сходится сверхлинейно. L-BFGS хранит $m = 5, \dots, 20$ последних пар векторов и применяет ту же рекурсию к вектору за $O(mn)$.

Как выбрать

1. n невелико или гессиан факторизуется дёшево, функция гладкая. Демпфированный Ньютон, проба шага $\alpha = 1$.
2. Доступен только градиент и n до нескольких тысяч. BFGS, условия Вульфа, проба $\alpha = 1$.
3. Доступен только градиент и n большое. L-BFGS, $m = 5, \dots, 20$, тот же поиск.

Мини-батч и шум градиента сюда не подставляют: секущие пары и внутренние сопряжённые градиенты рассчитаны на точный f'.

Источники

- J. Nocedal, S. Wright. *Numerical Optimization*, 2nd ed. Springer, 2006, главы 3, 6 и 7.
- J. E. Dennis, J. J. Moré. *Quasi-Newton Methods, Motivation and Theory.* SIAM Review, 1977.
- D. C. Liu, J. Nocedal. *On the Limited Memory BFGS Method for Large Scale Optimization.* Mathematical Programming, 1989.
- A. Cayley. *The Newton–Fourier imaginary problem.* American Journal of Mathematics, 2 (1879).
- P. Blanchard. *The Dynamics of Newton's Method.* In: Complex Dynamical Systems, AMS, 1994.

Дальше

- Шаг Ньютона и пара $(\mathbf{s}, \mathbf{y})$ строятся без множества допустимых точек. Ограничение $\mathbf{x} \in Q$ эти методы сами по себе не уважают.
- Проекция возвращает шаг градиента на Q. Условный градиент Франка — Вульфа заменяет проекцию линейной минимизацией по Q.
- Оба метода снова первого порядка. Гессиан появится внутри только если проекцию или линейную подзадачу удаётся решить ньютоновским шагом.

