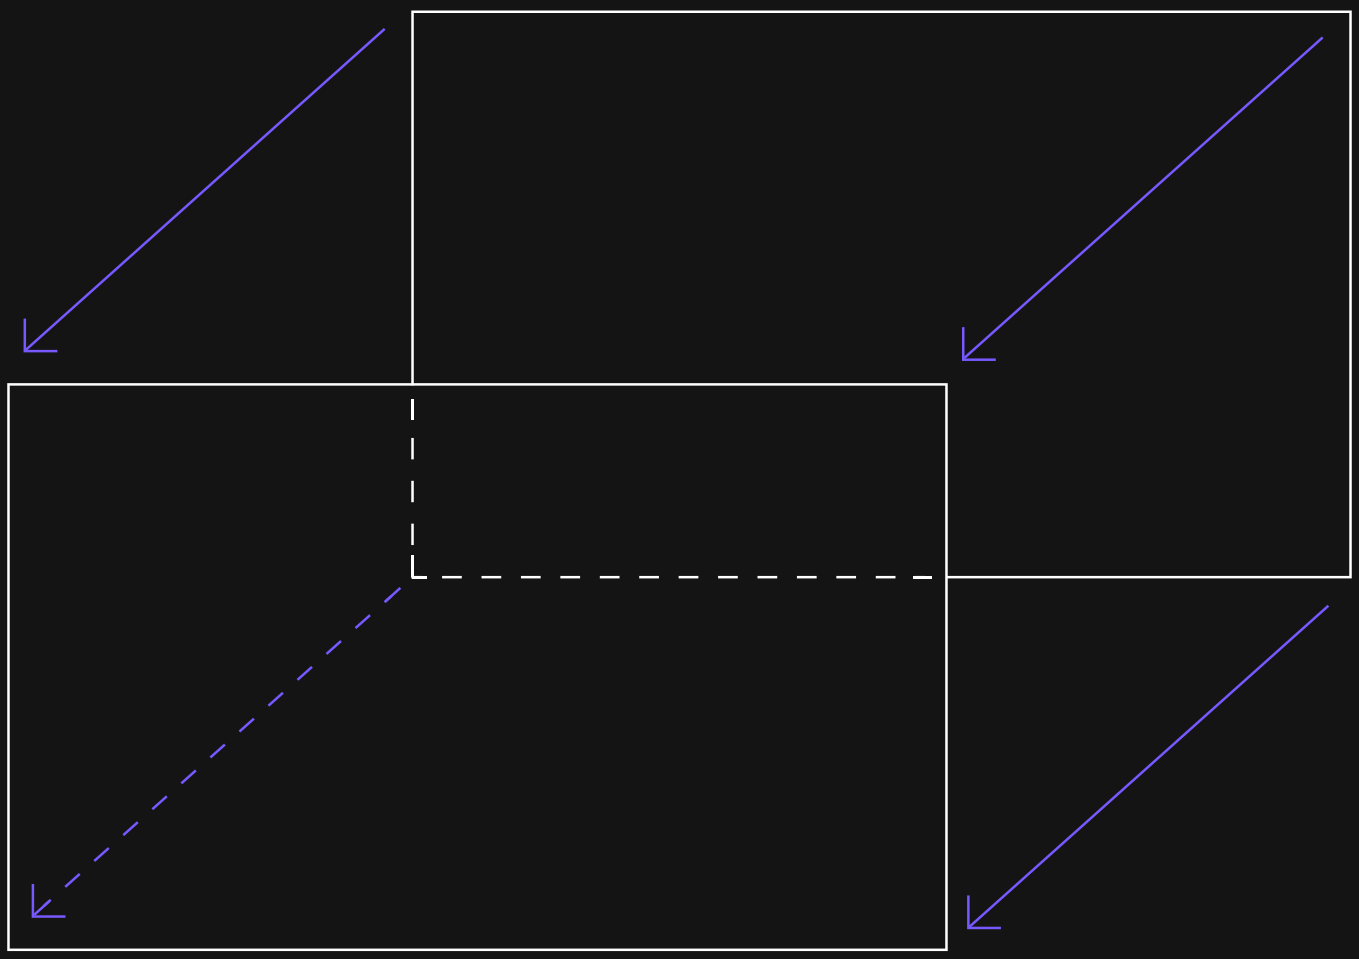
Машинное обучение | Лонгрид

Методы оптимизации | 10

Метод проекции градиента и метод Франк–Вульфа



Проксимальный шаг и метод Франк — Вульфа

Контекст

На слайдах шаг проксимального градиентного метода записан как проксимальный оператор от градиентного шага по гладкой части, ускорение — та же схема, что у Нестерова на неделе 8, с постоянным коэффициентом при известном μ, а метод Франк — Вульфа заменяет проекцию линейной минимизацией. Для сильно выпуклой задачи выписаны множитель $1 - \mu/L$ у проксимального градиентного метода, множитель $1 - 1/\sqrt{\kappa}$ у ускорения и оценка $2LD^2/(k+2)$ у метода Франк — Вульфа. Вывод этих трёх оценок в презентацию не вошёл.

Применение

Множитель говорит, какой бюджет закладывать. У проксимального градиентного метода он по-прежнему порядка κ, у ускорения — порядка $\sqrt{\kappa}$: негладкое слагаемое, если его проксимальный оператор точен, в оценку не входит. У метода Франк — Вульфа бюджет порядка LD^2/ε.

Задача лонгрида

Доказать три оценки со слайдов.

Краткий план

- Проксимальный градиентный метод: квадрат расстояния умножается на $1 - \mu/L$
- Ускорение с постоянным β: зазор умножается на $1 - 1/\sqrt{\kappa}$
- Франк — Вульф: зазор не больше $2LD^2/(k+2)$

Базовая литература к доказательствам этой недели:

- S. Bubeck, *Convex Optimization: Algorithms and Complexity*, Foundations and Trends in Machine Learning, 2015, теорема 3.10;
- A. Beck, M. Teboulle, *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems*, SIAM Journal on Imaging Sciences, 2009;
- Y. Nesterov, *Gradient methods for minimizing composite functions*, Mathematical Programming, 2013;
- Y. Nesterov, *Lectures on Convex Optimization*, Springer, 2018;
- M. Jaggi, *Revisiting Frank–Wolfe: Projection-Free Sparse Convex Optimization*, ICML, 2013, теорема 1.

Штрих обозначает градиент: $f'(\mathbf{x}) \in \mathbb{R}^n$. Норма евклидова. Число обусловленности гладкой сильно выпуклой функции — $\kappa = L/\mu$. Логарифм в оценках числа итераций натуральный.

1. ПРОКСИМАЛЬНЫЙ ОПЕРАТОР

Композитная задача —

$$F(\mathbf{x}) = f(\mathbf{x}) + g(\mathbf{x}).$$

Функция f дифференцируема и выпукла. Функция g выпукла, замкнута и не равна тождественно $+\infty$; значение $+\infty$ разрешено и как раз задаёт ограничение. Проксимальный оператор при $\alpha > 0$ —

$$\operatorname{prox}_{\alpha g}(\mathbf{v}) = \arg\min_{\mathbf{x}} \left(g(\mathbf{x}) + \frac{1}{2\alpha}\|\mathbf{x} - \mathbf{v}\|^2 \right). \tag{1}$$

Квадрат строго выпуклый и уходит в $+\infty$ вместе с $\|\mathbf{x}\|$, поэтому минимум существует и единственен при любом $\mathbf{v}$.

ЛЕММА 1

Точка $\mathbf{x}^+ = \operatorname{prox}_{\alpha g}(\mathbf{v})$ характеризуется неравенством: для всякого $\mathbf{y}$

$$g(\mathbf{y}) \;\geqslant\; g(\mathbf{x}^+) + \left\langle \frac{\mathbf{v}-\mathbf{x}^+}{\alpha}, \mathbf{y}-\mathbf{x}^+ \right\rangle. \tag{2}$$

Если $g(\mathbf{y}) = +\infty$, неравенство выполнено само собой.

ДОКАЗАТЕЛЬСТВО

Пусть $g(\mathbf{y}) < +\infty$ и $\mathbf{d} = \mathbf{y} - \mathbf{x}^+$. Функция

$$\eta(\mathbf{z}) = g(\mathbf{z}) + \frac{1}{2\alpha}\|\mathbf{z}-\mathbf{v}\|^2$$

выпукла и имеет минимум в $\mathbf{x}^+$, поэтому при $t \in (0,1)$ выполнено $\eta(\mathbf{x}^+ + t\mathbf{d}) \geqslant \eta(\mathbf{x}^+)$. Раскрываем квадрат:

$$\frac{g(\mathbf{x}^+ + t\mathbf{d}) - g(\mathbf{x}^+)}{t} \;\geqslant\; \left\langle \frac{\mathbf{v}-\mathbf{x}^+}{\alpha}, \mathbf{d} \right\rangle - \frac{t}{2\alpha}\|\mathbf{d}\|^2.$$

У выпуклой g разностные отношения возрастают. В самом деле, при $0 < t < s \leqslant 1$ точка $\mathbf{x}^+ + t\mathbf{d}$ есть выпуклая комбинация $\mathbf{x}^+$ и $\mathbf{x}^+ + s\mathbf{d}$ с весом t/s у второй точки, откуда

$$\frac{g(\mathbf{x}^+ + t\mathbf{d}) - g(\mathbf{x}^+)}{t} \;\leqslant\; \frac{g(\mathbf{x}^+ + s\mathbf{d}) - g(\mathbf{x}^+)}{s}.$$

Значит, левая часть при $t \in (0,1)$ не больше значения при $t = 1$, то есть не больше $g(\mathbf{y}) - g(\mathbf{x}^+)$. Правая часть при $t \downarrow 0$ стремится к скалярному произведению из (2).

ЛЕММА 2

Проксимальный оператор не растягивает расстояния: для любых $\mathbf{v}, \mathbf{w}$

$$\|\operatorname{prox}_{\alpha g}(\mathbf{v}) - \operatorname{prox}_{\alpha g}(\mathbf{w})\| \;\leqslant\; \|\mathbf{v}-\mathbf{w}\|.$$

Точнее, если $\mathbf{x}^+ = \operatorname{prox}_{\alpha g}(\mathbf{v})$ и $\mathbf{y}^+ = \operatorname{prox}_{\alpha g}(\mathbf{w})$, то

$$\|\mathbf{x}^+ - \mathbf{y}^+\|^2 \;\leqslant\; \langle \mathbf{v}-\mathbf{w}, \mathbf{x}^+ - \mathbf{y}^+ \rangle.$$

ДОКАЗАТЕЛЬСТВО

Подставляем в (2) точку $\mathbf{y}^+$ для входа $\mathbf{v}$ и точку $\mathbf{x}^+$ для входа $\mathbf{w}$:

$$\langle \mathbf{v}-\mathbf{x}^+, \mathbf{y}^+ - \mathbf{x}^+ \rangle \;\leqslant\; \alpha\big(g(\mathbf{y}^+) - g(\mathbf{x}^+)\big),$$

$$\langle \mathbf{w}-\mathbf{y}^+, \mathbf{x}^+ - \mathbf{y}^+ \rangle \;\leqslant\; \alpha\big(g(\mathbf{x}^+) - g(\mathbf{y}^+)\big).$$

Сумма правых частей равна нулю, поэтому

$$\langle \mathbf{v}-\mathbf{w}, \mathbf{y}^+ - \mathbf{x}^+ \rangle + \|\mathbf{y}^+ - \mathbf{x}^+\|^2 \;\leqslant\; 0.$$

Это второе неравенство леммы. Неравенство Коши — Буняковского даёт из него нерастяжение.

ЛЕММА 3

Равенство $\operatorname{prox}_{\alpha g}(\mathbf{x}) = \mathbf{x}$ выполнено тогда и только тогда, когда $\mathbf{x}$ минимизирует g.

Пусть ещё f выпукла и дифференцируема. Точка $\mathbf{x}^\star$ минимизирует F тогда и только тогда, когда при каком-нибудь, и тогда при любом, $\alpha > 0$

$$\mathbf{x}^\star = \operatorname{prox}_{\alpha g}\bigl(\mathbf{x}^\star - \alpha f'(\mathbf{x}^\star)\bigr). \tag{3}$$

Оба утверждения равносильны вариационному неравенству

$$\langle f'(\mathbf{x}^\star), \mathbf{y} - \mathbf{x}^\star\rangle + g(\mathbf{y}) - g(\mathbf{x}^\star) \;\geqslant\; 0 \qquad \forall\, \mathbf{y}. \tag{4}$$

ДОКАЗАТЕЛЬСТВО

При $\mathbf{v} = \mathbf{x}$ и $\mathbf{x}^+ = \mathbf{x}$ неравенство (2) превращается в $g(\mathbf{y}) \geqslant g(\mathbf{x})$. Обратно, если $\mathbf{x}$ минимизирует g, то $\mathbf{x}$ допустима в задаче (1) при $\mathbf{v} = \mathbf{x}$, а для любого другого $\mathbf{y}$ квадрат только увеличивает значение. Единственность минимума даёт $\operatorname{prox}_{\alpha g}(\mathbf{x}) = \mathbf{x}$.

Подстановка $\mathbf{v} = \mathbf{x}^\star - \alpha f'(\mathbf{x}^\star)$ в (2) есть в точности (4). Остаётся связать (4) с минимумом F.

Если выполнено (4), выпуклость f даёт $f(\mathbf{y}) \geqslant f(\mathbf{x}^\star) + \langle f'(\mathbf{x}^\star), \mathbf{y} - \mathbf{x}^\star\rangle$, и в сумме с (4) получается $F(\mathbf{y}) \geqslant F(\mathbf{x}^\star)$.

Обратно, пусть $\mathbf{x}^\star$ минимизирует F и $g(\mathbf{y}) < +\infty$. При $t \in (0,1)$ точка $\mathbf{x}^\star + t(\mathbf{y} - \mathbf{x}^\star)$ не уменьшает F. Делим приращение на t и устремляем $t \downarrow 0$: производная гладкой части равна $\langle f'(\mathbf{x}^\star), \mathbf{y} - \mathbf{x}^\star\rangle$, а разностное отношение g не меньше своего предела и не больше значения при $t = 1$. Отсюда $\langle f'(\mathbf{x}^\star), \mathbf{y} - \mathbf{x}^\star\rangle + g(\mathbf{y}) - g(\mathbf{x}^\star) \geqslant 0$.

Если g — индикатор выпуклого замкнутого Q, задача (1) есть проекция, от α она не зависит, и (4) превращается в вариационное неравенство со слайда: $\langle f'(\mathbf{x}^\star), \mathbf{y} - \mathbf{x}^\star\rangle \geqslant 0$ для всех $\mathbf{y} \in Q$.

2. ПРОКСИМАЛЬНЫЙ ГРАДИЕНТНЫЙ МЕТОД ПРИ $\mu > 0$

Шаг проксимального градиентного метода —

$$\mathbf{x}_{k+1} = \operatorname{prox}_{\alpha g}\bigl(\mathbf{x}_k - \alpha f'(\mathbf{x}_k)\bigr), \qquad \alpha = \frac{1}{L}. \tag{5}$$

Ниже $f : \mathbb{R}^n \to \mathbb{R}$ выпукла, L-гладкая и μ-сильно выпуклая, $\mu > 0$. Лемма о спуске и определение сильной выпуклости те же, что в лонгриде недели 7.

ЛЕММА 4

Пусть f выпукла и L-гладкая. Тогда для всех $\mathbf{x}, \mathbf{y}$

$$f(\mathbf{y}) \;\geqslant\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x}\rangle + \frac{1}{2L}\|f'(\mathbf{y}) - f'(\mathbf{x})\|^2 \tag{6}$$

и

$$\langle f'(\mathbf{x}) - f'(\mathbf{y}), \mathbf{x} - \mathbf{y}\rangle \;\geqslant\; \frac{1}{L}\|f'(\mathbf{x}) - f'(\mathbf{y})\|^2. \tag{7}$$

ДОКАЗАТЕЛЬСТВО

Фиксируем $\mathbf{x}$ и положим $\varphi(\mathbf{z}) = f(\mathbf{z}) - \langle f'(\mathbf{x}), \mathbf{z}\rangle$. Тогда φ выпукла и L-гладкая, а $\varphi'(\mathbf{x}) = \mathbf{0}$, так что $\mathbf{x}$ минимизирует φ. Для произвольного $\mathbf{z}$ шаг $\mathbf{z}^+ = \mathbf{z} - \varphi'(\mathbf{z})/L$ по лемме о спуске даёт

$$\varphi(\mathbf{z}^+) \;\leqslant\; \varphi(\mathbf{z}) - \frac{1}{2L}\|\varphi'(\mathbf{z})\|^2.$$

Минимум не больше левой части: $\varphi(\mathbf{x}) \leqslant \varphi(\mathbf{z}^{+})$. Поскольку $\varphi'(\mathbf{z}) = f'(\mathbf{z}) - f'(\mathbf{x})$,

$$f(\mathbf{z}) \;\geqslant\; f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{z} - \mathbf{x}\rangle + \frac{1}{2L}\|f'(\mathbf{z}) - f'(\mathbf{x})\|^2.$$

Это (6). То же неравенство с переставленными $\mathbf{x}$ и $\mathbf{y}$ в сумме с ним даёт (7): линейные члены складываются в скалярное произведение градиентов, а квадраты норм совпадают.

ЛЕММА 5

Если f дифференцируема и μ-сильно выпукла, то

$$\langle f'(\mathbf{x}) - f'(\mathbf{y}), \mathbf{x} - \mathbf{y}\rangle \;\geqslant\; \mu\|\mathbf{x} - \mathbf{y}\|^2.$$

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость в точках $\mathbf{x}$ и $\mathbf{y}$ даёт два неравенства. Их сумма уничтожает $f(\mathbf{x})$ и $f(\mathbf{y})$ и оставляет указанное скалярное произведение.

ТЕОРЕМА 1

Пусть f L-гладкая и μ-сильно выпуклая, g выпукла и замкнута, минимум F достигается в $\mathbf{x}^{\star}$, шаг равен $1/L$. Тогда

$$\|\mathbf{x}_k - \mathbf{x}^{\star}\|^2 \;\leqslant\; \Bigl(1 - \frac{\mu}{L}\Bigr)^{k} \|\mathbf{x}_0 - \mathbf{x}^{\star}\|^2.$$

ДОКАЗАТЕЛЬСТВО

Сильная выпуклость f и выпуклость g дают сильную выпуклость F, поэтому минимум единственен. По лемме 3 он неподвижная точка шага (5). Лемма 2 сравнивает шаг из $\mathbf{x}_k$ с шагом из $\mathbf{x}^{\star}$:

$$\|\mathbf{x}_{k+1} - \mathbf{x}^{\star}\|^2 \;\leqslant\; \bigl\|\bigl(\mathbf{x}_k - \alpha f'(\mathbf{x}_k)\bigr) - \bigl(\mathbf{x}^{\star} - \alpha f'(\mathbf{x}^{\star})\bigr)\bigr\|^2.$$

Обозначим $\mathbf{d} = \mathbf{x}_k - \mathbf{x}^{\star}$ и $\mathbf{g} = f'(\mathbf{x}_k) - f'(\mathbf{x}^{\star})$. При $\alpha = 1/L$ правая часть равна

$$\|\mathbf{d}\|^2 - \frac{2}{L}\langle \mathbf{g}, \mathbf{d}\rangle + \frac{1}{L^2}\|\mathbf{g}\|^2.$$

Функция f выпукла, потому что она сильно выпукла. Неравенство (7) даёт $\|\mathbf{g}\|^2 \leqslant L\langle \mathbf{g}, \mathbf{d}\rangle$, и член с квадратом нормы не больше $\langle \mathbf{g}, \mathbf{d}\rangle / L$. Остаётся

$$\|\mathbf{x}_{k+1} - \mathbf{x}^{\star}\|^2 \;\leqslant\; \|\mathbf{d}\|^2 - \frac{1}{L}\langle \mathbf{g}, \mathbf{d}\rangle.$$

Лемма 5 заменяет скалярное произведение на $\mu\|\mathbf{d}\|^2$:

$$\|\mathbf{x}_{k+1} - \mathbf{x}^{\star}\|^2 \;\leqslant\; \Bigl(1 - \frac{\mu}{L}\Bigr)\|\mathbf{x}_k - \mathbf{x}^{\star}\|^2.$$

Множитель неотрицателен: из леммы о спуске и сильной выпуклости следует $\mu \leqslant L$, как в лонгриде недели 7. Индукция по k даёт степень k.

СЛЕДСТВИЕ

Квадрат расстояния становится не больше $\varepsilon > 0$ при

$$k \;\geqslant\; \kappa \ln \frac{\|\mathbf{x}_0 - \mathbf{x}^{\star}\|^2}{\varepsilon},$$

если ε меньше начального квадрата. На числах слайда $L=10$, $\mu=1$, $\kappa=10$ и уменьшение квадрата расстояния в 10^4 раз требуют $k \geqslant 10\ln\bigl(10^4\bigr) \approx 92$.

ДОКАЗАТЕЛЬСТВО

Пусть $R=\|\mathbf{x}_0-\mathbf{x}^\star\|$. Достаточно $(1-1/\kappa)^k R^2 \leqslant \varepsilon$. При $u\in(0,1]$ выполнено $-\ln(1-u)\geqslant u$, поэтому хватает

$$k \geqslant \kappa \ln\bigl(R^2/\varepsilon\bigr).$$

Численно $\ln\bigl(10^4\bigr)\approx 9{,}21$.

ЗАМЕЧАНИЕ

При $g=0$ оператор ничего не сдвигает, и теорема 1 есть сжатие квадрата расстояния у градиентного спуска с шагом $1/L$. Лонгрид недели 7 тем же множителем $1-\mu/L$ сжимает зазор по значению. Из сильной выпуклости в точке минимума $\frac{\mu}{2}\|\mathbf{x}_k-\mathbf{x}^\star\|^2 \leqslant f(\mathbf{x}_k)-f^\star$, так что расстояние и зазор убывают с одной и той же линейной скоростью. Для индикатора Q шаг (5) есть проекция градиента: это теорема 3.10 у Bubeck.

3. УСКОРЕНИЕ ПРИ ИЗВЕСТНОМ μ

Схема со слайда: $\mathbf{x}_{-1}=\mathbf{x}_0$, $\alpha=1/L$,

$$\begin{aligned} \mathbf{y}_k &= \mathbf{x}_k+\beta(\mathbf{x}_k-\mathbf{x}_{k-1}),\\ \mathbf{x}_{k+1} &= \operatorname{prox}_{\alpha g}\bigl(\mathbf{y}_k-\alpha f'(\mathbf{y}_k)\bigr), \end{aligned} \qquad \beta=\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}. \tag{8}$$

Пишем $\theta=1/\sqrt{\kappa}=\sqrt{\mu/L}$, так что $\beta=(1-\theta)/(1+\theta)$ и $\theta\in(0,1]$ при $\kappa\geqslant 1$. Точка $\mathbf{y}_k$ собирает инерцию и может выйти из области, где g конечна. Градиент f считается в $\mathbf{y}_k$, поэтому f должна быть определена на всём $\mathbb{R}^n$. Проксимальный оператор возвращает $\mathbf{x}_{k+1}$ туда, где g конечна.

При $\kappa=1$ выходит $\beta=0$ и $\theta=1$. Тогда $L=\mu$, верхняя и нижняя параболы совпадают, модель шага есть сама F, и первая итерация попадает в минимум. Дальше $\kappa>1$, так что $\theta\in(0,1)$.

Градиентное отображение одного проксимального шага из точки $\mathbf{y}$ —

$$\mathbf{G}=L\bigl(\mathbf{y}-\mathbf{x}^+\bigr), \qquad \mathbf{x}^+=\operatorname{prox}_{\alpha g}\bigl(\mathbf{y}-\alpha f'(\mathbf{y})\bigr). \tag{9}$$

Тогда $\mathbf{x}^+=\mathbf{y}-\mathbf{G}/L$. При $g=0$ получается $\mathbf{G}=f'(\mathbf{y})$, и схема (8) совпадает со схемой Нестерова из лонгрида недели 8.

ЛЕММА 6

Пусть f L-гладкая и μ-сильно выпуклая, g выпукла, $\mathbf{x}^+$ и $\mathbf{G}$ взяты из (9). Тогда для всякого $\mathbf{w}$ с конечным $g(\mathbf{w})$

$$F(\mathbf{x}^+) \;\leqslant\; F(\mathbf{w})+\langle \mathbf{G},\mathbf{y}-\mathbf{w}\rangle-\tfrac{\mu}{2}\|\mathbf{y}-\mathbf{w}\|^2-\tfrac{1}{2L}\|\mathbf{G}\|^2. \tag{10}$$

ДОКАЗАТЕЛЬСТВО

Лемма о спуске в точке $\mathbf{y}$ и неравенство (2) для $\mathbf{v}=\mathbf{y}-f'(\mathbf{y})/L$ дают

$$\begin{aligned} F(\mathbf{x}^+) \;\leqslant\; & f(\mathbf{y})+\langle f'(\mathbf{y}),\mathbf{x}^+-\mathbf{y}\rangle+\tfrac{L}{2}\|\mathbf{x}^+-\mathbf{y}\|^2\\ & +g(\mathbf{w})-L\langle \mathbf{y}-\mathbf{x}^+,\mathbf{w}-\mathbf{x}^+\rangle+\langle f'(\mathbf{y}),\mathbf{w}-\mathbf{x}^+\rangle. \end{aligned}$$

Скалярные произведения с $f'(\mathbf{y})$ складываются в $\langle f'(\mathbf{y}), \mathbf{w}-\mathbf{y}\rangle$. Квадратные члены равны $\frac{L}{2}\bigl(\|\mathbf{w}-\mathbf{y}\|^2 - \|\mathbf{w}-\mathbf{x}^+\|^2\bigr)$: это тождество

$$\|\mathbf{w}-\mathbf{y}\|^2 - \|\mathbf{w}-\mathbf{x}^+\|^2 = \|\mathbf{x}^+-\mathbf{y}\|^2 - 2\langle \mathbf{y}-\mathbf{x}^+, \mathbf{w}-\mathbf{x}^+\rangle.$$

Сильная выпуклость f в точке $\mathbf{y}$ заменяет $f(\mathbf{y}) + \langle f'(\mathbf{y}), \mathbf{w}-\mathbf{y}\rangle$ на величину не больше $f(\mathbf{w}) - \frac{\mu}{2}\|\mathbf{w}-\mathbf{y}\|^2$. Получаем

$$F(\mathbf{x}^+) \;\leqslant\; F(\mathbf{w}) + \tfrac{L-\mu}{2}\|\mathbf{y}-\mathbf{w}\|^2 - \tfrac{L}{2}\|\mathbf{w}-\mathbf{x}^+\|^2.$$

Подставляем $\mathbf{x}^+ = \mathbf{y} - \mathbf{G}/L$:

$$\|\mathbf{w}-\mathbf{x}^+\|^2 = \|\mathbf{w}-\mathbf{y}\|^2 + \tfrac{2}{L}\langle \mathbf{w}-\mathbf{y}, \mathbf{G}\rangle + \tfrac{1}{L^2}\|\mathbf{G}\|^2,$$

и правая часть предыдущей оценки превращается в правую часть (10).

ЗАМЕЧАНИЕ

При $\mathbf{y} = \mathbf{w} = \mathbf{x}_k$ неравенство (10) говорит, что обычный проксимальный шаг уменьшает F по крайней мере на $\|\mathbf{G}\|^2/(2L)$. В минимуме $\mathbf{G} = \mathbf{0}$: это та же неподвижная точка, что в лемме 3.

Вспомогательная точка, как в лонгриде недели 8, отдельно не хранится:

$$\mathbf{z}_k = \mathbf{x}_k + \frac{1-\theta}{\theta}(\mathbf{x}_k - \mathbf{x}_{k-1}), \qquad \mathbf{z}_0 = \mathbf{x}_0. \tag{11}$$

ЛЕММА 7

Для схемы (8) и точки (11), при $\mathbf{G}_k = L(\mathbf{y}_k - \mathbf{x}_{k+1})$,

$$\mathbf{y}_k = \frac{\mathbf{x}_k + \theta \mathbf{z}_k}{1+\theta},$$

и

$$\mathbf{z}_{k+1} = (1-\theta)\mathbf{z}_k + \theta \mathbf{y}_k - \frac{\theta}{\mu}\mathbf{G}_k.$$

ДОКАЗАТЕЛЬСТВО

Из (11) разность $\mathbf{x}_k - \mathbf{x}_{k-1}$ равна $\frac{\theta}{1-\theta}(\mathbf{z}_k - \mathbf{x}_k)$. Коэффициент при ней в формуле $\mathbf{y}_k$ равен

$$\beta \cdot \frac{\theta}{1-\theta} = \frac{1-\theta}{1+\theta}\cdot\frac{\theta}{1-\theta} = \frac{\theta}{1+\theta}.$$

Поэтому $\mathbf{y}_k = \mathbf{x}_k + \frac{\theta}{1+\theta}(\mathbf{z}_k - \mathbf{x}_k)$, что и есть первая формула.

Определение (11) на следующем шаге даёт

$$\mathbf{z}_{k+1} = \frac{1}{\theta}\mathbf{x}_{k+1} - \frac{1-\theta}{\theta}\mathbf{x}_k.$$

Подставляем $\mathbf{x}_{k+1} = \mathbf{y}_k - \mathbf{G}_k/L$:

$$\mathbf{z}_{k+1} = \frac{1}{\theta}\mathbf{y}_k - \frac{1-\theta}{\theta}\mathbf{x}_k - \frac{1}{\theta L}\mathbf{G}_k.$$

Из $\theta^2 = \mu/L$ следует $1/(\theta L) = \theta/\mu$. Остаётся проверить

$$\frac{1}{\theta}\mathbf{y}_k - \frac{1-\theta}{\theta}\mathbf{x}_k = (1-\theta)\mathbf{z}_k + \theta\mathbf{y}_k.$$

После подстановки $\mathbf{y}_k = (\mathbf{x}_k + \theta\mathbf{z}_k)/(1+\theta)$ обе части равны $(\theta\mathbf{x}_k + \mathbf{z}_k)/(1+\theta)$. У левой коэффициент при $\mathbf{x}_k$ упрощается так:

$$\frac{1}{\theta(1+\theta)} - \frac{1-\theta}{\theta} = \frac{1-(1-\theta^2)}{\theta(1+\theta)} = \frac{\theta}{1+\theta},$$

и рядом остаётся $\mathbf{z}_k/(1+\theta)$. У правой коэффициент при $\mathbf{z}_k$ равен $(1-\theta) + \theta^2/(1+\theta) = 1/(1+\theta)$.

ТЕОРЕМА 2

Пусть f L-гладкая и μ-сильно выпуклая на $\mathbb{R}^n$, g выпукла и замкнута, минимум F достигается в $\mathbf{x}^\star$, шаг и β взяты из (8). Тогда при $k \geqslant 0$

$$F(\mathbf{x}_k) - F^\star \;\leqslant\; \left(1 - \frac{1}{\sqrt{\kappa}}\right)^k \left(F(\mathbf{x}_0) - F^\star + \tfrac{\mu}{2}\|\mathbf{x}_0 - \mathbf{x}^\star\|^2\right). \tag{12}$$

Точность ε по значению достигается при $k \geqslant \sqrt{\kappa}\,\ln(V_0/\varepsilon)$, где V_0 — скобка в правой части.

ДОКАЗАТЕЛЬСТВО

Случай $\kappa = 1$ уже разобран: правая часть при $k \geqslant 1$ равна нулю, и первая итерация попадает в минимум. Дальше $\theta \in (0,1)$.

Положим

$$V_k = F(\mathbf{x}_k) - F^\star + \tfrac{\mu}{2}\|\mathbf{z}_k - \mathbf{x}^\star\|^2.$$

Достаточно доказать $V_{k+1} \leqslant (1-\theta)V_k$. Пишем $\mathbf{G} = \mathbf{G}_k$, $\mathbf{y} = \mathbf{y}_k$, $\mathbf{x} = \mathbf{x}_k$, $\mathbf{z} = \mathbf{z}_k$, $\mathbf{x}^+ = \mathbf{x}_{k+1}$ и $\mathbf{z}^+ = \mathbf{z}_{k+1}$.

Лемму 6 применяем дважды: в точке $\mathbf{w} = \mathbf{x}$ с весом $1-\theta$ и в точке $\mathbf{w} = \mathbf{x}^\star$ с весом θ. Оба значения g конечны: $\mathbf{x}$ получен проксимальным оператором или является стартом в области конечности g, а $\mathbf{x}^\star$ минимизирует F. Выпуклая комбинация сохраняет неравенство:

$$\begin{aligned} F(\mathbf{x}^+) - F^\star \;\leqslant\; & (1-\theta)\big(F(\mathbf{x}) - F^\star\big) \\ & + \big\langle \mathbf{G}, (1-\theta)(\mathbf{y}-\mathbf{x}) + \theta(\mathbf{y}-\mathbf{x}^\star)\big\rangle \\ & - \tfrac{\mu}{2}\Big((1-\theta)\|\mathbf{y}-\mathbf{x}\|^2 + \theta\|\mathbf{y}-\mathbf{x}^\star\|^2\Big) - \tfrac{1}{2L}\|\mathbf{G}\|^2. \end{aligned} \tag{13}$$

Рекурсия для $\mathbf{z}$ даёт

$$\mathbf{z}^+ - \mathbf{x}^\star = (1-\theta)(\mathbf{z}-\mathbf{x}^\star) + \theta(\mathbf{y}-\mathbf{x}^\star) - \frac{\theta}{\mu}\mathbf{G}.$$

Квадрат нормы, умноженный на $\mu/2$, содержит перекрёстный член

$$-\theta\big\langle (1-\theta)(\mathbf{z}-\mathbf{x}^\star) + \theta(\mathbf{y}-\mathbf{x}^\star), \mathbf{G}\big\rangle$$

и член $\theta^2\|\mathbf{G}\|^2/(2\mu) = \|\mathbf{G}\|^2/(2L)$. Последний взаимно уничтожается с последним членом (13).

Перекрёстный член гасится скалярным произведением из (13), потому что

$$(1-\theta)(\mathbf{y}-\mathbf{x}) + \theta(\mathbf{y}-\mathbf{x}^\star) = \theta\Big((1-\theta)(\mathbf{z}-\mathbf{x}^\star) + \theta(\mathbf{y}-\mathbf{x}^\star)\Big). \tag{14}$$

Проверка — подстановка $\mathbf{y} = (\mathbf{x}+\theta\mathbf{z})/(1+\theta)$. Тогда $\mathbf{y}-\mathbf{x} = \frac{\theta}{1+\theta}(\mathbf{z}-\mathbf{x})$ и

$$\mathbf{y}-\mathbf{x}^\star = \frac{\mathbf{x}-\mathbf{x}^\star}{1+\theta} + \frac{\theta}{1+\theta}(\mathbf{z}-\mathbf{x}^\star).$$

У левой части (14) коэффициент при $\mathbf{x}-\mathbf{x}^\star$ равен $\theta/(1+\theta) - \theta(1-\theta)/(1+\theta) = \theta^2/(1+\theta)$, а коэффициент при $\mathbf{z}-\mathbf{x}^\star$ равен $\theta(1-\theta)/(1+\theta) + \theta^2/(1+\theta) = \theta/(1+\theta)$. Правая часть после той же подстановки даёт те же коэффициенты: вклад $\theta(1-\theta)(\mathbf{z}-\mathbf{x}^\star)$ и вклад $\theta^2(\mathbf{y}-\mathbf{x}^\star)$ в сумме имеют коэффициент $\theta/(1+\theta)$ при $\mathbf{z}-\mathbf{x}^\star$, поскольку $(1-\theta)(1+\theta)+\theta^2 = 1$.

После взаимного уничтожения

$$\begin{aligned} V_{k+1} \;\leqslant\; & (1-\theta)\big(F(\mathbf{x})-F^\star\big) + \tfrac{\mu}{2}\|(1-\theta)(\mathbf{z}-\mathbf{x}^\star)+\theta(\mathbf{y}-\mathbf{x}^\star)\|^2 \\ & - \tfrac{\mu}{2}(1-\theta)\|\mathbf{y}-\mathbf{x}\|^2 - \tfrac{\mu\theta}{2}\|\mathbf{y}-\mathbf{x}^\star\|^2. \end{aligned} \tag{15}$$

Обозначим $\mathbf{u} = \mathbf{z}-\mathbf{x}^\star$ и $\mathbf{w} = \mathbf{z}-\mathbf{x}$. Тогда

$$\mathbf{y}-\mathbf{x}^\star = \mathbf{u} - \frac{\mathbf{w}}{1+\theta}, \qquad \mathbf{y}-\mathbf{x} = \frac{\theta}{1+\theta}\mathbf{w},$$

$$(1-\theta)\mathbf{u} + \theta(\mathbf{y}-\mathbf{x}^\star) = \mathbf{u} - \frac{\theta}{1+\theta}\mathbf{w}.$$

Разность между правой частью (15) и $(1-\theta)(\mu/2)\|\mathbf{u}\|^2$, делённая на $\mu/2$, равна

$$\begin{aligned} E = & \Big\|\mathbf{u} - \frac{\theta}{1+\theta}\mathbf{w}\Big\|^2 - (1-\theta)\|\mathbf{u}\|^2 \\ & - (1-\theta)\Big\|\frac{\theta}{1+\theta}\mathbf{w}\Big\|^2 - \theta\Big\|\mathbf{u}-\frac{\mathbf{w}}{1+\theta}\Big\|^2. \end{aligned}$$

Коэффициент при $\|\mathbf{u}\|^2$ равен $1-(1-\theta)-\theta = 0$. Коэффициент при $\langle\mathbf{u},\mathbf{w}\rangle$ равен $-2\theta/(1+\theta) + 2\theta/(1+\theta) = 0$. Коэффициент при $\|\mathbf{w}\|^2$ равен

$$\frac{\theta^2 - (1-\theta)\theta^2 - \theta}{(1+\theta)^2} = \frac{\theta(\theta^2-1)}{(1+\theta)^2} = -\frac{\theta(1-\theta)}{1+\theta}.$$

Значит,

$$E = -\frac{\theta(1-\theta)}{1+\theta}\|\mathbf{z}-\mathbf{x}\|^2 \;\leqslant\; 0,$$

и $V_{k+1} \leqslant (1-\theta)V_k$.

Отсюда $V_k \leqslant (1-\theta)^k V_0$. В начале $\mathbf{z}_0 = \mathbf{x}_0$, поэтому V_0 есть скобка в (12). Зазор $F(\mathbf{x}_k) - F^\star$ не превосходит V_k. Поскольку $1-\theta \leqslant e^{-\theta}$, неравенство $V_0(1-\theta)^k \leqslant \varepsilon$ выполнено при $k \geqslant \theta^{-1}\ln(V_0/\varepsilon)$.

СЛЕДСТВИЕ

Если $g = 0$, то $f'(\mathbf{x}^\star) = \mathbf{0}$, и лемма о спуске в этой точке даёт $F(\mathbf{x}_0) - F^\star \leqslant \frac{L}{2} R^2$. Скобка в (12) не больше $\frac{L+\mu}{2} R^2 \leqslant L R^2$. Это оценка лонгрида недели 8, с той же схемой и тем же множителем $1 - 1/\sqrt{\kappa}$.

ДОКАЗАТЕЛЬСТВО

При $g = 0$ условие (4) есть $f'(\mathbf{x}^\star) = \mathbf{0}$. Лемма о спуске с центром в $\mathbf{x}^\star$ даёт верхнюю параболу кривизны L. Второе слагаемое скобки равно $\frac{\mu}{2} R^2$.

ЗАМЕЧАНИЕ

На графике LASSO со слайда ускорение идёт по схеме с t_k, которая величины μ не знает. Колебания на этом графике — свойство меняющегося коэффициента на сильно выпуклой задаче. Постоянный β из (8) в теореме 2 этих зубцов не производит: множитель $1 - \theta$ один и тот же на каждом шаге. Для индикатора множества оценка (12) по-прежнему верна, но скобку уже нельзя заменить на $L R^2$: на границе $f'(\mathbf{x}^\star)$ может быть ненулевым, и зазор $f(\mathbf{x}_0) - f^\star$ бывает больше $\frac{L}{2} R^2$. В бюджет тогда входит само V_0.

4. МЕТОД ФРАНК-ВУЛЬФА

Дальше $Q \subset \mathbb{R}^n$ выпукло, замкнуто и ограничено, $D = \operatorname{diam}(Q)$, старт $\mathbf{x}_0 \in Q$. Функция f выпукла и L-гладкая. Гладкости на всём пространстве здесь не нужно: шаг не выходит из Q. Линейная минимизация и шаг —

$$\mathbf{s}_k \in \arg\min_{\mathbf{s} \in Q} \langle f'(\mathbf{x}_k), \mathbf{s} \rangle, \qquad \mathbf{x}_{k+1} = \mathbf{x}_k + \gamma_k (\mathbf{s}_k - \mathbf{x}_k), \qquad \gamma_k = \frac{2}{k+2}. \tag{16}$$

При $\gamma_k \in [0,1]$ точка $\mathbf{x}_{k+1}$ есть выпуклая комбинация точек Q, поэтому она лежит в Q.

ЛЕММА 8

Для выпуклой дифференцируемой f и любого $\mathbf{x} \in Q$

$$f(\mathbf{x}) - f^\star \;\leqslant\; \langle f'(\mathbf{x}), \mathbf{x} - \mathbf{s} \rangle,$$

где $\mathbf{s}$ — какая-либо точка линейной минимизации $\langle f'(\mathbf{x}), \cdot \rangle$ на Q, а $f^\star = \min_Q f$. Правая часть считается из того же ответа, который метод находит сам.

ДОКАЗАТЕЛЬСТВО

Касательная лежит под графиком: $f(\mathbf{y}) \geqslant f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle$ при всех $\mathbf{y} \in Q$. Минимум правой части по $\mathbf{y}$ равен $f(\mathbf{x}) + \langle f'(\mathbf{x}), \mathbf{s} - \mathbf{x} \rangle$. Он не больше $f^\star$.

ТЕОРЕМА 3

Пусть f выпукла и L-гладкая, Q выпукло и компактно, шаг $\gamma_k = 2/(k+2)$. Тогда при $k \geqslant 1$

$$f(\mathbf{x}_k) - f^\star \;\leqslant\; \frac{2 L D^2}{k+2}.$$

ДОКАЗАТЕЛЬСТВО

Лемма о спуске на отрезке от $\mathbf{x}_k$ до $\mathbf{s}_k$ даёт при любом $\gamma \in [0,1]$

$$f\big(\mathbf{x}_k + \gamma(\mathbf{s}_k - \mathbf{x}_k)\big) \;\leqslant\; f(\mathbf{x}_k) + \gamma \langle f'(\mathbf{x}_k), \mathbf{s}_k - \mathbf{x}_k \rangle + \tfrac{L}{2} \gamma^2 \|\mathbf{s}_k - \mathbf{x}_k\|^2.$$

Норма разности не больше диаметра. Обозначим $h_k = f(\mathbf{x}_k) - f^\star$ и

$$g_k = \langle f'(\mathbf{x}_k), \mathbf{x}_k - \mathbf{s}_k \rangle.$$

Лемма 8 даёт $g_k \geqslant h_k$, поэтому при $\gamma = \gamma_k$

$$h_{k+1} \leqslant (1-\gamma_k)h_k + \tfrac{LD^2}{2}\gamma_k^2. \tag{17}$$

Проверим $h_k \leqslant 2LD^2/(k+2)$ индукцией при $k \geqslant 1$.

При $k=0$ шаг равен 1, и (17) даёт $h_1 \leqslant LD^2/2$. Правая часть теоремы при $k=1$ равна $2LD^2/3$. Поскольку $\frac{1}{2} \leqslant \frac{2}{3}$, база верна.

Если оценка верна для некоторого $k \geqslant 1$, то $\gamma_k = 2/(k+2)$ и

$$\begin{aligned} h_{k+1} &\leqslant \frac{k}{k+2}\cdot\frac{2LD^2}{k+2} + \frac{LD^2}{2}\cdot\frac{4}{(k+2)^2} \\ &= \frac{2(k+1)LD^2}{(k+2)^2}. \end{aligned}$$

Сравнение с $2LD^2/(k+3)$ сводится к $(k+1)(k+3) \leqslant (k+2)^2$, то есть к $k^2+4k+3 \leqslant k^2+4k+4$. Множитель $1-\gamma_k$ неотрицателен, поэтому завышение h_k до верхней границы только увеличивает правую часть рекурсии.

СЛЕДСТВИЕ

Та же оценка $2LD^2/(k+2)$ верна, если на итерации k вместо открытого шага $2/(k+2)$ взять точный минимум f на отрезке $[\mathbf{x}_k, \mathbf{s}_k]$ или короткий шаг

$$\gamma = \min\left\{1,\ \frac{\langle f'(\mathbf{x}_k), \mathbf{x}_k - \mathbf{s}_k\rangle}{L\|\mathbf{s}_k - \mathbf{x}_k\|^2}\right\}.$$

ДОКАЗАТЕЛЬСТВО

Квадратичная оценка сверху из леммы о спуске в точке открытого шага $\gamma_k = 2/(k+2)$ уже даёт рекурсию (17): член $\|\mathbf{s}_k - \mathbf{x}_k\|^2$ заменён на D^2. Точный поиск выбирает на отрезке точку, где f не больше, чем в точке γ_k, а та не больше параболы. Короткий шаг минимизирует параболу с настоящей длиной $\|\mathbf{s}_k - \mathbf{x}_k\|$. В точке γ_k эта более тесная парабола не выше параболы с диаметром D. В обоих случаях h_{k+1} удовлетворяет (17), и индукция из теоремы 3 проходит без изменений.

ЗАМЕЧАНИЕ

Почему сильная выпуклость не меняет порядок

Оценка теоремы 3 не содержит μ. На треугольнике со слайда $L=6$, $\mu=1$, оптимум лежит внутри основания, а не в вершине. Первый шаг равен единице и попадает в вершину. Дальше линейная минимизация чередует вершины основания, точка идёт по хорде, а длина шага $\gamma_k = 2/(k+2)$ имеет порядок $1/k$. Зазор через 40 итераций ещё порядка $2\cdot 10^{-3}$, тогда как проекция градиента на той же задаче уже сжимает его множителем $1-\mu/L$. У методов, которые за итерацию добавляют один атом линейной минимизации, порядок $1/k$ на классе выпуклых L-гладких задач неулучшаем: это нижняя оценка в теореме 1 работы Jaggi.

5. ЧТО ПОЛУЧИЛОСЬ

Метод	Что сжимается	Множитель
Проксимальный градиент, шаг $1/L$	$\|\mathbf{x}_k - \mathbf{x}^\star\|^2$	$1 - \mu/L$
Ускорение с постоянным β	$F(\mathbf{x}_k) - F^\star$	$1 - 1/\sqrt{\kappa}$
Франк — Вульф, шаг $2/(k+2)$	$f(\mathbf{x}_k) - f^\star$	порядок $1/k$, оценка $2LD^2/(k+2)$