ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Метод проекции градиента и метод Франк-Вульфа

МЕТОДЫ ОПТИМИЗАЦИИ

НЕДЕЛЯ 10

План лекции

1. Задача с ограничением на простом множестве
2. Проксимальный оператор и его свойства
3. Составная задача и проксимальный градиент. Проекция как частный случай
4. Ускорение проксимального градиента и численный пример
5. Метод Франка — Вульфа: шаг, отличие от проекции, скорость
6. Где линейная минимизация удобнее проекции
7. Сводка

Что меняется по сравнению с неделями 7–9

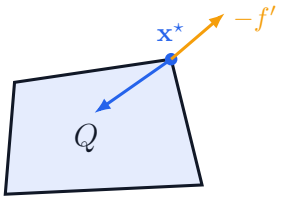
На неделях 7–9 шаг строился в $\mathbb{R}^n$: градиент, инерция, гессиан. Сегодня точка обязана лежать в допустимом множестве Q.

$$f(\mathbf{x}) \;\to\; \min_{\mathbf{x}\in Q}.$$

- $Q \subset \mathbb{R}^n$ выпукло, замкнуто и непусто. Выпуклость — с недели 4: без неё проекция может быть неединственной.
- Множество **простое**, если дёшево решается одна из двух подзадач: проекция на Q или минимизация линейной функции на Q.
- Целевая функция по-прежнему L-гладкая. Оценки недель 7 и 8 переносятся, когда подзадача решается точно.

Стационарность на множестве

На неделе 5 допустимое направление $\mathbf{d}$ в точке $\mathbf{x} \in Q$ — это шаг, который при малом $t > 0$ не выводит из Q. В локальном минимуме нет допустимого направления спуска.



Для выпуклого Q это записывается одним неравенством. Точка $\mathbf{x}^\star \in Q$ является точкой минимума для выпуклой дифференцируемой f, если

$$\langle f'(\mathbf{x}^\star),\, \mathbf{y} - \mathbf{x}^\star \rangle \;\geq\; 0 \qquad \forall\, \mathbf{y} \in Q.$$

- Если $\mathbf{x}^\star$ лежит внутри Q, допустимо любое направление, и неравенство превращается в $f'(\mathbf{x}^\star) = \mathbf{0}$.
- На границе градиент может смотреть наружу. Обнулять его не нужно.

Два оракула простого множества

Оба оракула получают на вход вектор и возвращают точку из Q.

Оракул	Задача	Кто им пользуется
Проекция	$\Pi_Q(\mathbf{z}) = \arg\min_{\mathbf{x}\in Q} \|\mathbf{x}-\mathbf{z}\|$	проксимальный градиентный метод
Линейная минимизация	$\mathbf{s} \in \arg\min_{\mathbf{s}\in Q} \langle \mathbf{c}, \mathbf{s}\rangle$	метод Франк — Вульфа

- Проекция — ближайшая точка. На многограннике ответ обычно лежит на грани.
- Линейная минимизация на многограннике достигает вершины: оптимум линейной функции на политопе — вершина, неделя 4.
- Дальше выбор метода — это выбор оракула. Скорости при этом разные.

Где оба оракула считаются явно

Q	Проекция	Линейная минимизация
Коробка $[l_i, u_i]$	обрезка координаты	конец отрезка с меньшим c_i
Шар $\|\mathbf{x}\| \le R$	масштабирование	$-R\mathbf{c}/\|\mathbf{c}\|$
Симплекс	пороговое отсечение после сортировки	координата $\arg\min_i c_i$

- Проекция на коробку — задача недели 5: условия ККТ распадаются по координатам.
- Проекция на симплекс — порог $\max\{y_i - \nu,\, 0\}$ и один скаляр ν, тоже неделя 5. Сложность $O(n \log n)$.
- На коробке и на шаре хватает одного прохода по координатам.

Проксимальный оператор

Пусть g выпукла и замкнута, $\alpha > 0$. Проксимальный оператор в точке $\mathbf{v}$ —

$$\operatorname{prox}_{\alpha g}(\mathbf{v}) \;=\; \arg\min_{\mathbf{x}} \left(g(\mathbf{x}) + \frac{1}{2\alpha}\|\mathbf{x} - \mathbf{v}\|^2 \right).$$

- Квадрат строго выпуклый, поэтому минимум существует и единственен при любом $\mathbf{v}$.
- α — тот же масштаб, что шаг градиентного метода. Большое α слабее притягивает ответ к $\mathbf{v}$.
- Если g — индикатор Q, то есть $g(\mathbf{x}) = 0$ при $\mathbf{x} \in Q$ и $+\infty$ снаружи, штраф за выход бесконечный. В задаче остаётся только квадрат, и

  $$\operatorname{prox}_{\alpha g}(\mathbf{v}) = \Pi_Q(\mathbf{v}).$$

  От α эта проекция не зависит.

Свойства

- **Нерастяжение.** Для любых $\mathbf{v}, \mathbf{w}$

$$\|\operatorname{prox}_{\alpha g}(\mathbf{v}) - \operatorname{prox}_{\alpha g}(\mathbf{w})\| \;\le\; \|\mathbf{v} - \mathbf{w}\|.$$

  Две траектории с одним и тем же шагом не разъезжаются быстрее, чем их входы.

- **Неподвижная точка.** $\operatorname{prox}_{\alpha g}(\mathbf{x}) = \mathbf{x}$ тогда и только тогда, когда $\mathbf{x}$ минимизирует g. Для индикатора неподвижные точки — это всё Q: проекция точки множества есть она сама.
- **Сепарабельность.** Если $g(\mathbf{x}) = \sum_i g_i(x_i)$, задача распадается на n скалярных. Так устроены ℓ_1-норма и коробка.

Три формулы, которые уже встречались

g	$\operatorname{prox}_{\alpha g}(\mathbf{v})$	Откуда формула
индикатор Q	$\Pi_Q(\mathbf{v})$	определение проекции
$\lambda\|\mathbf{x}\|_1$	$\operatorname{sign}(v_i)\max(\|v_i\|-\alpha\lambda,\,0)$	ККТ недели 5, порог $\tau=\alpha\lambda$
$\frac{\mu}{2}\|\mathbf{x}\|^2$	$\mathbf{v}/(1+\alpha\mu)$	квадрат сдвигается к нулю

Мягкий порог обнуляет координаты, которые по модулю меньше $\alpha\lambda$, и сдвигает остальные к нулю на $\alpha\lambda$.

Композитная задача

$$F(\mathbf{x}) \;=\; f(\mathbf{x}) + g(\mathbf{x}) \;\to\; \min_{\mathbf{x}}.$$

Функция f дифференцируема и L-гладкая. Функция g выпукла, и $\operatorname{prox}_{\alpha g}$ считается быстро. Сама g может быть негладкой.

- Гладкая задача на Q: g — индикатор Q. Тогда $F = f$ на Q.
- LASSO: $f(\mathbf{x}) = \frac{1}{2}\|\mathbf{A}\mathbf{x} - \mathbf{b}\|^2$, $g = \lambda\|\mathbf{x}\|_1$.
- Логистическая регрессия с ℓ_1-штрафом устроена так же: гладкое среднее потерь плюс норма.
- Неотрицательный МНК: g — индикатор $\mathbf{x} \geq \mathbf{0}$. Проекция — обрезка отрицательных координат.

Шаг из верхней модели

Лемма о спуске с недели 7 заменяет f параболой кривизны $1/\alpha$, $\alpha \le 1/L$. К параболе добавляют точное g и минимизируют по приращению:

$$\mathbf{x}_{k+1} = \arg\min_{\mathbf{y}} \left(\langle f'(\mathbf{x}_k),\, \mathbf{y} - \mathbf{x}_k \rangle + \frac{1}{2\alpha} \|\mathbf{y} - \mathbf{x}_k\|^2 + g(\mathbf{y}) \right).$$

Сдвиг $\mathbf{v} = \mathbf{x}_k - \alpha f'(\mathbf{x}_k)$ превращает эту задачу в определение проксимального оператора:

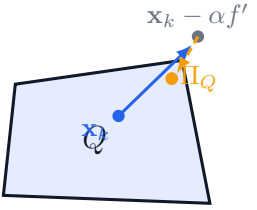
$$\mathbf{x}_{k+1} \;=\; \operatorname{prox}_{\alpha g}\bigl(\mathbf{x}_k - \alpha f'(\mathbf{x}_k)\bigr).$$

- При $\alpha = 1/L$ парабола та же, что у градиентного спуска на неделе 7.
- Градиент нужен только у f. Негладкая g входит через проксимальный оператор.

Проекция градиента — частный случай

Если g — индикатор Q, проксимальный шаг — это градиентный шаг и возврат на множество:

$$\mathbf{x}_{k+1} \;=\; \Pi_Q\big(\mathbf{x}_k - \alpha f'(\mathbf{x}_k)\big), \qquad 0 < \alpha \le \frac{1}{L}.$$



- Градиентный шаг может выйти из Q. Проекция возвращает ближайшую допустимую точку.
- На коробке это обрезка. На шаре — масштабирование. На симплексе — порог и сортировка.
- При $Q = \mathbb{R}^n$ проекция ничего не делает, и шаг совпадает с градиентным спуском.

Теорема: выпуклая композитная задача

Теорема

Пусть f выпукла и L-гладкая, g выпукла, минимум F достигается в $\mathbf{x}^\star$, шаг $\alpha \in (0, 1/L]$. Тогда при $k \geq 1$

$$F(\mathbf{x}_k) - F^\star \;\leq\; \frac{\|\mathbf{x}_0 - \mathbf{x}^\star\|^2}{2\alpha k}.$$

При $\alpha = 1/L$ правая часть равна $L\|\mathbf{x}_0 - \mathbf{x}^\star\|^2/(2k)$.

- Та же оценка, что у градиентного спуска на неделе 7, с F вместо f.
- Негладкость g в скорость не входит: она спрятана в точном проксимальном операторе.
- Для проекции на Q в оценке стоит зазор $f(\mathbf{x}_k) - f^\star$.

Теорема 3.1 в A. Beck, M. Teboulle, SIAM J. Imaging Sci., 2009.

Теорема: f ещё и μ-сильно выпукла

Теорема

Пусть f L-гладкая и μ-сильно выпуклая, g выпукла, шаг равен $1/L$. Тогда

$$\|\mathbf{x}_k - \mathbf{x}^\star\|^2 \;\le\; \left(1 - \frac{\mu}{L}\right)^k \|\mathbf{x}_0 - \mathbf{x}^\star\|^2.$$

- Множитель $1 - 1/\kappa$ тот же, что на неделе 7. Здесь он сжимает квадрат расстояния до минимума.
- Доказательство для проекции опирается на то, что проекция нерастягивающая и $\mathbf{x}^\star = \Pi_Q(\mathbf{x}^\star - f'(\mathbf{x}^\star)/L)$. Проксимальный оператор нерастягивающий по той же причине, поэтому оценка переносится на составную задачу.
- Бюджет по-прежнему порядка $\kappa \log(1/\varepsilon)$.

Для проекции: S. Bubeck, *Convex Optimization: Algorithms and Complexity*, 2015, Theorem 3.10.

Те же числа, что на неделе 7

Выпуклая задача, $L = 10$, $R = \|\mathbf{x}_0 - \mathbf{x}^\star\| = 1$, точность 10^{-4} по значению.

- Проксимальный градиент с шагом $1/L$: $LR^2/(2k) \le 10^{-4}$ даёт $k \ge 5 \cdot 10^4$.
- Это ровно бюджет градиентного спуска с недели 7. Проекция или мягкий порог на каждой итерации бюджет не увеличивают.

Сильно выпуклая задача, те же L и R, $\mu = 1$, так что $\kappa = 10$.

- Квадрат расстояния умножается на $1 - 1/\kappa = 0{,}9$. Чтобы уменьшить его в 10^4 раз, нужно порядка $\kappa \log\bigl(10^4\bigr) \approx 92$ итераций.
- На неделе 7 те же входные данные давали около 108 итераций для зазора по значению. Порядок один: κ, а не κ^2.

То же упреждение, что на неделе 8

Ускорение Нестерова переносится заменой градиентного шага на проксимальный. Схема, в которой μ не используется: $t_0 = 1$, $\mathbf{y}_0 = \mathbf{x}_0$, $\alpha = 1/L$,

$$\begin{aligned}
\mathbf{x}_{k+1} &= \operatorname{prox}_{\alpha g}\bigl(\mathbf{y}_k - \alpha f'(\mathbf{y}_k)\bigr), \\
t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\
\mathbf{y}_{k+1} &= \mathbf{x}_{k+1} + \frac{t_k - 1}{t_{k+1}}(\mathbf{x}_{k+1} - \mathbf{x}_k).
\end{aligned}$$

- Коэффициент $(t_k - 1)/t_{k+1}$ тот же, что у схемы с t_k на неделе 8.
- Точка $\mathbf{y}_k$ может выйти из Q: коэффициент при $\mathbf{x}_k$ отрицательный. Градиент f считается снаружи, prox возвращает $\mathbf{x}_{k+1}$ туда, где g конечна. Значит, f должна быть определена в окрестности Q.

Теорема: ускорение для композитной задачи

Теорема

Пусть f выпукла и L-гладкая, g выпукла, минимум достигается, шаг равен $1/L$, коэффициент инерции считается через t_k. Тогда при $k \geq 1$

$$F(\mathbf{x}_k) - F^\star \;\leq\; \frac{2L\|\mathbf{x}_0 - \mathbf{x}^\star\|^2}{(k+1)^2}.$$

- Порядок $1/k^2$. У проксимального градиентного метода на том же классе — $1/k$.
- На числах недели 7 и 8: $2LR^2/(k+1)^2 \leq 10^{-4}$ при $L = 10$, $R = 1$ даёт $k + 1 \geq 448$ вместо $5 \cdot 10^4$.

Теорема 4.4 в A. Beck, M. Teboulle, SIAM J. Imaging Sci., 2009. Для гладкой f без g это теорема недели 8.

Если μ известна

Постоянный коэффициент берётся из числа обусловленности, как на неделе 8. $\mathbf{x}_{-1} = \mathbf{x}_0$,

$$\mathbf{y}_k = \mathbf{x}_k + \beta(\mathbf{x}_k - \mathbf{x}_{k-1}),$$
$$\mathbf{x}_{k+1} = \operatorname{prox}_{\alpha g}\big(\mathbf{y}_k - \alpha f'(\mathbf{y}_k)\big), \qquad \beta = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}, \quad \alpha = \frac{1}{L}.$$

Теорема

Пусть f L-гладкая и μ-сильно выпуклая, $\kappa = L/\mu$, g выпукла. Тогда зазор $F(\mathbf{x}_k) - F^\star$ убывает с множителем $1 - 1/\sqrt{\kappa}$: число итераций порядка $\sqrt{\kappa}\,\log(1/\varepsilon)$.

- Схема с t_k величины μ не знает и на сильно выпуклой задаче колеблется. Постоянный β быстрее, когда μ надёжна.
- Рестарт тот же, что на неделе 8: если инерция смотрит против градиента, полагают $t_k = 1$.

Численный пример: LASSO

$F(\mathbf{x}) = \frac{1}{2}\|\mathbf{A}\mathbf{x} - \mathbf{b}\|^2 + \lambda\|\mathbf{x}\|_1$, $n = 80$, $\kappa(\mathbf{A}^\top\mathbf{A}) = 400$, $\lambda = 6{,}8 \cdot 10^{-3}$. В сигнале 12 ненулевых координат. Шаг $1/L$, старт в нуле. Ускорение — схема с t_k. $F^\star$ — значение длинного прогона той же схемы.

К зазору 10^{-4} проксимальный градиент приходит на итерации 189, ускоренный — на итерации 43.

Что на графике важно

- Гладкая часть сильно выпукла, $\kappa = 400$. После того как мягкий порог нащупал носитель, проксимальный градиент выходит на прямую в логарифмической шкале: это множитель $1 - 1/\kappa$.
- Ускоренная схема обгоняет её и колеблется. Колебание — свойство коэффициента t_k на сильно выпуклой задаче, оно уже было у метода Нестерова на неделе 8.
- Постоянный $\beta = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ этих зубцов не даёт. Рестарт по скалярному произведению тоже гасит их, и μ для рестарта не нужна.
- ℓ_1-слагаемое не испортило порядок сходимости. В теореме от g требуется только выпуклость и точный prox. Здесь prox — мягкий порог, один проход по координатам.

Линейная модель вместо проекции

Метод Франк — Вульфа, он же метод условного градиента, остаётся в допустимом множестве Q без проекции. В точке $\mathbf{x}_k \in Q$ функцию заменяют линейным приближением и минимизируют его на Q:

$$\mathbf{s}_k \in \arg\min_{\mathbf{s}\in Q} \langle f'(\mathbf{x}_k),\, \mathbf{s}\rangle,$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \gamma_k(\mathbf{s}_k - \mathbf{x}_k), \qquad \gamma_k = \frac{2}{k+2}.$$

- $\mathbf{x}_0 \in Q$. При $\gamma_k \in [0,1]$ и выпуклом Q точка $\mathbf{x}_{k+1}$ — выпуклая комбинация допустимых точек, поэтому она тоже в Q.
- При $k = 0$ шаг равен 1: первая итерация попадает в атом $\mathbf{s}_0$. На многограннике атом — вершина.
- Короткий шаг $\gamma_k = \min\bigl\{1,\ \langle f'(\mathbf{x}_k), \mathbf{x}_k - \mathbf{s}_k\rangle / (L\|\mathbf{s}_k - \mathbf{x}_k\|^2)\bigr\}$ и точный поиск на отрезке $[\mathbf{x}_k, \mathbf{s}_k]$ дают ту же гарантию. Поиск по отрезку делает $f(\mathbf{x}_k)$ монотонной.

Чем шаг отличается от проекции

	Проекция градиента	Франк — Вульф
Подзадача	ближайшая точка	вершина линейной модели
Следующая точка	$\Pi_Q(\mathbf{x} - \alpha f')$	$(1-\gamma)\mathbf{x} + \gamma\mathbf{s}$
Где считается f'	в Q, у ускорения — и снаружи	только в Q
Память о вершинах	нет	$\mathbf{x}_k$ — комбинация атомов

- Проекция двигает точку по нормали к границе. Франк — Вульф двигает её вдоль хорды к вершине.
- После k шагов со стартом в вершине точка Франк — Вульфа лежит в выпуклой оболочке не более чем $k+1$ атомов. Отсюда разреженность разложения.
- На симплексе атом — одна координата. Итерация добавляет вес одной координате и перенормирует остальные.

Зазор Франк — Вульфа

Линейная минимизация сразу даёт верхнюю оценку зазора. Для выпуклой дифференцируемой f и любого $\mathbf{x} \in Q$

$$f(\mathbf{x}) - f^\star \;\le\; \max_{\mathbf{s} \in Q} \langle f'(\mathbf{x}),\, \mathbf{x} - \mathbf{s} \rangle .$$

Правая часть считается из того же $\mathbf{s}$, который метод находит сам: $\langle f'(\mathbf{x}), \mathbf{x} - \mathbf{s} \rangle$.

- Это сертификат. Если величина не больше ε, точка ε-оптимальна, и $\mathbf{x}^\star$ для проверки не нужна.
- Вывод: касательная лежит под графиком, поэтому $f^\star \ge f(\mathbf{x}) + \min_{\mathbf{s} \in Q} \langle f'(\mathbf{x}), \mathbf{s} - \mathbf{x} \rangle$.
- У проекции градиента свой сертификат — норма $\mathbf{G}_\alpha(\mathbf{x})$. В ноль она обращается в том же месте, в минимуме.

Теорема: скорость на выпуклой задаче

Пусть Q выпукло и компактно, $D = \operatorname{diam}(Q) = \max_{\mathbf{x},\mathbf{y}\in Q} \|\mathbf{x} - \mathbf{y}\|$.

Теорема

Пусть f выпукла и L-гладкая, шаг $\gamma_k = 2/(k+2)$. Тогда при $k \geq 1$

$$f(\mathbf{x}_k) - f^\star \;\leq\; \frac{2LD^2}{k+2}.$$

- Порядок $1/k$, как у проксимального градиентного метода без ускорения. В оценке стоит диаметр Q, а не расстояние от старта до минимума.
- Короткий шаг и поиск на отрезке дают оценку того же порядка.
- На классе методов, которые за итерацию добавляют один атом линейной минимизации, порядок $1/k$ неулучшаем.

M. Jaggi, *Revisiting Frank–Wolfe*, ICML, 2013, Theorem 1. Нижняя оценка — там же.

Почему нет ни $1/k^2$, ни линейной скорости

- Ускорение до $1/k^2$ использует упреждение и проекцию. Оракул Франка — Вульфа упреждённую точку снаружи Q не принимает: линейная минимизация определена на Q.
- Сильная выпуклость сама по себе линейную скорость тоже не даёт. Если $\mathbf{x}^\star$ лежит внутри грани с несколькими вершинами, метод по очереди выбирает эти вершины. Хорды пересекают грань, шаг вдоль грани остаётся порядка $1/k$.

S. Lacoste-Julien, M. Jaggi, *On the Global Linear Convergence of Frank–Wolfe Optimization Variants*, NeurIPS, 2015.

Треугольник: проекция и Франк — Вульф

$f(\mathbf{x}) = \frac{1}{2}(x_1 - 1{,}35)^2 + 3(x_2 + 0{,}35)^2$, так что $L = 6$, $\mu = 1$. Безусловный минимум лежит под основанием, условный — в точке $(1{,}35,\ 0)$ на нём. Старт — верхняя вершина. У Франк — Вульфа шаг равен $2/(k+2)$.

Как читать график

- Первый шаг Франк — Вульфа равен единице и попадает в правую вершину. Дальше линейная минимизация чередует вершины основания, и точка прыгает вокруг точки $(1{,}35,\ 0)$.
- Проекция градиента с шагом $1/L$ спускается внутрь треугольника и вдоль основания подходит к минимуму монотонно по значению.
- На правом графике зазор проекции падает по прямой: множитель $1 - \mu/L$. Зазор Франк — Вульфа колеблется и через 40 итераций ещё порядка $2 \cdot 10^{-3}$, тогда как у проекции он уже $2 \cdot 10^{-7}$.
- Оба оракула на треугольнике считаются за несколько операций. Быстрее проекция: задача сильно выпуклая, а оптимум лежит на грани, а не в одной вершине.

Где линейная минимизация дешевле проекции

Множество	Линейная минимизация	Проекция
Спектроэдр $\mathbf{X} \succeq 0$, $\operatorname{tr} \mathbf{X} = 1$	минимальный собственный вектор	все собственные значения
Ядерный шар $\|\mathbf{X}\|_* \le \tau$	старшая сингулярная пара	полное SVD
Оболочка путей в графе	кратчайший путь	квадратичная задача на потоках

- На спектроэдре минимум $\langle \mathbf{C}, \mathbf{X} \rangle$ равен наименьшему собственному значению, и атом — $\mathbf{v}\mathbf{v}^\top$ для соответствующего вектора. Итерация Ланцоша считает один вектор. Проекция просит весь спектр.
- На ядерном шаре атом — $-\tau \mathbf{u}\mathbf{v}^\top$ для старших сингулярных векторов. Проекция мягко обрезает все сингулярные числа.

Задачи, где метод выбирают по оракулу

- **Спектральные ограничения.** Релаксации с матрицей $\mathbf{X} \succeq 0$ и единичным следом. Один собственный вектор на итерацию вместо разложения порядка n^3.
- **Заполнение пропусков в матрице.** Ограничение на ядерную норму, наблюдаемых входов мало. Старшая сингулярная пара определяется умножениями известной матрицы на векторы, полное SVD — нет.
- **Пути и маршруты.** Допустимые точки — выпуклые комбинации путей. Линейная минимизация — алгоритм Дейкстры. Проекция на то же множество квадратична.
- **Симплекс, когда ответ должен быть разреженным.** Проекция на симплекс дешёвая, но плотная. Франк — Вульф добавляет по одной координате: так устроены бустинг и жадное разложение по атомам. После k шагов в комбинации не больше $k + 1$ атомов.

Где Франк — Вульф не берут

- Коробка, неотрицательный ортант, евклидов шар. Проекция — обрезка или одно масштабирование, и к ней применяется ускорение $1/k^2$. Линейная минимизация на коробке возвращает угол, и дальше метод ползёт по граням со скоростью $1/k$.
- Нужна точность заметно лучше 10^{-4}, а проекция доступна. В оценке Франка — Вульфа уменьшение допуска в 100 раз увеличивает бюджет в 100 раз. У ускоренного проксимального метода — в 10 раз.
- Оба оракула дорогие. Пересечение многих сложных ограничений этой лекцией не покрывается: ни проекция, ни вершина линейной модели не считаются за приемлемую цену.

Итоги

Метод	Оракул	Выпуклая L-гладкая	μ-сильно выпуклая
Градиентный спуск	f'	$LR^2/(2k)$	$1 - 1/\kappa$
Нестеров	f'	$2LR^2/(k+1)^2$	$1 - 1/\sqrt{\kappa}$
Проксимальный градиент	prox	$LR^2/(2k)$	$1 - 1/\kappa$
Ускоренный проксимальный	prox	$2LR^2/(k+1)^2$	$1 - 1/\sqrt{\kappa}$
Франк — Вульф	линейная минимизация	$2LD^2/(k+2)$	в общем снова $1/k$

Строка про сильную выпуклость у Франк — Вульфа ломается шагом отхода: на многограннике он возвращает линейную скорость.

Что запомнить

- На выпуклом Q минимум гладкой f — это вариационное неравенство. Внутри Q оно совпадает с $f' = \mathbf{0}$, на границе градиент может смотреть наружу.
- Проксимальный оператор обобщает проекцию. Для индикатора это Π_Q, для $\lambda\|\mathbf{x}\|_1$ — мягкий порог из недели 5.
- Проксимальный градиент делает градиентный шаг по гладкой части и prox по негладкой. Оценки те же, что у градиентного спуска и Нестерова: $1/k$, линейная при $\mu > 0$, ускорение $1/k^2$ и $1 - 1/\sqrt{\kappa}$.
- Франк — Вульф заменяет проекцию линейной минимизацией и держит точку в Q выпуклой комбинацией. Скорость $2LD^2/(k+2)$. Зазор метода сам служит сертификатом.
- Проекцию ускоряют. Линейную минимизацию выбирают, когда один атом дешевле ближайшей точки или когда ответ должен быть короткой комбинацией вершин.

Как выбрать

1. Коробка, шар, неотрицательные переменные, сепарабельный штраф. Проксимальный градиент с шагом $1/L$ и схема с t_k. Если μ известна надёжно — постоянный β.
2. Нужен порядок $1/k^2$, и prox считается. Ускоренный проксимальный метод. Франк — Вульф этот порядок не даёт.
3. Подзадача — собственный вектор, сингулярная пара или кратчайший путь, а проекция просит полное разложение. Франк — Вульф с шагом $2/(k+2)$ или с поиском на отрезке.
4. Ответ — короткая выпуклая комбинация атомов, как в бустинге. Франк — Вульф, даже если проекция на симплекс доступна.

Источники

- A. Beck, M. Teboulle. *A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems.* SIAM Journal on Imaging Sciences, 2009.
- Y. Nesterov. *Lectures on Convex Optimization.* Springer, 2018.
- S. Bubeck. *Convex Optimization: Algorithms and Complexity.* Foundations and Trends in Machine Learning, 2015.
- N. Parikh, S. Boyd. *Proximal Algorithms.* Foundations and Trends in Optimization, 2014.
- M. Frank, P. Wolfe. *An algorithm for quadratic programming.* Naval Research Logistics Quarterly, 1956.
- M. Jaggi. *Revisiting Frank–Wolfe: Projection-Free Sparse Convex Optimization.* ICML, 2013.
- S. Lacoste-Julien, M. Jaggi. *On the Global Linear Convergence of Frank–Wolfe Optimization Variants.* NeurIPS, 2015.

